

Avaliação comparativa e otimização de modelos de aprendizado profundo para segmentação de pistas de pouso em imagens *SAR Sentinel-1*

Matheus H. F. Afonso, Alvaro L. A. Ribeiro e Felipe A. P. de Figueiredo
Instituto Nacional de Telecomunicações – Inatel
Santa Rita do Sapucaí, Brasil

Resumo—A segmentação de pistas de pouso em imagens de radar de abertura sintética contribui para o estudo do monitoramento remoto da Amazônia brasileira. Este trabalho preliminar avalia duas variantes de *You Only Look Once (YOLO)*, *YOLOv8x* e *YOLO11x*, e o *Segment Anything Model (SAM)*, ajustado para a tarefa, em uma coleção local de imagens *Sentinel-1* e máscaras. As avaliações registradas sobre 115 imagens de teste comuns apresentam médias macro de interseção sobre união (*IoU*) e *Dice* de 0,3769 e 0,5061 para o *SAM* de referência histórico, comparadas a 0,1529 e 0,2218 para o *YOLOv8x*. O ponto de verificação avaliado do *YOLO11x* não identifica a classe de interesse com limiar de confiança de 0,25. Diferenças nos dados de treinamento e perdas de segmentação não finitas nos modelos *YOLO* limitam essas comparações. Um ajuste anterior do *SAM*, selecionado com *Optuna*, apresenta *IoU* macro de 0,3820 e *Dice* de 0,5105. Um estudo separado, já concluído, registra 150 tentativas, das quais 148 bem-sucedidas, e seleciona a tentativa 86 com *IoU* de validação de 0,3928; sua avaliação final de teste permanece pendente. Esses parâmetros definem um estudo de ablação controlado, em andamento, com 18 técnicas de pré-processamento e aumento de dados em relação a uma nova configuração de referência. O manuscrito distingue resultados disponíveis, lacunas de proveniência, experimentos em andamento e avaliações futuras de dados sintéticos de treinamento e aumento de dados durante a inferência.

Palavras-chave—Radar de abertura sintética, segmentação semântica, *Segment Anything Model*, *YOLO*, aumento de dados, otimização de hiperparâmetros.

I. INTRODUÇÃO

O monitoramento de pistas de pouso na Amazônia brasileira é uma aplicação relevante do sensoriamento remoto. A cobertura persistente de nuvens restringe a observação óptica, motivando o uso de radar de abertura sintética (*synthetic aperture radar, SAR*). O *Sentinel-1 Amazon Airstrip Dataset* é apresentado por seus autores como um conjunto de dados de pistas clandestinas e disponibiliza imagens *SAR* e anotações para investigar essa tarefa [1], [2]. Este trabalho utiliza a classificação fornecida pelo conjunto, sem atribuí-la ou validá-la: o objetivo é somente segmentar, nas imagens, as regiões anotadas como pistas.

A. L. A. Ribeiro, M. H. F. Afonso e F. A. P. de Figueiredo são vinculados ao *Wireless and Artificial Intelligence Laboratory (WAI Lab)* e ao Instituto Nacional de Telecomunicações (Inatel), Santa Rita do Sapucaí, MG, Brasil (e-mails: alvaro.ribeiro@mtel.inatel.br; matheus.fonseca@mtel.inatel.br; felipe.figueiredo@inatel.br).

Uma delimitação precisa exige distinguir o alvo dos padrões de cobertura do solo ao redor. O ruído *speckle* e os efeitos geométricos das imagens *SAR* dificultam essa interpretação [1], enquanto a pequena largura da região de interesse pode tornar a sobreposição sensível a deslocamentos de contorno. Essas características motivam a avaliação das predições por *pixel* e a inspeção das regiões de falsos positivos e falsos negativos, além da pontuação de localização de um detector.

O aprendizado profundo oferece diferentes abordagens para esse problema, como redes codificador-decodificador, variantes de segmentação do *You Only Look Once (YOLO)* e o *Segment Anything Model (SAM)* [3]–[6]. A Seção IV apresenta o funcionamento dessas arquiteturas. Uma comparação experimental precisa considerar as diferenças entre seus procedimentos de treinamento e inferência.

Trabalhos anteriores investigaram a detecção de pistas com *YOLOv8* em imagens *SAR* da Amazônia [7]. Ainda é necessário examinar a delimitação do alvo, distinguir as fontes de variação entre os experimentos e verificar se a otimização de hiperparâmetros e as transformações dos dados produzem ganhos sob controles comparáveis. A Seção II formaliza esse problema e os objetivos da pesquisa.

Este manuscrito inicial da TP558 documenta uma comparação exploratória entre *YOLOv8x*, *YOLO11x* e *SAM* ajustado à tarefa; um estudo com *Optuna* orientado pela validação, com 150 tentativas registradas; e o protocolo de uma ablação individual de aumento de dados e pré-processamento, ainda em andamento. Nesta etapa, as contribuições são a comparação rastreável dos pontos de verificação disponíveis, a distinção entre dois registros de otimização e a descrição explícita dos controles e das limitações necessários aos próximos experimentos. A ablação constitui um componente metodológico em desenvolvimento, e não uma contribuição quantitativa concluída.

II. PROBLEMA E OBJETIVOS

A. Delimitação do problema

O problema científico investigado é a segmentação, em nível de *pixel*, de pistas de pouso em imagens *SAR Sentinel-1* da Amazônia brasileira. Pretende-se obter máscaras que representem adequadamente a região anotada, apesar do ruído *speckle*, das variações de contraste, dos efeitos geométricos

do imageamento por radar e da forma estreita e alongada do alvo. Pequenos deslocamentos de contorno podem alterar substancialmente a interseção entre predição e referência; por isso, localizar aproximadamente uma pista não é suficiente para o objetivo deste estudo.

Há também um problema metodológico. Os resultados disponíveis foram produzidos por arquiteturas, conjuntos de treinamento, transformações e procedimentos de inferência distintos. Uma diferença de métrica entre pontos de verificação, isoladamente, não permite atribuir o desempenho à arquitetura. A pesquisa deve, portanto, preservar a proveniência dos experimentos e separar três possíveis fontes de variação: a família do modelo, a otimização de hiperparâmetros e o pré-processamento ou aumento de dados.

O escopo é restrito às imagens e máscaras anotadas do conjunto estudado. A saída esperada é uma máscara binária da pista em recortes associados a localizações conhecidas; no estágio atual, não se mede a taxa de falsos alarmes de uma busca sobre regiões extensas.

B. Pergunta de pesquisa

A pergunta principal é: entre os fluxos baseados em *YOLOv8x*, *YOLO11x* e *SAM*, qual apresenta maior potencial para segmentar pistas de pouso nas imagens *SAR* avaliadas e em que medida a otimização de hiperparâmetros e a aplicação controlada de transformações podem melhorar a sobreposição e a generalização das máscaras?

Essa formulação distingue o potencial observado nos pontos de verificação históricos de uma comparação conclusiva entre arquiteturas. Para respondê-la, é necessário avaliar os modelos sobre exemplos comuns, registrar as condições de treinamento e selecionar configurações com dados de validação, reservando o conjunto de teste para a estimativa final de desempenho.

C. Objetivo geral

O objetivo geral é investigar e avaliar modelos de aprendizado profundo para a segmentação de pistas de pouso em imagens *SAR Sentinel-1*, identificando um fluxo experimental promissor e verificando, de forma rastreável, se a otimização de hiperparâmetros e técnicas de transformação dos dados produzem máscaras mais próximas das anotações de referência.

D. Objetivos específicos

Para alcançar o objetivo geral, este trabalho busca:

- 1) estabelecer referências experimentais para *YOLOv8x*, *YOLO11x* e *SAM*, documentando os dados, pontos de verificação e procedimentos associados a cada resultado;
- 2) quantificar a qualidade das máscaras por métricas de sobreposição e examinar qualitativamente regiões de falsos positivos e falsos negativos;
- 3) identificar limitações que impeçam uma comparação válida, incluindo perdas não finitas, ausência de detecções e diferenças entre os dados de treinamento;
- 4) otimizar o ajuste do *SAM* com seleção orientada exclusivamente pelo conjunto de validação e avaliar a configuração selecionada no conjunto de teste;

- 5) medir individualmente o efeito de técnicas de pré-processamento e aumento de dados em relação a uma nova configuração de referência, mantendo as demais condições experimentais constantes;
- 6) selecionar, a partir da validação, transformações candidatas a combinações posteriores e verificar se os ganhos se mantêm em dados não usados nas decisões experimentais; e
- 7) ampliar a avaliação com repetições, análise estatística e separação espacial, além de investigar dados sintéticos restritos ao treinamento e aumento de dados durante a inferência.

Os três primeiros objetivos sustentam a consolidação dos resultados preliminares. No quarto, a busca de hiperparâmetros foi concluída, mas a avaliação de teste da configuração selecionada permanece pendente. O quinto encontra-se em execução, enquanto o sexto e o sétimo orientam as etapas posteriores. Considera-se que um ganho foi demonstrado somente quando a configuração supera sua referência sob o mesmo protocolo, é escolhida sem consultar o teste e mantém a melhoria nas métricas e na inspeção das máscaras. Essa definição permite registrar também resultados negativos ou inconclusivos, que são necessários para estabelecer os limites da abordagem.

III. TRABALHOS RELACIONADOS

A. Imagens *SAR* e segmentação de pistas

Gomes et al. [1] apresentaram um conjunto de dados *Sentinel-1* voltado à detecção e à segmentação de pistas na Amazônia brasileira. Esse conjunto fornece o contexto de aplicação deste estudo e identifica o *speckle* e os efeitos geométricos como desafios relevantes. Em trabalho anterior, Gomes et al. [7] avaliaram o *YOLOv8* para detectar pistas em imagens *SAR*. Como este artigo avalia a sobreposição de máscaras, aqueles resultados de detecção não constituem referências quantitativas para suas tabelas. O artigo do conjunto de dados também identifica um estudo de pistas com *U-Net*, cuja cópia local está anonimizada. **TODO: Obter e verificar o registro final nos anais antes de incluir a referência bibliográfica completa.**

B. Aprendizado profundo para segmentação semântica

Modelos codificador-decodificador, como a *U-Net* [3], associam a extração de características contextuais a predições espacialmente detalhadas. Seus resultados motivam o aprendizado de uma decisão por *pixel* sobre a classe de interesse a partir de pares de imagens e máscaras, reconhecendo que o desempenho em outros domínios de imagem não estabelece o desempenho em *SAR*. O foco desta pesquisa é a avaliação empírica dos fluxos disponíveis de *YOLO* e *SAM*, sem pressupor uma comparação de todas as arquiteturas relevantes de segmentação.

C. Segmentação baseada em *YOLO*

A *Ultralytics* disponibiliza variantes de segmentação de instâncias do *YOLOv8* e do *YOLO11* [4], [5]. Essas referências identificam as famílias implementadas; seus componentes

arquiteturais são apresentados uma única vez na Seção IV. A confiança de detecção, a geração das máscaras e a representação das anotações permanecem partes do fluxo avaliado e podem influenciar a comparação com um preditor semântico.

D. SAM

Kirillov et al. [6] introduziram o *SAM*, e o *AutoGluon* fornece uma adaptação para segmentação semântica [8]. Os experimentos deste artigo ajustam os pesos pré-treinados às máscaras de pistas; portanto, não avaliam a capacidade original sem exemplos específicos de treinamento, denominada *zero-shot*. A arquitetura e a forma de adaptação são detalhadas na Seção IV.

Osco et al. [9] exploraram aplicações do *SAM* em sensoriamento remoto com indicações e aprendizado a partir de um exemplo, ou *one-shot*, relatando limitações para imagens de menor resolução. Especificamente para *SAR*, Pu et al. [10] propuseram adaptadores leves e um decodificador de máscaras por classe para segmentação da cobertura do solo. Esses estudos estabelecem precedentes relevantes para adaptar o *SAM* além das imagens naturais, mas suas classes de interesse e estratégias diferem da tarefa de pistas. Este rascunho não reivindica o primeiro uso de *SAM* em *SAR*.

E. Aumento de dados e otimização de hiperparâmetros

O *MixUp* [11] e o *CutMix* [12] foram propostos como técnicas de regularização, mas ganhos relatados em classificação não estabelecem seu efeito na segmentação *SAR*. A pesquisa combina a seleção de parâmetros com *Optuna* [13] e uma ablação posterior de transformações individuais, cujos mecanismos são explicados na Seção IV e cujos resultados permanecem pendentes.

IV. REVISÃO DA TEORIA

Esta seção reúne os fundamentos necessários para compreender o fluxo experimental e delimita o papel de cada técnica efetivamente utilizada. São abordados o imageamento *SAR*, as duas formulações de segmentação presentes no estudo, as arquiteturas *YOLO* e *SAM*, o ajuste dos modelos, a otimização de hiperparâmetros, o pré-processamento, o aumento de dados e as métricas. Modelos probabilísticos de difusão com remoção de ruído (*denoising diffusion probabilistic models*, *DDPM*) e aumento de dados durante a inferência (*test-time augmentation*, *TTA*) permanecem etapas futuras e, por isso, não são descritos como componentes do método executado.

A. Imagens *SAR Sentinel-1*

O *SAR* é um sensor ativo: a antena transmite pulsos de micro-ondas e registra a energia retroespalhada pela superfície. O movimento da plataforma permite sintetizar uma abertura maior que a antena física e, consequentemente, obter resolução fina na direção azimutal. Como a aquisição não depende da iluminação solar e as micro-ondas atravessam nuvens, esse sensor é apropriado ao monitoramento recorrente de regiões tropicais. A missão *Sentinel-1* opera na banda C e oferece modos padronizados de aquisição, entre eles o *Interferometric Wide (IW)* empregado no conjunto deste estudo [14].

O sinal *SAR* é coerente. A interferência construtiva e destrutiva dos retornos de vários espalhadores dentro de uma célula de resolução produz o *speckle*, uma variação granular que pode ocultar alvos de baixo contraste. A intensidade também depende da geometria de observação, da rugosidade e das propriedades dielétricas da superfície. Nos produtos *Ground Range Detected (GRD)*, os dados já passaram por detecção e projeção para a geometria de terreno; neste trabalho utiliza-se polarização vertical na transmissão e na recepção (*vertical transmit, vertical receive, VV*). Essas características explicam por que filtros de preservação de bordas e transformações de contraste são avaliados, mas não garantem que uma transformação concebida para imagens ópticas preserve informação útil em *SAR* [1], [15].

B. Segmentação semântica, segmentação de instâncias e preparação dos rótulos

Na segmentação semântica, cada *pixel* recebe uma classe. Para a tarefa binária, a referência pode ser representada por $G \in \{0, 1\}^{H \times W}$, em que 1 identifica pista e 0 identifica fundo. A segmentação de instâncias acrescenta a separação entre objetos individuais. O *SAM* ajustado pelo *AutoGluon* produz diretamente uma saída semântica, enquanto as variantes *YOLO* de segmentação predizem caixas e máscaras por instância. Para tornar as saídas comparáveis, as máscaras de todas as instâncias *YOLO* da classe de interesse são unidas em uma única máscara binária antes do cálculo das métricas.

Imagens e rótulos precisam permanecer geometricamente alinhados. Redimensionamentos contínuos da imagem podem usar interpolação com reconstrução, enquanto a máscara categórica deve usar vizinho mais próximo para não criar classes intermediárias. Esse cuidado preserva a correspondência espacial entre a entrada e a classe atribuída a cada *pixel*; a implementação específica é descrita em Materiais e métodos.

C. Arquitetura de segmentação *YOLO*

YOLO é uma família de modelos de uma etapa: a mesma passagem pela rede localiza e classifica objetos, sem uma etapa separada de propostas de regiões. As implementações modernas da *Ultralytics* organizam a rede em *backbone*, *neck* e *head* [16]. O *backbone* extrai padrões locais e progressivamente mais abstratos; o *neck* combina informação semântica profunda com detalhe espacial; e a *head* transforma essas características nas predições da tarefa.

Nos arquivos de arquitetura das variantes de segmentação usadas neste estudo, o *backbone* produz mapas em resoluções sucessivamente menores. O *neck* realiza fusões descendente e ascendente, associadas à rede de pirâmide de características (*Feature Pyramid Network*, *FPN*) e à rede de agregação de caminhos (*Path Aggregation Network*, *PAN*). Por operações de ampliação, redução e concatenação, ele entrega as escalas *P3/8*, *P4/16* e *P5/32*; o denominador indica o passo espacial em relação à entrada. *P3* preserva mais detalhe para objetos estreitos ou pequenos, enquanto *P5* contém contexto com maior campo receptivo. Essa fusão multiescala é especialmente

pertinente para pistas, cujas dimensões aparentes variam entre recortes.

No *YOLOv8-seg*, os blocos *C2f* dividem o fluxo de características, processam parte dele por gargalos residuais e concatenam resultados intermediários. Essa estratégia de caminho parcial reduz redundância e mantém o fluxo de gradientes. Ao final do *backbone*, o agrupamento rápido em pirâmide espacial (*Spatial Pyramid Pooling–Fast, SPPF*) aplica agrupamento máximo sequencial para reunir contexto em diferentes campos receptivos. No *YOLO11-seg*, blocos *C3k2* substituem os *C2f* e permitem gargalos com diferentes configurações de convolução; após o *SPPF*, o *C2PSA* introduz autoatenção espacial em parte dos canais. As duas famílias conservam a fusão *P3–P5* e uma cabeça desacoplada, sem âncoras, para regressão de caixas e classificação [4], [5], [16].

A cabeça *Segment* estende a cabeça de detecção com duas saídas de máscara. A primeira é um conjunto compartilhado de protótipos espaciais; a segunda contém coeficientes específicos de cada detecção, obtidos nas três escalas. A combinação linear entre protótipos e coeficientes gera a máscara de cada instância. As caixas e escores de classe passam por limiarização e supressão de não máximos (*non-maximum suppression, NMS*); depois, as máscaras retidas são reconstruídas e recortadas nas regiões correspondentes. A Figura 1 resume esse caminho. A letra “x” em *YOLOv8x* e *YOLO11x* identifica a escala extragrande de profundidade e largura, não uma arquitetura de segmentação distinta.

D. Arquitetura do SAM

O *SAM* foi concebido como um modelo fundacional de segmentação guiado por indicações (*prompts*) e contém três módulos: codificador de imagens, codificador de indicações e decodificador de máscaras [6]. O codificador de imagens é executado uma vez e produz uma representação densa. Na variante *sam-vit-huge*, ele é baseado em um transformador visual (*Vision Transformer, ViT-H*): a imagem é particionada em blocos (*patches*), convertida em uma sequência de vetores e processada por autoatenção. Diferentemente de uma convolução local, a autoatenção relaciona posições afastadas na imagem, embora seu custo cresça com o número de elementos da sequência.

O codificador de indicações representa pontos positivos ou negativos, caixas e máscaras iniciais. Pontos e caixas tornam-se vetores esparsos com informação posicional; uma máscara torna-se uma representação densa. O decodificador leve recebe a representação da imagem, as incorporações vetoriais (*embeddings*) das indicações e elementos aprendidos (*tokens*). Blocos de atenção cruzada fazem a informação fluir nos dois sentidos entre esses elementos e a imagem; em seguida, uma cabeça dinâmica produz máscaras candidatas e estima sua qualidade. Essa separação permite reutilizar a representação de uma imagem para diferentes solicitações interativas.

Neste projeto, o *MultiModalPredictor* do *AutoGluon* adapta o modelo à segmentação semântica binária supervisionada [8], [17]. A máscara anotada fornece o alvo de treinamento, e a inferência avaliada não exige pontos ou caixas de um operador.

Assim, o resultado representa o *SAM* ajustado ao domínio, e não o uso *zero-shot* do modelo original. A Figura 2 distingue esses fluxos.

E. Transferência de aprendizado, LoRA e otimização do treinamento

O ajuste parte de pesos pré-treinados, uma forma de transferência de aprendizado que reutiliza representações obtidas em uma base maior e adapta o modelo ao domínio *SAR*. Atualizar todos os pesos do *ViT-H* seria computacionalmente dispendioso. A adaptação de baixa ordem (*Low-Rank Adaptation, LoRA*) mantém uma matriz pré-treinada W fixa e aprende uma atualização fatorada

$$W' = W + \Delta W, \quad \Delta W = BA, \quad (1)$$

na qual o posto de BA é muito menor que as dimensões de W . Isso reduz a quantidade de parâmetros treináveis e a memória associada ao otimizador [18]. A opção *lora_norm* do *AutoGluon* utilizada nas execuções estende esse ajuste aos parâmetros de normalização; o codificador de indicações permanece congelado.

O *AdamW* separa o decaimento de pesos da atualização adaptativa do *Adam*, evitando que a regularização seja implicitamente reescalada pelos momentos do gradiente [19]. A taxa de aprendizado controla o tamanho das atualizações, e o decaimento de pesos penaliza soluções com pesos elevados. Os cronogramas cossenoidal, linear e polinomial reduzem essa taxa ao longo das épocas segundo formas diferentes. O treinamento também usa parada antecipada: se a métrica de validação não melhora pelo número de épocas definido pela paciência, o processo é encerrado e mantém-se um ponto de verificação anterior. O lote por unidade de processamento gráfico (*graphics processing unit, GPU*) determina a memória de cada passo; quando o lote total configurado é maior, o arcabouço pode acumular gradientes de vários microlotes antes da atualização.

Nos registros do *AutoGluon*, *StructureLoss* é a função objetivo usada para ajustar a máscara, enquanto a *IoU* de validação seleciona pontos de verificação e hiperparâmetros. Esses papéis não devem ser confundidos: a perda precisa ser diferenciável para orientar os gradientes, ao passo que a métrica mede a sobreposição após a decisão de segmentação. Como a definição exata de *StructureLoss* pertence à versão do *AutoGluon*, a versão do *software* faz parte da especificação reproduzível do experimento.

F. Otimização de hiperparâmetros com TPE

Hiperparâmetros são escolhas externas ao aprendizado dos pesos, como taxa de aprendizado, decaimento de pesos, cronograma, método de ajuste eficiente em parâmetros (*parameter-efficient fine-tuning, PEFT*), paciência e tamanhos de lote. Cada avaliação completa é cara; portanto, a busca não enumera necessariamente todas as combinações. O amostrador de Parzen estruturado em árvore (*Tree-structured Parzen Estimator, TPE*) constrói densidades dos valores de hiperparâmetros associados a observações melhores e piores e prioriza candidatos




Figura 1. Arquitetura conceitual das variantes *YOLO* de segmentação avaliadas. O *backbone* difere entre *YOLOv8* e *YOLO11*, mas ambos fundem as escalas *P3/8*, *P4/16* e *P5/32* e usam uma cabeça que prevê detecções e máscaras de instâncias. Neste estudo, a união das instâncias produz a máscara semântica binária usada na avaliação.




Figura 2. Arquitetura conceitual do *SAM* e sua adaptação no estudo. O modelo original combina a representação *ViT-H* da imagem com indicações; o fluxo experimental usa supervisão por máscaras para produzir uma segmentação binária sem interação durante a inferência. Linhas tracejadas indicam elementos congelados na configuração registrada.

com maior razão entre essas densidades, uma aproximação da melhoria esperada [20].

O *Optuna* implementa essa busca sequencial e registra parâmetros, estados e valores objetivos de cada tentativa [13]. A poda pode interromper configurações pouco promissoras a partir de resultados intermediários; esse mecanismo difere da parada antecipada interna, que encerra o treinamento quando a validação deixa de melhorar. A configuração adotada neste projeto é especificada em Materiais e métodos.

G. Pré-processamento e aumento de dados

O pré-processamento altera a representação antes do aprendizado; o aumento de dados cria variações de treino com o objetivo de reduzir sobreajuste e testar invariâncias plausíveis. Transformações espaciais devem ser aplicadas de maneira idêntica à imagem e à máscara, enquanto filtros de intensidade afetam apenas a imagem. O *Albumentations* coordena essas transformações para alvos complexos [21].

Os filtros avaliados têm mecanismos distintos. O filtro de mediana substitui cada *pixel* pela mediana de uma vizinhança e é robusto a valores extremos. O bilateral calcula uma média ponderada simultaneamente pela distância espacial e pela diferença de intensidade, suavizando regiões semelhantes e reduzindo a mistura através de bordas [22]. O filtro de Lee aproxima a intensidade a partir da média e da variância locais: áreas estimadas como homogêneas recebem maior

suavização, enquanto regiões com variação estrutural retêm mais do valor observado [15]. Como a implementação local é uma aproximação linear por estatísticas locais, seu resultado não deve ser generalizado para todas as variantes de filtros Lee para SAR.

As transformações de contraste atuam na distribuição de intensidades. A transformação de potência aplica $I' = 255g(I/255)^\gamma$; para $\gamma < 1$, intensidades baixas são expandidas. A expansão de contraste mapeia percentis inferior e superior para os extremos do intervalo, reduzindo o efeito de valores atípicos. A equalização de histograma (*Histogram Equalization, HE*) usa a distribuição acumulada global para redistribuir tons. A equalização adaptativa de histograma com limitação de contraste (*Contrast Limited Adaptive Histogram Equalization, CLAHE*) divide a imagem em regiões, limita a amplificação do histograma local e interpola entre regiões, procurando elevar o contraste sem amplificar ilimitadamente o ruído [23].

Os aumentos geométricos avaliados são rotação fixa de 90° , reflexões vertical e horizontal, simetrias do quadrado e *CropAndPad*. A técnica *SquareSymmetry* amostra as oito transformações do grupo diedral do quadrado, combinando rotações e reflexões sem interpolação arbitrária. A *CropAndPad* remove ou acrescenta bordas e redimensiona de volta ao tamanho comum. Os aumentos fotométricos são inversão, $I' = 255 - I$, e *FancyPCA*, que perturba a intensidade ao

longo dos componentes principais dos canais, técnica popularizada no treinamento de redes convolucionais [24]. Como os três canais da nova ablação são cópias do mesmo sinal SAR em tons de cinza, a diversidade cromática disponível à *FancyPCA* é limitada; sua utilidade precisa ser determinada empiricamente.

As técnicas de mistura combinam amostras de treino e seus rótulos. A *Mosaic* organiza quatro amostras em uma grade 2×2 [25]; a *CopyPaste* seleciona componentes da máscara de uma amostra doadora e cola seus *pixels* e rótulos na receptora [26]. A *CutMix* substitui uma região retangular pela região correspondente de outra amostra [12]; a *MixUp* forma uma combinação convexa $\tilde{x} = \lambda x_i + (1 - \lambda)x_j$ e aplica o mesmo peso às máscaras [11]. No protocolo local, λ é amostrado de uma distribuição Beta e as máscaras suaves da *MixUp* são quantizadas em 8 *bits*. Em todas as misturas, os doadores pertencem exclusivamente ao conjunto de treinamento, o que evita transferir conteúdo de validação ou teste para o ajuste.

H. Métricas e decisão experimental

Para uma classe binária, verdadeiros positivos (*true positives*, *TP*) são *pixels* corretamente identificados como pista; falsos positivos (*false positives*, *FP*) são *pixels* de fundo preditos como pista; e falsos negativos (*false negatives*, *FN*) são *pixels* de pista omitidos. A interseção sobre união (*intersection over union*, *IoU*) e o coeficiente *Dice* são definidos por

$$IoU(P, G) = \frac{|P \cap G|}{|P \cup G|}, \quad (2)$$

$$Dice(P, G) = \frac{2|P \cap G|}{|P| + |G|}. \quad (3)$$

Em contagens agregadas, essas expressões correspondem a $TP/(TP + FP + FN)$ e $2TP/(2TP + FP + FN)$. Ambas ignoram verdadeiros negativos no denominador, evitando que a grande quantidade de fundo domine a avaliação. Para uma única matriz de confusão, $Dice = 2IoU/(1 + IoU)$; essa conversão não vale entre médias macro calculadas imagem a imagem.

O limiar de confiança do *YOLO* decide quais detecções entram no pós-processamento. Já o limiar de *IoU* da *NMS* compara caixas preditas entre si para remover duplicatas e não é a mesma grandeza que a *IoU* das máscaras contra a referência. A seleção de modelos e transformações usa somente a validação. O conjunto de teste permanece reservado para estimar o desempenho final da configuração escolhida.

V. MATERIAIS E MÉTODOS

A. Conjunto de dados e partições materializadas

O estudo utiliza a coleção local de imagens e máscaras associada ao conjunto citado na Introdução, identificado como *S1-AAD* e apresentado por Gomes et al. [1]. A versão publicada contém 1.040 localizações de pistas em imagens *Sentinel-1* e fornece anotações para detecção, segmentação e detecção de mudanças. Seus recortes nominais têm 200×200 *pixels*; a aquisição SAR utiliza o modo *Interferometric Wide*, polarização *VV* e produtos *Ground Range Detected*. A versão

pública é a 1 [2]. **TODO: Verificar a correspondência entre os arquivos locais de origem e a versão pública por somas de verificação.**

Os registros de treinamento contêm 1.288 amostras de treino, 281 de validação e 115 de teste. O conjunto de treino materializado contém 644 identificadores originais e uma cópia aumentada por identificador. As frações configuradas são 0,62/0,27/0,11, com semente de divisão 42. Uma auditoria local confirma que os identificadores de origem são disjuntos entre essas partições. Essas contagens descrevem os registros efetivos dos experimentos, sem assumir uma divisão de 70/15/15 ou 80/10/10.

Uma distinção importante diz respeito à resolução. Embora os arquivos *YAML* resolvidos do *SAM* especifiquem um tamanho de 512×512 , os conjuntos locais reutilizados contêm imagens e máscaras *PNG* de 256×256 . A reconstrução do conjunto estava desativada nas configurações salvas. Portanto, o tamanho indicado no *YAML*, isoladamente, não estabelece a resolução usada para criar os arquivos materializados. As reanálises quantitativas apresentadas utilizam a grade de referência de 256×256 . O tamanho de entrada registrado do *YOLO* é 512; o *SAM* aplica adicionalmente suas próprias transformações de redimensionamento e normalização. **TODO: Recuperar o registro histórico de construção do conjunto e a resolução efetiva de entrada do codificador SAM em cada execução.**

O código atual de preparação converte as imagens para tons de cinza, utiliza redimensionamento *LANCZOS* nas imagens e vizinho mais próximo nas máscaras, mapeia o menor valor da máscara *TIFF* para a classe de interesse com valor 255 e os demais valores para o fundo com valor zero. Nas máscaras *PNG* avaliadas, *pixels* diferentes de zero representam a classe de interesse. Isso descreve a implementação disponível e a convenção de rótulos, mas não comprova retrospectivamente cada etapa de pré-processamento usada para construir os arquivos históricos.

B. Fluxo experimental

A Figura 3 separa as avaliações dos pontos de verificação disponíveis, a busca de hiperparâmetros concluída e a etapa de ablação em andamento. Cada valor relatado está vinculado ao seu artefato de origem no registro de evidências que acompanha o artigo. A questão científica é se os fluxos avaliados fornecem delimitações úteis das pistas e se o ajuste de parâmetros e as transformações controladas individualmente melhoram esse desempenho. Como as condições iniciais de treinamento diferem, esta primeira comparação é exploratória.

C. Modelos avaliados

1) *YOLOv8x* e *YOLO11x*: Os pontos de verificação de segmentação são *yolov8x-seg.pt* e *yolo11x-seg.pt*. O segundo é denominado *YOLOv11x* na configuração da pesquisa e *YOLO11x* na documentação do *software* [4], [5]; adota-se *YOLO11x* a seguir. Ambas as execuções utilizam pesos pré-treinados, tamanho de lote 2, entrada de tamanho 512, semente 42, limite de 150 épocas e paciência de parada antecipada de




Figura 3. Organização do estudo. Caixas contínuas identificam registros experimentais disponíveis; a caixa tracejada identifica o protocolo de ablação em andamento. A execução 145 está associada à tentativa anterior 13, não à tentativa 86 da busca concluída de 150 tentativas.

30 épocas. Os registros resolvem *optimizer=auto* para *AdamW*, com taxa de aprendizado de 0,002 e decaimento de pesos de 0,0005; o valor nominal *lr0=0.01* é explicitamente substituído. Os históricos contêm 127 e 57 épocas para *YOLOv8x* e *YOLO11x*, respectivamente.

As configurações salvas do *YOLO* incluem aumento de dados durante o treinamento, com reflexão horizontal, translação, escala e *Mosaic*. As anotações poligonais de segmentação de instâncias são derivadas das máscaras preparadas, enquanto a avaliação utiliza a união binária definida na Seção IV. Assim, comparam-se fluxos completos de treinamento e inferência com diferentes representações da supervisão, em vez de uma substituição isolada da rede extratora de características.

2) *Segment Anything Model*: O *SAM* recebe ajuste fino por meio do *MultiModalPredictor* do *AutoGluon* [6], [8], utilizando *facebook/sam-vit-huge*. A referência histórica corresponde à execução 136. Sua configuração salva utiliza *AdamW*, taxa de aprendizado 10^{-4} , decaimento de pesos 3×10^{-4} , decaimento cossenoidal, adaptação eficiente em parâmetros *lora_norm*, microlote de tamanho 2, lote total configurado de 256 e limite e paciência de 150 épocas. A configuração efetiva registra *structure_loss*, codificador de indicações congelado, cabeça de predição da qualidade das máscaras congelada e um grupo treinável de parâmetros do decodificador de máscaras. Também inclui reflexão horizontal aleatória interna.

O aumento de dados histórico materializado combina *SquareSymmetry* com inversão de intensidade e reflexão vertical, estas duas últimas configuradas com probabilidade 0,5 cada. Portanto, “*SAM* de referência” designa a execução histórica de comparação e não significa “sem aumento de dados”. A execução 145 é um ajuste final separado que utiliza parâmetros de uma exportação anterior do *Optuna*, conforme detalhado a seguir.

Tabela I
ESPAÇO DE BUSCA DO *Optuna* E VALORES SELECIONADOS NA TENTATIVA 86 DO ESTUDO DE 150 TENTATIVAS. OS INTERVALOS CONTÍNUOS USAM AMOSTRAGEM LOGARÍTMICA.

Parâmetro	Espaço de busca	Tentativa 86
Taxa de aprendizado	$[10^{-6}, 10^{-3}]$	$8,8412 \times 10^{-4}$
Decaimento de pesos	$[10^{-6}, 10^{-2}]$	$1,7228 \times 10^{-6}$
Decaimento da taxa	Cossenoidal, linear, polinomial	Polinomial
Método <i>PEFT</i>	<i>LoRA</i> , <i>LoRA + norm</i>	<i>LoRA + norm</i>
Paciência	Inteiros 5–30	23
Microlote	{1, 2}	2
Lote configurado	{128, 256}	128

D. Otimização de hiperparâmetros

O *Optuna* [13] maximiza a *IoU* de validação retornada pelo *AutoGluon*. A implementação utiliza um amostrador *TPE* com semente 42 e *NopPruner*; portanto, não há poda intermediária pelo *Optuna*. Cada tentativa tem limite de 30 épocas e 5.400 segundos de ajuste. O estudo é persistido em *SQLite* e retomado entre submissões ao *Slurm*. O orçamento nominal de 150 tentativas deve ser distinguido da quantidade de tentativas bem-sucedidas.

A Tabela I apresenta o espaço de busca e a configuração selecionada no estudo concluído de 150 tentativas. A configuração separada de treinamento final tem limite de 150 épocas e 82.800 segundos de ajuste. A parada antecipada e os limites de tempo podem encerrar o treinamento antes desse teto. A exportação da execução 145 pertence a um registro anterior do estudo com 14 tentativas, das quais 12 concluídas e duas com falha. Ela seleciona a tentativa 13, com taxa de aprendizado $9,7760089 \times 10^{-4}$, decaimento de pesos $8,1878879 \times 10^{-3}$, decaimento linear, paciência 18 e tamanho de lote configurado de 128. Suas métricas de teste não podem ser atribuídas à tentativa posterior 86.

E. Estudo individual de aumento de dados e pré-processamento

O conjunto de experimentos em andamento define uma nova referência sem transformações opcionais e 18 técnicas individuais, todas com os hiperparâmetros da tentativa 86. Cada conjunto é reconstruído a partir da coleção local original, recebe pré-processamento comum para 512×512 e mantém 644 identificadores de treino, 281 de validação e 115 de teste. Cada tratamento substitui uma amostra de treino por uma versão transformada, preservando a quantidade de amostras. As transformações materializadas permanecem fixas entre épocas. A reflexão horizontal interna e a *MixUp* do *AutoGluon* são desativadas igualmente em todos os experimentos.

As técnicas compreendem filtros bilateral, de mediana e Lee; transformação de potência, expansão de contraste, equalização de histograma e *CLAHE*; *Rotate90*, reflexões vertical e horizontal, *SquareSymmetry*, *CropAndPad*, *FancyPCA* e *InvertImg*; e *Mosaic*, *CopyPaste*, *CutMix* e *MixUp*. A Tabela IV

mantém todas as técnicas configuradas. A implementação local do Lee é uma aproximação baseada em estatísticas locais; a *MixUp* preserva rótulos probabilísticos quantizados. A eficácia dessas técnicas nesta aplicação permanece uma questão experimental.

Apenas amostras de treino recebem transformações opcionais, e os doadores das operações de mistura são restritos aos identificadores de treino. Validação e teste recebem somente o pré-processamento comum. As técnicas são selecionadas pela *IoU* de validação em relação à referência correspondente sem transformações; os resultados de teste não devem selecionar combinações. O novo conjunto de experimentos altera resolução, quantidade de amostras e controles de aumento de dados em relação à referência histórica do *SAM*, exigindo sua própria execução de referência para medir ganhos. Não foram encontradas métricas concluídas desse conjunto nos artefatos locais inspecionados. Desfoque gaussiano, *Canny* e *MixUp* no espaço de Fourier não constam do conjunto configurado e não são relatados como experimentos executados.

F. Métricas de avaliação

As métricas *IoU* e *Dice*, definidas nas Equações 2 e 3, medem a sobreposição entre a máscara predita P e a referência G . As tabelas principais utilizam a média aritmética sobre as mesmas 115 imagens de teste, atribuindo peso igual a cada imagem. Os valores micro, calculados após somar todas as contagens de confusão por *pixel*, constituem outra forma de agregação. Em particular, converter algebricamente a *IoU* média para *Dice* não produz a média de *Dice*.

Os cadernos computacionais de reanálise convertem as máscaras retornadas pelo *SAM* em matrizes booleanas e, quando necessário, redimensionam-nas para a grade de referência por interpolação de vizinho mais próximo. A avaliação do *YOLO* utiliza confiança 0,25, *IoU* de supressão de não máximos (*NMS*) de 0,70, entrada de tamanho 512 e a união das máscaras de instâncias retornadas. A ausência de detecções resulta em uma predição vazia. As funções de *IoU* e *Dice* retornam um para denominador nulo, embora todos os registros de teste inspecionados contenham *pixels* da classe de interesse. A *IoU* nativa do *AutoGluon* e a *IoU* macro calculada manualmente são mantidas como grandezas distintas. **TODO: Arquivar a especificação da saída binária e o ambiente de inferência da reanálise SAM juntamente com as máscaras preditas exportadas.**

G. Protocolo experimental e rastreabilidade

Os registros do ambiente de computação de alto desempenho (*high-performance computing*, *HPC*) identificam *Linux*, *Python* 3.13.13, *AutoGluon* 1.5.0 e uma *GPU NVIDIA H200*. Os registros do *YOLO* também identificam *Ultralytics* 8.4.120, *PyTorch* 2.9.1+cu128 e uma alocação de múltiplas instâncias da unidade gráfica (*Multi-Instance GPU*, *MIG*) *H200* 3g.71gb. A arquitetura unificada de dispositivos de computação (*Compute Unified Device Architecture*, *CUDA*) 12.8 relatada pelo ambiente de execução difere da capacidade *CUDA* 12.9 anunciada pelo controlador. **TODO: Completar, por execução, as**

Tabela II

MÉDIAS MACRO PRELIMINARES DE TESTE EM 115 IMAGENS. *YOLO11x* CORRESPONDE AO *YOLOv11x* DO REPOSITÓRIO. AS EXECUÇÕES *YOLO* TÊM PERDAS DE SEGMENTAÇÃO NÃO FINITAS; OS VALORES DESCREVEM PONTOS DE VERIFICAÇÃO, NÃO UMA CLASSIFICAÇÃO CONTROLADA DE ARQUITETURAS.

Modelo	<i>IoU</i> ↑	<i>Dice</i> ↑
<i>YOLOv8x</i>	0,1529	0,2218
<i>YOLO11x</i>	0,0000	0,0000
<i>SAM</i> de referência (136)	0,3769	0,5061

versões de *PyTorch*, *Optuna* e *Albumentations*, sementes de treinamento, épocas concluídas do *SAM* e revisões históricas do código a partir dos registros de execução. O código inspecionado para este rascunho está identificado no *README*; não se presume que sua revisão seja a mesma utilizada nos treinamentos anteriores.

A auditoria local verifica imagens e máscaras de validação e teste idênticas em *bytes* entre os dois conjuntos históricos materializados, com os mesmos identificadores de teste nas quatro exportações de métricas. Os identificadores de treino também coincidem, mas apenas 690 de 1.288 imagens e 733 de 1.288 máscaras são idênticas em *bytes*. A igualdade dos dados de avaliação, portanto, não implica igualdade dos dados de treinamento. A separação de identificadores não comprova independência geográfica: sobreposição espacial, locais próximos e dependência entre aquisições ainda precisam ser auditados.

VI. RESULTADOS EXPERIMENTAIS

A. Comparação dos modelos de referência

A Tabela II apresenta *IoU* e *Dice* macro de teste a partir das avaliações salvas por imagem. O *SAM* da execução 136 obtém *IoU* de 0,3769 e *Dice* de 0,5061, comparados a 0,1529 e 0,2218 para o *YOLOv8x*. O ponto de verificação avaliado do *YOLO11x* não retorna detecções da classe de interesse com confiança 0,25, produzindo *IoU* e *Dice* iguais a zero nesse conjunto de teste com presença de pistas. Essas observações favorecem o fluxo *SAM* disponível, considerando as diferenças de treinamento e as falhas numéricas discutidas a seguir.

Os históricos dos modelos *YOLO* contêm perdas de segmentação não finitas. O *YOLOv8x* registra o primeiro valor indefinido (*not a number*, *NaN*) na perda de segmentação de treino na época 99; o *YOLO11x*, na época 20. As perdas de segmentação de validação já são não finitas nas épocas 3 e 1, respectivamente. Assim, a pontuação zero é uma propriedade desse ponto de verificação treinado e dessa configuração de inferência, não uma evidência de incapacidade da arquitetura *YOLO11* de segmentar pistas em *SAR*. A varredura de confiança registrada para *YOLO11* é um diagnóstico posterior realizado sobre dados de teste; ela não é usada aqui para escolher um novo limiar nem relatar um resultado de teste ajustado.

A classe de interesse ocupa apenas 0,7668% dos *pixels* das máscaras avaliadas. O *YOLO11x*, portanto, alcança aproxima-




Figura 4. *IoU* de validação ao longo da busca de 150 tentativas. Os pontos representam tentativas concluídas; a linha, o melhor valor concluído até cada momento; e as cruzes, os índices das tentativas com falha no eixo inferior. A numeração das tentativas começa em zero.

Tabela III

MÉDIAS MACRO DE TESTE: O PONTO DE VERIFICAÇÃO OTIMIZADO DISPONÍVEL UTILIZA A TENTATIVA 13 DA BUSCA ANTERIOR. OS RESULTADOS DE TESTE DA TENTATIVA 86 DO ESTUDO DE 150 TENTATIVAS PERMANECEM PENDENTES.

Configuração	<i>IoU</i>	<i>Dice</i>	ΔIoU
<i>SAM</i> de referência	0,3769	0,5061	—
<i>SAM</i> otimizado, tentativa 13	0,3820	0,5105	+0,0051
<i>SAM</i> otimizado, tentativa 86	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>

damente 99,23% de acurácia por *pixel* mesmo sem identificar nenhum *pixel* dessa classe. Isso demonstra por que *IoU* e *Dice* da classe de interesse são mais informativas que a acurácia nesses registros.

B. Otimização de hiperparâmetros do SAM

O estudo com *Optuna* concluído contém 150 tentativas registradas: 148 concluídas e duas com falha. A tentativa 86 alcança a maior *IoU* de validação, 0,3928, sob o protocolo de busca. A Figura 4 mostra as pontuações das tentativas e o melhor valor acumulado. São resultados de validação de ajustes com orçamento limitado, não medidas de teste nem intervalos de confiança.

A Tabela III distingue o modelo ajustado anteriormente da configuração selecionada posteriormente. A execução 145, treinada a partir da tentativa 13, obtém *IoU* macro de teste de 0,3820 e *Dice* de 0,5105. Em relação à execução 136, as diferenças absolutas são 0,0051 em *IoU* e 0,0044 em *Dice* na escala de 0 a 1. As medidas nativas de *IoU* do *AutoGluon* salvas são 0,374334 para a execução 136 e 0,379919 para a execução 145; elas não substituem os valores macro da tabela. Não foi encontrada uma avaliação local de teste atribuível ao modelo final da tentativa 86, de modo que suas células de teste permanecem como *TODO*.

Tabela IV

ABLAÇÃO INDIVIDUAL EM ANDAMENTO COM PARÂMETROS DA TENTATIVA 86. *TODO* INDICA AUSÊNCIA DE AVALIAÇÃO LOCAL CONCLUÍDA, NÃO DESEMPENHO ZERO. OS GANHOS DEVEM USAR A NOVA REFERÊNCIA DO CONJUNTO DE EXPERIMENTOS.

Estratégia	Categoria	<i>IoU</i>	<i>Dice</i>	ΔIoU
Sem aumento	Referência	<i>TODO</i>	<i>TODO</i>	—
Bilateral	Filtro	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
Mediana	Filtro	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
Lee	Filtro	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
Potência	Contraste	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
Expansão de contraste	Contraste	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
<i>HE</i>	Contraste	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
<i>CLAHE</i>	Contraste	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
<i>Rotate90</i>	Geométrica	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
<i>VerticalFlip</i>	Geométrica	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
<i>HorizontalFlip</i>	Geométrica	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
<i>SquareSymmetry</i>	Geométrica	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
<i>CropAndPad</i>	Geométrica	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
<i>FancyPCA</i>	Fotométrica	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
<i>InvertImg</i>	Fotométrica	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
<i>Mosaic</i>	Mistura	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
<i>CopyPaste</i>	Mistura	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
<i>CutMix</i>	Mistura	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>
<i>MixUp</i>	Mistura	<i>TODO</i>	<i>TODO</i>	<i>TODO</i>

As análises existentes nos cadernos computacionais fornecem intervalos obtidos por reamostragem com reposição (*bootstrap*) por imagem. Os intervalos de 95% de *IoU* salvos são [0,3360; 0,4182] para a execução 136 e [0,3420; 0,4234] para a execução 145; os intervalos correspondentes de *Dice* são [0,4595; 0,5527] e [0,4641; 0,5583]. Essas estimativas utilizam 5.000 e 2.000 reamostragens, respectivamente. Elas descrevem a incerteza de reamostragem por imagem condicionada aos modelos ajustados, não a variabilidade entre sementes de treinamento. Não se afirma significância estatística com base nesses intervalos marginais.

C. Experimentos de aumento de dados

O protocolo de ablação individual está implementado e configurado, mas resultados locais concluídos da nova referência e dos 18 tratamentos não estavam disponíveis na elaboração deste rascunho. A Tabela IV preserva o inventário experimental completo. Suas entradas *TODO* devem ser substituídas somente após a conclusão da execução correspondente e a verificação dos dados, modelo, semente e protocolo de avaliação. O objetivo de validação da tentativa 86 não é um resultado da referência da ablação.

D. Resultados qualitativos

A Figura 5 reproduz três exemplos de teste do *SAM* de referência, selecionados aleatoriamente e já armazenados no caderno computacional de análise. Nos três casos, há uma predição alongada próxima à pista anotada, mas erros de largura e alinhamento permanecem visíveis. No exemplo inferior, a predição se estende além da anotação e deixa parte dela descoberta. Essas observações se restringem às amostras exibidas.




Figura 5. SAM de referência (execução 136): três exemplos de teste selecionados pela amostragem aleatória com semente do caderno computacional original. As colunas mostram a entrada SAR, a máscara de referência, a predição e a sobreposição de erros. Verde indica verdadeiros positivos; vermelho, falsos positivos; e amarelo, falsos negativos. O painel original mantém seus rótulos em inglês e é reproduzido sem gerar novamente as predições.

A Figura 6 reproduz o painel original de diagnóstico dos modelos *YOLO*. O caderno computacional selecionou duas imagens com as menores e duas com as maiores médias de *IoU* entre os dois modelos. Essa inclusão deliberada de casos favoráveis e desfavoráveis ilustra modos de falha, mas não estima sua frequência. **TODO: Exportar máscaras alinhadas de *YOLOv8x*, *YOLO11x*, SAM de referência e ajuste final da tentativa 86 em exemplos comuns de baixa, média e alta sobreposição.**

VII. DISCUSSÃO

A. Interpretação da comparação entre modelos

O ponto de verificação do SAM disponível produz uma sobreposição da classe de interesse substancialmente maior que a dos dois pontos de verificação *YOLO* avaliados. Isso sustenta a continuidade da investigação do SAM neste contexto de pesquisa. Entretanto, não isola a arquitetura como causa: os dados de treino materializados, os aumentos de dados internos, a otimização, as representações das anotações e os critérios de seleção dos pontos de verificação diferem. As falhas numéricas dos modelos *YOLO* são especialmente

relevantes, pois a comparação com um treinamento instável não estabelece o desempenho alcançável por essa família.

A representação pré-treinada do SAM e o ajuste fino específico para a tarefa oferecem uma explicação plausível para a delimitação obtida, mas seus efeitos individuais não foram isolados. Uma repetição controlada deve primeiro resolver as perdas não finitas dos modelos *YOLO*, verificar as anotações poligonais e igualar os identificadores de origem e as máscaras de avaliação. Os orçamentos de treinamento e a resolução precisam ser registrados explicitamente. Qualquer seleção do limiar de confiança deve utilizar os dados de validação, especialmente porque a varredura existente sobre o teste já expôs o comportamento nesse conjunto.

Os exemplos qualitativos mostram que localizar uma pista não garante contornos precisos. Para objetos estreitos da classe de interesse, deslocamentos e largura predita excessiva produzem falsos positivos e falsos negativos. Nas contagens agregadas do modelo de referência, os *pixels* falsos positivos superam os falsos negativos. As figuras sugerem categorias de erro úteis para uma análise posterior baseada em anotações, mas não estabelecem uma relação geral entre erro e terreno, condições de aquisição ou dimensões da pista.




Figura 6. Diagnóstico qualitativo salvo dos modelos *YOLO*. Da esquerda para a direita: entrada *SAR*, máscara de referência, máscara e erros do *YOLOv8x*, e máscara e erros do *YOLO11x*. Amarelo indica verdadeiros positivos; vermelho, falsos positivos; e azul, falsos negativos. Os extremos de pontuação selecionados são ilustrativos, não estimativas representativas de frequência.

B. Alcance dos resultados de otimização

A execução 145 apresenta uma pequena diferença positiva na sobreposição macro em relação à referência histórica. Suas contagens agregadas também mostram mais *pixels* verdadeiros positivos e mais falsos positivos, comportamento compatível com uma expansão da predição, em vez de uma melhoria uniforme dos contornos. O ganho de *IoU* observado deve, portanto, ser relatado juntamente com *Dice* e erros qualitativos, sem ser descrito como uma melhoria estatisticamente estabelecida.

A busca de 150 tentativas identifica uma configuração diferente daquela usada na execução 145. Seu objetivo de validação mais alto sustenta a seleção da tentativa 86 para os próximos ajustes controlados, mas não estabelece ganho no teste. Reutilizar os valores de teste da execução anterior para os novos parâmetros mesclaria incorretamente experimentos distintos. Além disso, muitas configurações foram selecionadas no mesmo conjunto de validação, de modo que a melhor pontuação da busca pode ser otimista. Avaliação independente e ajustes repetidos continuam necessários. **TODO: Consolidar o custo computacional total da busca, o custo adicional das**

tentativas com falha e a duração do ajuste final antes de discutir a relação entre custo e benefício.

C. Escopo da ablação de aumento de dados

Avaliar uma transformação opcional por vez permite uma comparação direta com a referência correspondente. Entretanto, não se presume que qualquer técnica seja benéfica. A suavização pode reduzir a variação local de intensidade e, ao mesmo tempo, obscurecer um alvo estreito; mudanças de contraste ou misturas podem alterar as características usadas pelo modelo ajustado. Essas são hipóteses para a ablação, não resultados. Desfechos negativos e neutros devem ser mantidos junto aos positivos.

O novo conjunto de experimentos possui controles mais rigorosos sobre a quantidade de amostras e o aumento de dados interno que os experimentos históricos. Por isso, deve ser analisado como um bloco experimental separado. É necessário obter o resultado de sua referência sem aumento de dados antes de atribuir qualquer mudança posterior a uma transformação. O *Dice* também precisa ser exportado segundo a mesma convenção de avaliação por imagem; os relatórios escalares de

IoU atualmente previstos, isoladamente, não preenchem toda a tabela planejada.

D. Limitações

As evidências atuais consistem em pontos de verificação preliminares ajustados e reanálises locais. Não incluem treinamentos independentes repetidos, avaliação com separação geográfica nem resultados concluídos da ablação. Os intervalos por *bootstrap* existentes não capturam variabilidade de treinamento nem dependência espacial. A correspondência entre arquivos locais de avaliação não autentica os *bytes* das entradas históricas do ambiente *HPC*, e a discrepância entre resolução configurada e armazenada exige uma auditoria da construção do conjunto. Algumas versões de *software* e sementes específicas de cada execução permanecem sem confirmação.

As imagens são centradas em localizações conhecidas de pistas. O desempenho nesses recortes não estabelece a taxa de falsos alarmes de uma aplicação sobre uma área extensa com muitas cenas sem pistas.

Dados de treinamento gerados por *DDPM*, aumento de dados durante a inferência e combinações de técnicas de aumento de dados não foram avaliados neste rascunho. Sua ausência define o escopo atual, sem constituir uma limitação de desempenho demonstrada dos modelos ajustados.

VIII. CONCLUSÃO E TRABALHOS FUTUROS

Este estudo preliminar documenta experimentos com *YOLOv8x*, *YOLO11x* e *SAM* para segmentação de pistas em imagens *SAR Sentinel-1*. O *SAM* de referência disponível alcança *IoU* e *Dice* macro de teste superiores aos dos pontos de verificação *YOLO* avaliados, mas as diferentes condições de treinamento e as perdas não finitas desses modelos impedem uma classificação geral das arquiteturas. O ajuste anterior do *SAM* otimizado, execução 145 a partir da tentativa 13, apresenta uma diferença positiva modesta de sobreposição em relação à referência.

A busca com *Optuna* concluída registra 150 tentativas e seleciona a tentativa 86 pela *IoU* de validação. Seu desempenho final de teste ainda precisa ser documentado separadamente. Os hiperparâmetros selecionados sustentam um conjunto controlado de experimentos em andamento, composto por uma nova referência e 18 técnicas individuais de pré-processamento ou aumento de dados. *IoU* e *Dice* permanecem como as principais medidas de sobreposição, com avaliações ausentes explicitamente marcadas como pendentes.

Os próximos passos são resolver a instabilidade de treinamento dos modelos *YOLO*, recuperar registros ausentes de proveniência e resolução efetiva, avaliar o ajuste da tentativa 86 e concluir a ablação individual. Posteriormente, as combinações serão escolhidas com base nas evidências de validação. As extensões planejadas incluem amostras geradas por *DDPM* adicionadas exclusivamente ao treino, aumento de dados durante a inferência (*TTA*) com reflexões, rotações e escalas, e comparação entre média de probabilidades e votação. Execuções repetidas, análise pareada de incerteza e avaliação espacialmente independente serão necessárias para

avaliar a estabilidade e a generalização de eventuais melhorias. Não se afirma benefício dessas técnicas futuras no presente rascunho.

REFERÊNCIAS

- [1] L. d. S. Gomes, G. H. d. Q. Stabile, T. N. Kuck, F. A. P. de Figueiredo, E. H. Shiguemori, and D. I. Alves, "A Sentinel-1 SAR imagery dataset for airstrips detection and segmentation in the Brazilian Amazon Rainforest," *Data in Brief*, vol. 65, p. 112472, 2026. [Online]. Available: <https://doi.org/10.1016/j.dib.2026.112472>
- [2] L. Gomes, G. Stabile, T. Kuck, F. Figueiredo, E. Shiguemori, and D. I. Alves, "S1-AAD: Sentinel-1 Amazon Airstrip Dataset," Mendeley Data, version 1, 2025. [Online]. Available: <https://data.mendeley.com/datasets/x7rn78ymtn/1>
- [3] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," arXiv:1505.04597, 2015. [Online]. Available: <https://arxiv.org/abs/1505.04597>
- [4] G. Jocher, A. Chaurasia, and J. Qiu, "Ultralytics YOLOv8," Software documentation, 2023, accessed: Sep. 13, 2026. [Online]. Available: <https://docs.ultralytics.com/models/yolov8/>
- [5] G. Jocher and J. Qiu, "Ultralytics YOLO11," Software documentation, 2024, accessed: Sep. 13, 2026. [Online]. Available: <https://docs.ultralytics.com/models/yolo11/>
- [6] A. Kirillov, E. Mintun, N. Ravi, H. Mao, C. Rolland, L. Gustafson, T. Xiao, S. Whitehead, A. C. Berg, W.-Y. Lo, P. Dollár, and R. Girshick, "Segment anything," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 4015–4026. [Online]. Available: https://openaccess.thecvf.com/content/ICCV2023/html/Kirillov_Segment_Anything_ICCV_2023_paper.html
- [7] L. d. S. Gomes, E. H. Shiguemori, T. N. Kuck, and D. I. Alves, "Evaluation of a YOLOv8-based method for detecting unauthorized airstrips in the Amazon Rainforest using SAR imagery," in *XLII Brazilian Symposium on Telecommunications and Signal Processing (SBTrT)*, 2024. [Online]. Available: <https://biblioteca.sbtrt.org.br/articles/4657>
- [8] AutoGluon Developers, "AutoMM for semantic segmentation—quick start," AutoGluon 1.5.0 documentation, accessed: Sep. 13, 2026. [Online]. Available: https://auto.gluon.ai/stable/tutorials/multimodal/image_segmentation/beginner_semantic_seg.html
- [9] L. P. Osco, Q. Wu, E. L. de Lemos, J. N. Gonçalves, A. P. M. Ramos, J. Li, and J. Marcato Junior, "The Segment Anything Model (SAM) for remote sensing applications: From zero to one shot," arXiv:2306.16623, 2023. [Online]. Available: <https://arxiv.org/abs/2306.16623>
- [10] X. Pu, H. Jia, L. Zheng, F. Wang, and F. Xu, "ClassWise-SAM-Adapter: Parameter efficient fine-tuning adapts Segment Anything to SAR domain for semantic segmentation," arXiv:2401.02326, 2024. [Online]. Available: <https://arxiv.org/abs/2401.02326>
- [11] H. Zhang, M. Cisse, Y. N. Dauphin, and D. Lopez-Paz, "mixup: Beyond empirical risk minimization," in *International Conference on Learning Representations (ICLR)*, 2018. [Online]. Available: <https://openreview.net/forum?id=r1Ddp1-Rb>
- [12] S. Yun, D. Han, S. J. Oh, S. Chun, J. Choe, and Y. Yoo, "CutMix: Regularization strategy to train strong classifiers with localizable features," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019, pp. 6023–6032. [Online]. Available: https://openaccess.thecvf.com/content_ICCV_2019/html/Yun_CutMix_Regularization_Strategy_to_Train_Strong_Classifiers_With_Localizable_Features_ICCV_2019_paper.html
- [13] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2019, pp. 2623–2631. [Online]. Available: <https://doi.org/10.1145/3292500.3330701>
- [14] R. Torres, P. Snoei, D. Geudtner, D. Bibby, M. Davidson, E. Attema, P. Potin, B. Rommen, N. Floury, M. Brown, I. N. Traver, P. Deghay, B. Duesmann, B. Rosich, N. Miranda, C. Bruno, M. L'Abbate, R. Croci, A. Pietropaolo, M. Huchler, and F. Rostan, "GMES Sentinel-1 mission," *Remote Sensing of Environment*, vol. 120, pp. 9–24, 2012. [Online]. Available: <https://doi.org/10.1016/j.rse.2011.05.028>
- [15] J.-S. Lee, "Digital image enhancement and noise filtering by use of local statistics," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. PAMI-2, no. 2, pp. 165–168, 1980. [Online]. Available: <https://doi.org/10.1109/TPAMI.1980.4766994>

- [16] Ultralytics, “YOLO architecture explained,” Software documentation, accessed: Sep. 14, 2026. [Online]. Available: <https://docs.ultralytics.com/guides/yolo-architecture/>
- [17] Z. Tang, H. Fang, S. Zhou, T. Yang, Z. Zhong, C. Hu, K. Kirchhoff, and G. Karypis, “AutoGluon-Multimodal (AutoMM): Supercharging multimodal AutoML with foundation models,” in *Proceedings of the Third International Conference on Automated Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 256, 2024, pp. 15/1–35. [Online]. Available: <https://proceedings.mlr.press/v256/tang24a.html>
- [18] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, “LoRA: Low-rank adaptation of large language models,” in *International Conference on Learning Representations (ICLR)*, 2022. [Online]. Available: <https://openreview.net/forum?id=nZeVKeeFYf9>
- [19] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *International Conference on Learning Representations (ICLR)*, 2019. [Online]. Available: <https://openreview.net/forum?id=Bkg6RiCqY7>
- [20] J. S. Bergstra, R. Bardenet, Y. Bengio, and B. Kégl, “Algorithms for hyper-parameter optimization,” in *Advances in Neural Information Processing Systems*, vol. 24, 2011. [Online]. Available: <https://proceedings.neurips.cc/paper/2011/hash/86e8f7ab32cfd12577bc2619bc635690-Abstract.html>
- [21] A. Buslaev, V. I. Iglovikov, E. Khvedchenya, A. Parinov, M. Druzhinin, and A. A. Kalinin, “Albumentations: Fast and flexible image augmentations,” *Information*, vol. 11, no. 2, p. 125, 2020. [Online]. Available: <https://doi.org/10.3390/info11020125>
- [22] C. Tomasi and R. Manduchi, “Bilateral filtering for gray and color images,” in *Proceedings of the Sixth International Conference on Computer Vision (ICCV)*, 1998, pp. 839–846. [Online]. Available: <https://doi.org/10.1109/ICCV.1998.710815>
- [23] S. M. Pizer, E. P. Amburn, J. D. Austin, R. Cromartie, A. Geselowitz, T. Greer, B. M. ter Haar Romeny, J. B. Zimmerman, and K. J. Zuiderveld, “Adaptive histogram equalization and its variations,” *Computer Vision, Graphics, and Image Processing*, vol. 39, no. 3, pp. 355–368, 1987. [Online]. Available: [https://doi.org/10.1016/S0734-189X\(87\)80186-X](https://doi.org/10.1016/S0734-189X(87)80186-X)
- [24] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet classification with deep convolutional neural networks,” in *Advances in Neural Information Processing Systems*, vol. 25, 2012. [Online]. Available: <https://proceedings.neurips.cc/paper/2012/hash/c399862d3b9d6b76c8436e924a68c45b-Abstract.html>
- [25] A. Bochkovskiy, C.-Y. Wang, and H.-Y. M. Liao, “YOLOv4: Optimal speed and accuracy of object detection,” arXiv:2004.10934, 2020. [Online]. Available: <https://arxiv.org/abs/2004.10934>
- [26] G. Ghiasi, Y. Cui, A. Srinivas, R. Qian, T.-Y. Lin, E. D. Cubuk, Q. V. Le, and B. Zoph, “Simple copy-paste is a strong data augmentation method for instance segmentation,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 2918–2928. [Online]. Available: https://openaccess.thecvf.com/content/CVPR2021/html/Ghiasi_Simple_Copy-Paste_Is_a_Strong_Data_Augmentation_Method_for_Instance_CVPR_2021_paper.html



Matheus H. F. Afonso é graduado em Engenharia da Computação pelo Instituto Nacional de Telecomunicações (Inatel) e mestrando em Telecomunicações pela mesma instituição, com foco em inteligência artificial. Participou de atividades de iniciação científica no Laboratório de Cibersegurança e Internet das Coisas (CS&ILAB) e atuou como monitor de Física. Atualmente, é Desenvolvedor de *Machine Learning I* no *Inatel Competence Center (ICC)*, no departamento de Pesquisa, Desenvolvimento e Inovação de *Software* (PDI SW), atuando no desenvolvimento, na

otimização e na operação de fluxos de aprendizado de máquina. Seus interesses incluem aprendizado de máquina, visão computacional, operações de aprendizado de máquina (*machine learning operations, MLOps*) e engenharia de *software*.



software, aprendizado de máquina e inteligência artificial.

Alvaro L. A. Ribeiro é graduado em Engenharia de *Software* pelo Instituto Nacional de Telecomunicações (Inatel) e possui formação técnica em Instalação e Reparação de Redes de Computadores pelo SENAI Orlando Chiarini. Foi estagiário do *Inatel Competence Center (ICC)* na área de Pesquisa e Desenvolvimento de *Software*. Também atuou como pesquisador no Laboratório de Cibersegurança e Internet das Coisas (CS&ILAB), onde participou de projetos de desenvolvimento de *software* seguro. Seus interesses de pesquisa incluem engenharia de



Felipe A. P. de Figueiredo recebeu os títulos de Bacharel e Mestre em Telecomunicações pelo Instituto Nacional de Telecomunicações (Inatel), Minas Gerais, Brasil, em 2004 e 2011, respectivamente. Recebeu o título de Doutor pela Universidade Estadual de Campinas (Unicamp), Brasil, em 2019. Atua há mais de quinze anos em pesquisa e desenvolvimento de sistemas de telecomunicações. Seus interesses de pesquisa incluem processamento digital de sinais, comunicações digitais, comunicações móveis com múltiplas entradas e saídas (*multiple-input multiple-output, MIMO*), modulações multiportadoras, desenvolvimento em matriz de portas programável em campo (*field-programmable gate array, FPGA*) e

aprendizado de máquina.