


TP558 - Tópicos avançados em
Machine Learning:
*Denoising Diffusion Probabilistic
Models - DDPM*



Agenda

- | | | |
|---|------------------------|--------------------------------|
| 1 | Motivação | Por que modelos de difusão? |
| 2 | Fundamentos | Forward, reverse e treinamento |
| 3 | Reprodução | Notebooks, vídeos e métricas |
| 4 | Análise crítica | Limitações, DDIM e soluções |
| 5 | Síntese | Usos viáveis e conclusão |

O problema de geração

Dados observados

Amostras reais disponíveis no dataset são limitados para treinamento do modelo.

Distribuição aprendida

Modelo aproxima regularidades dos dados gerados por conta de similaridade.

Novas amostras

Saídas plausíveis, não cópias diretas.

Geração pode ser incondicional ou guiada por classe, texto, imagem, mapa semântico ou medidas.

Pergunta prática: como gerar dados novos mantendo qualidade, diversidade e controle?

Por que surgiu o DDPM?

2015

Diffusion Probabilistic Models

Surge a ideia de destruir os dados progressivamente com ruído e aprender o processo inverso.

Desafio

A abordagem ainda não demonstrava geração de imagens com qualidade competitiva.

2020

DDPM

Ho et al. tornam a difusão competitiva em geração de imagens com uma formulação baseada em **predição de ruído** e conexão com **score matching**.


O DDPM não surgiu para substituir GANs, mas para tornar modelos de difusão competitivos em qualidade com um treinamento simples e estável.

Treino não adversarial • predição de ruído • formulação probabilística

Duas cadeias de Markov: forward conhecido adiciona ruído; reverse aprendido remove ruído.


1) FORWARD PROCESS (q) – FIXO

Adiciona ruído gradualmente até obter ruído gaussiano puro.




2) REVERSE PROCESS (p_θ) – APRENDIDO


Remove o ruído passo a passo para gerar novos dados.



3) TREINAMENTO (em cada iteração)



4) GERAÇÃO (SAMPLING / INFERÊNCIA)



IDEIA CENTRAL O forward destrói a informação de forma controlada. A rede aprende a estimar o ruído em cada nível para inverter esse processo e transformar ruído puro em dados realistas.

Forward: a imagem perde informação



Leitura do vídeo

Mais $t \rightarrow$ menos sinal $\rightarrow$ mais ruído

A mesma fórmula produz os estados intermediários do processo.

Ponto-chave

O forward é fixo e conhecido. Ele não aprende nada, apenas cria versões ruidosas do dado.

Backward: aprendendo a remover ruído

Distribuição reversa

$$p_{\theta}(x_{t-1} | x_t) = N(\mu_{\theta}(x_t, t), \sigma_t^2 I)$$

O que a rede estima?

$\epsilon_{\theta}(x_t, t)$: o ruído presente no estado atual.


A rede não desenha tudo de uma vez: resolve repetidamente um pequeno problema de denoising.

O que significam t, T e os passos?

<u>Símbolo</u>	<u>Significado</u>	<u>Na reprodução</u>
t	<u>Índice / nível de ruído fornecido à rede</u>	$0 \leq t < 1000$
T	<u>Tamanho da agenda de ruído do treinamento</u>	1000
S	<u>Avaliações escolhidas pelo amostrador</u>	DDPM 1000 • DDIM 100/250

Mais S geralmente reduz erro de discretização, mas aumenta a latência e o ganho pode saturar.

Como o DDPM é treinado



No treino, não é necessário executar todos os T passos por imagem.



Para que modelos de difusão servem?

Síntese

texto→imagem, classe→imagem,
imagem→imagem

Restauração

super-resolução, inpainting, deblurring

Dados sintéticos

aumento de dados e conjuntos para
tarefas posteriores

Multimodal

vídeo, áudio, linguagem e séries temporais

Ciência


moléculas, proteínas, estruturas 3D

Saúde

reconstrução de MRI e problemas inversos

A mesma ideia — transportar uma distribuição simples de ruído para dados complexos — se adapta a diferentes modalidades.

Uso prático: geração de dados sintéticos



Cenários úteis





classes raras • imagens médicas • defeitos industriais • condições adversas

Cuidados

dados sintéticos podem amplificar vieses, memorizar padrões e distorcer a distribuição real

A pergunta não é “a imagem parece bonita?”, mas “ela melhora uma tarefa real sem introduzir risco?”.

O modelo realmente aprendeu?



MSE de validação

0,04963 → 0,03229

Redução relativa

34,93% após o ajuste

Cuidado

MSE de ruído não mede sozinha realismo ou diversidade.

Limitações do DDPM

1 **Latência**

Centenas ou milhares de avaliações sequenciais.

2 **Custo**

Memória, energia e treinamento de redes grandes.

3 **Avaliação**

Amostra bonita não garante cobertura ou diversidade.

4 **Dados e segurança**

Vieses, memorização, licenças e conteúdo indevido.

A principal limitação operacional do DDPM original é a amostragem iterativa.

Como a pesquisa ataca as limitações

Muitos passos

DDIM - solvers ODE/SDE - Distilação

Alto custo

Difusão latente - Arquiteturas eficientes

Baixo controle

Condicionamento - Guidance

Qualidade

Agendas - Variância aprendida - Cascatas

Avaliação

FID/KID + Cobertura + Inspeção humana

Cada solução reduz um gargalo e cria outro compromisso.

DDIM: a solução demonstrada



Mesmo treinamento

Reutiliza o preditor de ruído do DDPM.

Menos passos

Escolhe uma subsequência de níveis t .

$\eta = 0$

Trajetória determinística com x_T fixo.

Mais passos: geralmente mais fidelidade, maior tempo e ganho eventualmente saturado.

Outras soluções importantes

Inatel

Solvers eficientes

Menos erro numérico com poucas avaliações.

Distilação

Condensa várias etapas em poucas etapas aprendidas.

Latent diffusion

Executa denoising em uma representação comprimida.

Guidance

Aumenta aderência à classe, texto ou observação.

Essas soluções tornaram modelos de difusão mais aplicáveis fora de ambientes puramente acadêmicos.

Onde o uso é mais viável?

Boa escolha quando

- Qualidade importa mais que poucos milissegundos
- Há edição, inpainting, super-resolução ou condicionamento
- Múltiplas soluções plausíveis são úteis

Não recomendado quando

- Há hardware restrito ou tempo real rígido
- Método determinístico simples já resolve
- Faltam dados, licença ou orçamento computacional

Decisão prática: o benefício de modelar uma distribuição justifica o custo iterativo?

Denoising Diffusion Probabilistic Models - DDPM

1. Aprender

DDPM prediz e remove ruído, revertendo um forward conhecido para gerar novos dados.

2. Trocar

Treino simples e não adversarial em troca de amostragem lenta.

3. Acelerar

DDIM e difusão latente tornam a abordagem mais prática.

Formulação probabilística clara + objetivo simples + evolução dos amostradores

Obrigado pela atenção!

Forms



<https://forms.gle/gH4DFu4DGdu6gAEC8>

Código, notebooks e artigos



<https://github.com/Mestrado-Matheus-Fonseca/matheus-983-tp558>

Referências

- [1] HO, J.; JAIN, A.; ABBEEL, P. Denoising Diffusion Probabilistic Models. NeurIPS, 2020.
- [2] SONG, J.; MENG, C.; ERMON, S. Denoising Diffusion Implicit Models. ICLR, 2021.
- [3] YANG, L. et al. Diffusion Models: A Comprehensive Survey of Methods and Applications. ACM Computing Surveys.
- [4] GHOJOGH, B.; GHODSI, A. Diffusion Models: Tutorial and Survey. 2024.
- [5] Reprodução experimental: notebooks, checkpoints, métricas e vídeos em seminar_1 deste repositório.

[PDFs completos em seminar_1/articles](#) • [código no QR do repositório](#)

Perguntas?