


TP558 - Tópicos avançados em Machine Learning: ***SAM 2 – Segment Anything***



Agenda da apresentação

Roteiro do seminário: da motivação do problema até a análise crítica e o encerramento.

1

Motivação e conceitos

Problema, tipos de segmentação e métricas para ler os resultados.

2

SAM original

Segmentação promptable em imagens e limitações em vídeo.

3

SAM 2

Arquitetura, memória temporal e ciclo iterativo.

4

Resultados do artigo

SA-V, ganho de anotação, FPS e benchmarks.

5

Execução local

SAM 2 Tiny, falhas, baseline e interpretação das métricas.

6

Análise crítica e fechamento

Pontos fortes, limitações, links, perguntas e conclusão.

i

Objetivo: explicar onde o SAM 2 melhora o SAM original e como avaliar seus resultados.

Segmentação: conceitos mínimos para ler os resultados



Semântica

Cada pixel recebe uma classe. Não distingue duas instâncias da mesma classe.



Instância

Separa objetos individualmente, mesmo quando pertencem à mesma classe.



Panóptica

Combina semântica + instância para descrever toda a cena.



VOS

Segmenta e acompanha um objeto ao longo de vários frames.

SAM/SAM 2 entram em outra perspectiva: segmentação interativa orientada por prompt.



ponto +



ponto -



box



máscara

O prompt define a intenção do usuário; o modelo não depende de uma lista fixa de classes.

Como avaliar a segmentação



Métricas em imagens



IoU

Interseção sobre união entre a predição e o ground truth.



Dice

Duas vezes a interseção dividida pela soma das áreas.



mIoU

IoU médio calculado sobre todas as classes.



Precisão

Proporção de pixels preditos que estão corretos.



Recall

Proporção de pixels reais que foram recuperados.



Métricas em vídeo

J

J

Média do IoU ao longo do tempo (consistência da segmentação).

F

F

Média do F-measure (Dice) ao longo do tempo.

J&F

J&F

Média harmônica entre J e F para equilibrar qualidade e contorno.



G

Método de qualidade global que penaliza erros e instabilidade temporal.

FPS

FPS

Frames processados por segundo (custo computacional).



Nenhuma métrica isolada conta toda a história: é importante combinar **qualidade espacial**, **consistência temporal** e **custo computacional**.

SAM: a base do “Segment Anything”

SAM é um vision foundation model para segmentação promptable em imagens.

- **Segmenta** objetos a partir de pontos, caixas ou máscaras.
- **É class-agnostic:** o usuário indica a região de interesse, não uma classe fixa.
- Foi treinado em **grande escala** para forte generalização zero-shot.
- Permite **refinar** a máscara adicionando novos prompts.


Fluxo de uso do SAM



prompt + imagem → máscara


A ideia central do SAM é interação espacial.
Ainda não há uma memória temporal nativa.

Arquitetura do SAM



Ponto-chave: a saída do SAM é uma máscara em um frame. Não existe um estado temporal compartilhado entre frames.

Por que o SAM original não resolve vídeo sozinho?



! Abordagem desacoplada

SAM + tracker pode propagar uma máscara, mas uma falha frequentemente exige reanotar e reiniciar o tracking.



Problema central: consistência temporal e correção interativa ao longo do vídeo.

SAM 2: objetivo e contribuições do artigo



Objetivo

Criar um modelo único para segmentação promptable em imagens e vídeos.



Hipótese de projeto

A memória temporal pode generalizar a ideia de SAM para manter e corrigir objetos ao longo do vídeo.



Tarefa

Promptable Visual Segmentation: prompts em qualquer frame definem/refinam um segmento espaço-temporal.



Contribuições declaradas

- Arquitetura Transformer com streaming memory.
- Data engine humano-no-loop para coletar anotações de vídeo em escala.
- SA-V: o maior dataset de segmentação de vídeo apresentado no artigo.
- Melhor qualidade com menos interações; em imagens, maior velocidade que SAM.

SAM → SAM 2: o que realmente mudou?

Aspecto	SAM	SAM 2
Domínio	Imagem	Imagem + vídeo
Prompt	Pontos / box / máscara	Mesmo conjunto de prompts
Estado temporal	Não	Streaming memory
Saída em vídeo	—	Masklet
Correção	Refina o frame	Refina e propaga para outros frames
Encoder	ViT	Hiera hierárquico

Diferencial central: o SAM 2 não trata cada frame como um problema isolado.

Promptable Visual Segmentation e o conceito de masklet

1

O usuário fornece um prompt em qualquer frame.

2


O modelo segmenta o objeto nesse frame.

3

A identidade é propagada no tempo — masklet.

4

Novos prompts corrigem o masklet e podem ser propagados.



masklet = sequência de máscaras do mesmo objeto

Um único prompt pode orientar vários frames — e uma correção futura pode recuperar o masklet.

Arquitetura do SAM 2

Segmentação em imagens e vídeos com memória streaming



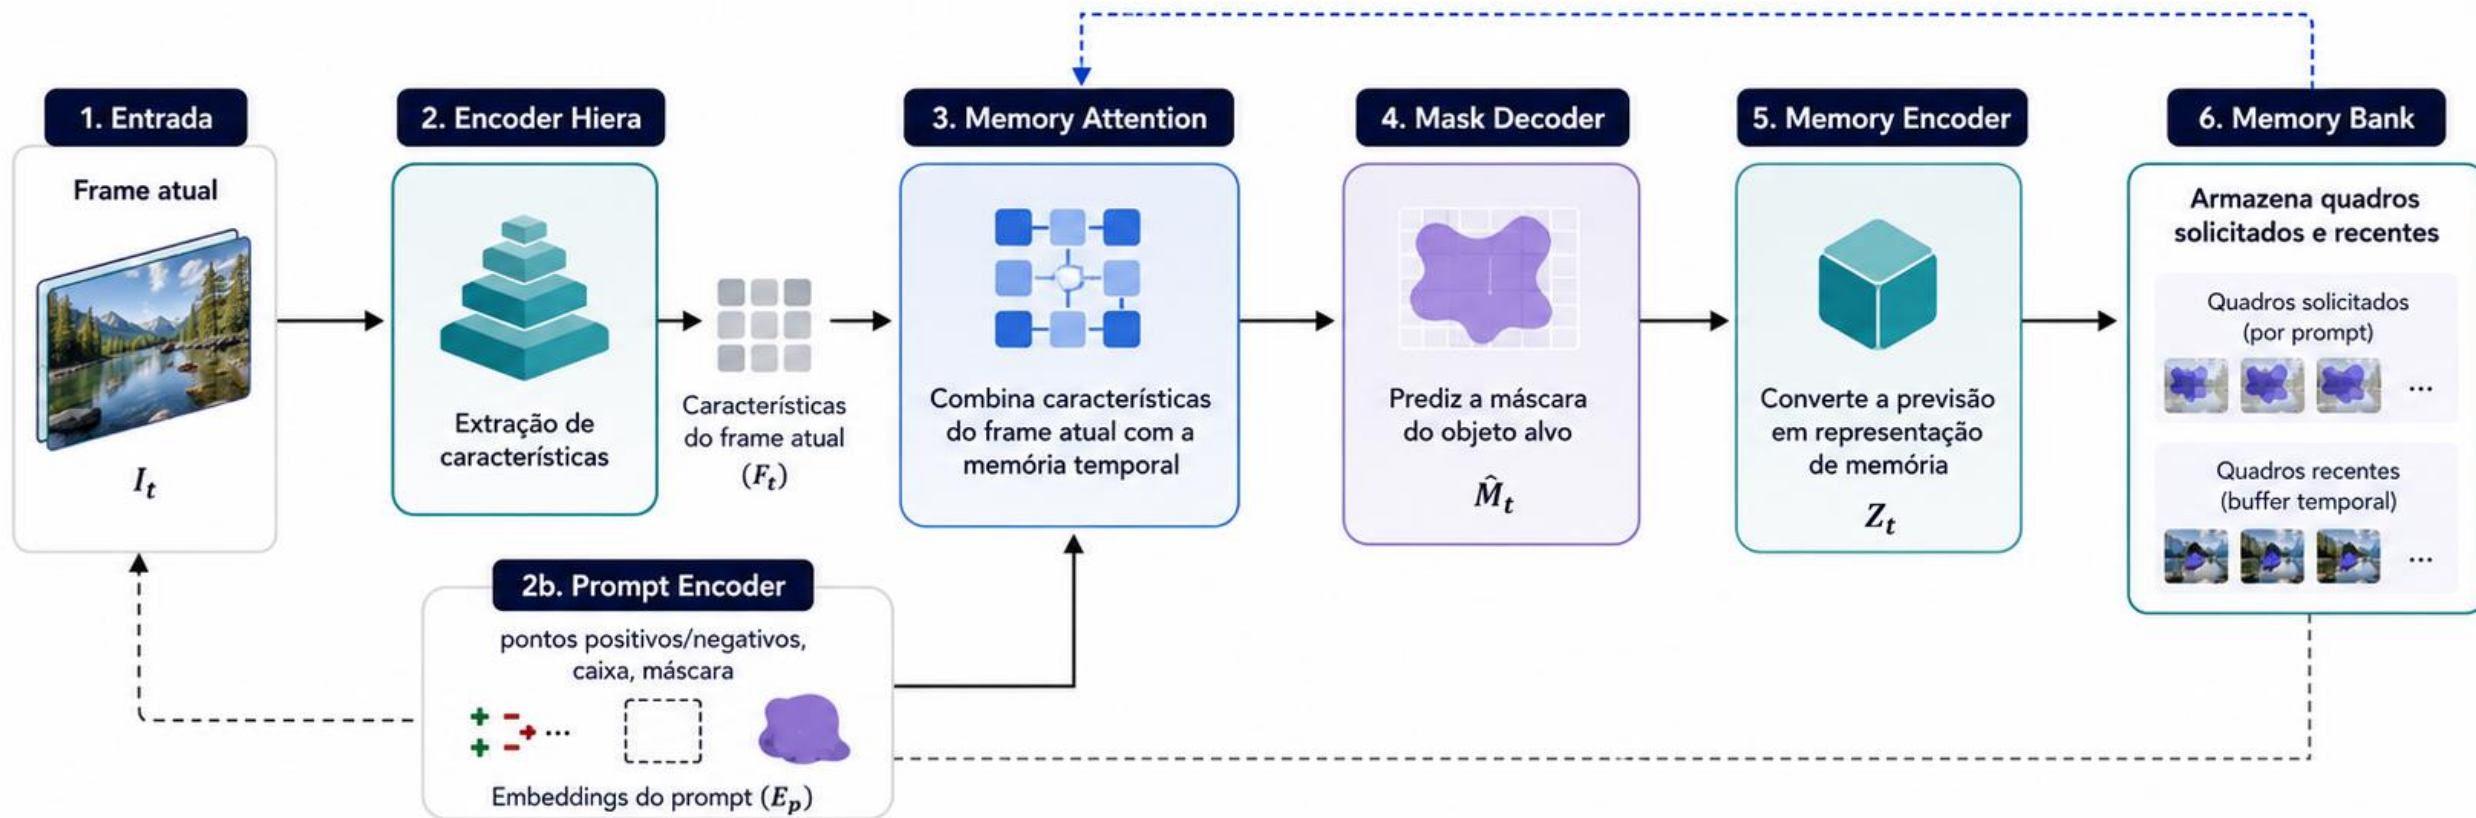
segmentação em
imagens e vídeos



memória
streaming



um prompt pode
orientar vários frames



Masklet ao longo do tempo

Um único prompt orienta a segmentação de vários frames consecutivos.



→ Fluxo de dados
- - -> Fluxo de memória (temporal)

Hiera: encoder hierárquico e multiescala



Por que trocar o encoder do SAM?

- ✓ Hiera gera representações hierárquicas do frame.
- ✓ Features de múltiplas escalas ajudam a recuperar detalhes na decodificação.
- ✓ O artigo atribui grande parte do ganho de velocidade em imagem ao encoder menor e mais eficiente.
- ✓ A família Hiera permite trocar capacidade por latência.

Stage 4 —
semântica

Stage 3

Stage 2

Stage 1 — alta resolução

.....
multiescala



Hiera-L → mais acurácia

Hiera-B+/S/Tiny → menos custo

Memory Attention: onde entra o contexto temporal

1 Memória consultada

Frames recentes e frames com prompt são recuperados da memória para contextualizar o frame atual.



2 Memory Attention



Self-attention + Cross-attention

O frame atual consulta informações espaciais e object pointers armazenados na memória. Assim, o embedding do frame atual passa a carregar contexto temporal do objeto.

3 Resultado



O decoder recebe um embedding já condicionado pelo histórico do objeto, o que ajuda a manter a identidade ao longo do vídeo.

Memory Encoder + Memory Bank



Memory Encoder

Combina a máscara prevista com o embedding não condicionado do frame. A máscara é reduzida e fundida por convoluções leves.



Memory Bank

Mantém uma fila FIFO de frames recentes e uma fila de frames que receberam prompts.



Object Pointers

Vetores compactos carregam informação semântica de alto nível sobre a identidade do objeto.



Exemplo de conteúdo da memória



P = frame promptado preservado | r = frames recentes



A memória é seletiva: não é necessário guardar todos os frames do vídeo.

Interação: segmentar → observar → corrigir → propagar



**A correção não precisa 'recomeçar do zero':
o contexto já armazenado ajuda a recuperar a identidade.**

Essa é a principal mudança de experiência em relação à SAM + tracker desacoplado.

SA-V: escala do dataset de vídeo



50,9 mil
vídeos



642,6 mil
masklets



35,5 milhões
máscaras



4,2 milhões
frames



Diversidade

Cenas internas/externas,
objetos completos,
partes e subpartes.



Dificuldade

Oclusão,
desaparecimento/reaparecimento
e alvos pequenos.



Cobertura

53× mais máscaras que o
maior dataset VOS aberto
citado no artigo.



O dataset é parte da contribuição: memória temporal exige exemplos temporais ricos para ser aprendida.

Evolução da anotação com o SAM 2



Fase 1

SAM por frame

37,8 s/frame

100% dos frames editados



Fase 2

SAM + SAM2 Mask

7,4 s/frame

23,25% dos frames editados



≈ 5,1x mais rápido



Fase 3

SAM 2

4,5 s/frame

19,04% dos frames editados



≈ 8,4x mais rápido




Menos tempo por frame e menos intervenção manual

Resultado em imagens: mais rápido sem perder qualidade



Velocidade em A100 (FPS)



≈ 6× mais rápido

SAM



58,1 mIoU



1 clique

SAM 2



58,9 mIoU



1 clique

Comparação com o mesmo conjunto SA-1B



Com o mix de dados do artigo, SAM 2 chega a 61,9 mIoU no conjunto SA-23.



A comparação de CPU do experimento local não deve ser misturada com estes números de A100.

Resultado em vídeo: qualidade e menos interações

SAM 2 (Hiera-L)

MOSE

77,9

J&F

SA-V test

78,4

J&F

DAVIS 2017

90,7

J&F

YTVOS 2019

89,3

G

Nos 9 benchmarks interativos, o artigo reporta melhor segmentação com >3× menos interações que SAM + trackers.

Leitura correta: o ganho está na combinação de acurácia + continuidade temporal + capacidade de refinamento.

Execução local: comportamento do SAM 2 Tiny

1 Frames 0–4



IoU médio $\approx 0,998$
segmentação
praticamente perfeita



Estabilidade e alta consistência
do acompanhamento

2 Frames 5–7



oclusão
queda do IoU para $\approx 0,568$
subsegmentação e
perda parcial do objeto



Oclusão causa degradação
expressiva do desempenho

3 Frames 8–11



masklet perdido
IoU = 0
falha total de
acompanhamento



A recuperação automática não
ocorre após a perda do masklet

IoU (Intersection over Union) por frame




	imagem	máscara	sobreposição
Frame 2 (regime 1)			
Frame 6 (regime 2)			
Frame 9 (regime 3)			



INTERPRETAÇÃO



**Precisão alta
isoladamente
não garante sucesso;
é preciso observar
IoU e recall**




Métricas de sobreposição e cobertura
são essenciais para avaliar
o rastreamento ao longo do tempo.

Interpretação da falha: precisão alta pode enganar

Frame 6 — subsegmentação

Precisão $\approx 0,977$

Recall $\approx 0,723$




Poucos falsos positivos, mas muitos falsos negativos → máscara correta, porém incompleta.

Frame 7 — máscara vazia

Precisão = 1

IoU = 0



Sem pixels previstos, não há falso positivo. Por convenção, a precisão pode aparecer como 1 — mas isso não significa sucesso.



Conclusão: interprete IoU + recall + precisão em conjunto.

Baseline de cor × SAM 2 Tiny



Baseline de cor



IoU

0,430



FPS

> 600



Vantagem

muito simples e rápido



SAM 2 Tiny



IoU

0,992



FPS

≈ 0,58



Vantagem

segmenta a instância
solicitada

Eficiência computacional ≠ eficiência de interação.

O que muda ao usar o checkpoint Tiny?



≈ 38,9 milhões

parâmetros



Vantagens

Menor memória e latência dentro da família SAM 2.



Trade-off

Modelos menores podem ter menos capacidade em cenas difíceis.



Uso adequado

Demonstrações, protótipos e dispositivos mais limitados.



Cuidado experimental

A falha local não pode ser atribuída ao Tiny sem testar B+, Large ou outros checkpoints.



O checkpoint define um ponto no trade-off capacidade × custo — não uma explicação automática para qualquer falha.

Análise crítica: pontos fortes, limitações e aplicações



Pontos fortes

- Arquitetura unificada para imagem e vídeo.
- Correção interativa com propagação temporal.
- Menos interações para atingir boa qualidade.
- Grande cobertura de dados no SA-V.
- Zero-shot forte em vários benchmarks.



Limitações

- Pode perder objetos após oclusões longas ou mudanças de cena.
- Objetos finos, rápidos ou visualmente semelhantes continuam difíceis.
- Vídeos longos aumentam custo de memória.
- Cada objeto é processado separadamente.
- Domínios muito diferentes podem exigir adaptação.



Aplicações

- Anotação de vídeo e construção de datasets.
- Edição e pós-produção de vídeo.
- Robótica e percepção temporal.
- Imagem médica e análise especializada.
- Sensoriamento remoto e inspeção.

Conclusão



SAM 2 transforma segmentação de vídeo em um processo interativo e temporal.

Sua principal eficiência está em reduzir a interação manual mantendo a identidade do objeto — não necessariamente em vencer métodos simples no tempo bruto de CPU.

Obrigado pela atenção!

Forms



<https://forms.gle/JqsAMRbyf8Wpq2LYA>

Código, notebooks e artigos



<https://github.com/Mestrado-Matheus-Fonseca/matheus-983-tp558>

Perguntas?

Referências

1. RAVI, N. et al. SAM 2: Segment Anything in Images and Videos. arXiv:2408.00714v2, 2024.
2. ZHANG, J.; TANG, H. SAM2 for Image and Video Segmentation: A Comprehensive Survey. arXiv:2503.12781, 2025.
3. ZHANG, C. et al. A Survey on Segment Anything Model (SAM): Vision Foundation Model Meets Prompt Engineering. arXiv:2306.06211v4, 2024.
4. KIRILLOV, A. et al. Segment Anything. IEEE/CVF International Conference on Computer Vision (ICCV), 2023.

Os valores de execução local e a comparação com o baseline foram fornecidos no material do seminário.

Obrigado!

Matheus Henrique Fonseca Afonso

TP558 - Tópicos avançados em Machine Learning