


TP558 - Tópicos avançados em Machine Learning: *Image Data Augmentation for Deep Learning*



Agenda

- | | | |
|---|---------------------------|---|
| 1 | Motivação | Por que aumentar dados? |
| 2 | Taxonomia | Básicos, mistura, políticas e generativos |
| 3 | Albumentations | Pipeline rápido para imagem, máscara e bbox |
| 4 | Cuidados | Data leakage, viés e split correto |
| 5 | Comparação crítica | Métodos tradicionais vs DDPM |
| 6 | Síntese | Aplicação na pesquisa e próximos passos |

Augmentation não cria informação

Data augmentation introduz invariâncias que acreditamos serem válidas para a tarefa

A ideia é ensinar ao modelo que certas variações da imagem não devem mudar o rótulo.



Exemplo: diferentes transformações aplicadas à mesma imagem.



Aplicamos transformações válidas

flip, crop, brilho, contraste, ruído...



Mais diversidade no treino

o modelo vê mais variações dos dados



Aprendizado de invariâncias úteis

o modelo aprende o que pode variar sem mudar a classe



Generalização mais robusta

melhor desempenho em dados novos



Data augmentation não cria informação nova gratuitamente: ele reforça hipóteses sobre quais variações são aceitáveis para a tarefa.



Atenção: a hipótese pode estar errada

- Rotação pode ser inadequada para dígitos como 6 e 9.
- Mudanças de cor podem ser problemáticas quando a cor define a classe.



Se a transformação preserva a semântica da tarefa, ela tende a ajudar; se não preserva, pode prejudicar o modelo.

Artigos estudados

Image Data Augmentation for Deep Learning: A Survey

- Taxonomia ampla de métodos
- Classificação, segmentação e detecção
- Limitações e desafios em aberto

Albumentations: fast and flexible image augmentations

- Pipelines práticos e reprodutíveis
- Suporte a máscaras e bounding boxes
- Ênfase em velocidade em CPU

Survey: “quais métodos existem?” • Albumentations: “como aplicar no pipeline?”

Famílias de data augmentation

	 Manipulação	 Apagamento	 Mistura	 Avançados
 Ideia central	Aplica transformações diretas na própria imagem, preservando o rótulo.	Remove ou oculta partes da imagem durante o treino.	Combina duas ou mais amostras para gerar novos exemplos sintéticos.	Usa políticas automáticas, espaço de características ou modelos generativos.
 Como funciona	Altera geometria ou aparência para simular variações reais do dado.	Força o modelo a não depender de uma única região discriminativa.	Mistura imagens, regiões ou rótulos para regularizar o treinamento.	Busca estratégias mais complexas ou gera novos dados sintéticos.
 Exemplos	flip, crop, rotação, escala, brilho, contraste, cor, ruído	Cutout, Random Erasing, GridMask	Mixup, CutMix, Mosaic, FMix	AutoAugment, RandAugment, Feature Augmentation, GANs, DDPM
 Vantagem principal	Simples, rápido e de baixo custo computacional.	Melhora robustez a oclusões e reduz sobreajuste.	Aumenta diversidade e pode melhorar generalização.	Pode gerar maior diversidade e estratégias mais sofisticadas.
 Cuidados	Nem toda transformação preserva a semântica da tarefa.	Excesso de apagamento pode destruir informação útil.	Pode exigir ajuste fino de hiperparâmetros e mais épocas.	Maior custo computacional e maior complexidade de implementação.
 Aplicações / observações	Muito usado como baseline e em pipelines tradicionais.	Útil quando há oclusão parcial ou fundo dominante.	Muito usado em classificação e detecção.	Interessante quando augmentation tradicional não é suficiente.

Transformações rápidas e controláveis




Manipulação da imagem


- Geometria: flip, rotação, escala, crop, translação
- Fotometria: brilho, contraste, saturação, blur, ruído
- Baixo custo: aplicação online durante o carregamento do batch
- Risco: intensidade exagerada pode gerar amostra fora da distribuição

Ponto-chave: rápido para testar e barato para escalar.

Imagem e rótulo precisam caminhar juntos



g. 2. An example of applying a combination of transformations available Albumentations to the original image, bounding boxes, and ground truth masks for instance segmentation.



Regras diferentes por tarefa

- Classificação: rótulo geralmente permanece igual
- Segmentação: máscara recebe a mesma transformação geométrica
- Detecção: bounding box deve ser recalculada após crop/rotação

Na reprodução: aplicar augmentation na imagem e na máscara de segmentação.

Cutout, Mixup e CutMix

Cutout

Oculta partes da imagem



Imagem original → Com Cutout

- O que faz**
Oculta um ou mais blocos da imagem.
- Rótulo**
Mantém o rótulo original.
- Vantagem**
Simula oclusão e reduz dependência de uma única região discriminativa.
- Atenção**
Se o apagamento for excessivo, pode remover informação importante.

Mixup

Combina imagens por interpolação



Imagem A (classe: gato) + Imagem B (classe: cachorro) → Imagem Mixup (interpolação)

- O que faz**
Combina duas imagens por interpolação linear.
- Rótulo**
O rótulo vira uma combinação ponderada entre as duas classes.
- Vantagem**
Regulariza o treinamento e suaviza as fronteiras de decisão.
- Atenção**
Pode gerar imagens menos interpretáveis visualmente.

CutMix

Recorta uma região e cola em outra



Imagem A (classe: pássaro) → Imagem B (classe: gato) → Resultado CutMix

- O que faz**
Recorta uma região de uma imagem e cola em outra.
- Rótulo**
O rótulo é ponderado pela proporção da área trocada.
- Vantagem**
Mantém pistas visuais locais e pode preservar melhor a localização.
- Atenção**
A área trocada nem sempre representa exatamente a informação semântica.

Como interpretar

O que o modelo aprende com cada técnica?



Cutout

O modelo aprende a reconhecer o objeto mesmo com partes ocultas.



Mixup

O modelo aprende transições suaves entre classes.



CutMix

O modelo aprende com partes reais de imagens diferentes.

Fórmula do Mixup

$$\tilde{x} = \lambda x_a + (1 - \lambda) x_b \quad \tilde{y} = \lambda y_a + (1 - \lambda) y_b$$

Fórmula do CutMix

$$\tilde{y} = \lambda y_a + (1 - \lambda) y_b$$

com λ aproximado pela fração de área preservada.

Busca automática, features e geração

AutoAugment / RandAugment

Busca operações, magnitudes e probabilidades. AutoAugment tem custo alto; RandAugment reduz o espaço de busca.

Feature augmentation

Modifica representações internas, podendo criar variações difíceis de expressar diretamente em pixels.

Modelos generativos

Tentam produzir amostras próximas à distribuição real; exigem treino próprio e avaliação de qualidade.

Critério prático: começar pelo barato, medir ganho, depois justificar o custo do generativo.

Augmentation tradicional vs DDPM

Métodos tradicionais

- Aplicação direta no batch
- Resultado imediato
- Baixo custo computacional
- Boa primeira hipótese experimental


Generativo

- Treino do gerador
- Amostragem mais lenta
- Avaliação de qualidade/diversidade
- Maior esforço de análise posterior



No contexto de trabalho: métodos rápidos viabilizam gerar mais dados artificiais e medir impacto antes de investir em métodos generativos

Evitar data leakage: augmentation só no treino



Evitar enviesar o modelo

Nem toda política melhora toda tarefa

- Aumentar quantidade não garante aumentar diversidade útil
- Transformações podem reforçar artefatos ou classes majoritárias
- É preciso monitorar distribuição por classe, por máscara e por cenário
- Métrica final deve ser no conjunto sem augmentation

Pergunta de auditoria: a transformação representa variações reais do problema?

Albumentations como compêndio prático de técnicas



Exemplo de pipeline

```
A.Compose([
    A.PadIfNeeded(40, 40),
    A.RandomCrop(32, 32),
    A.HorizontalFlip(p=0.5),
    A.ColorJitter(p=0.8),
], seed=42)
```

Explicação

- Compose encadeia operações
- p controla probabilidade
- seed ajuda reprodutibilidade
- máscaras usam interpolação discreta
- BboxParams define formato das caixas

Um único pipeline transforma imagem + máscara + bbox de forma consistente.

Velocidade importa no treinamento

TABLE I

TIME IN SECONDS PER IMAGE TRANSFORMATION OPERATION TASK USING DIFFERENT AUGMENTATION TOOLS (LOWER IS BETTER).

	Albumentations	imgaug	torchvision (Pillow backend)	torchvision (Pillow-SIMD backend)	Keras
RandomCrop64	0.0017	-	0.0182	0.0182	-
PadToSize512	0.2413	-	2.493	2.3682	-
HorizontalFlip	0.7765	2.2299	0.3031	0.3054	2.0508
VerticalFlip	0.178	0.3899	0.2326	0.2308	0.1799
Rotate	3.8538	4.0581	16.16	9.5011	50.8632
ShiftScaleRotate	2.0605	2.4478	18.5401	10.6062	47.0568
Brightness	2.1018	2.3607	4.6854	3.4814	9.9237
ShiftHSV	10.3925	14.2255	34.7778	27.0215	-
ShiftRGB	2.6159	2.1989	-	-	3.0598
Gamma	1.4832	-	1.1397	1.1447	-
Grayscale	1.2048	5.3895	1.6826	1.2721	-

Por que isso importa?


- Augmentation geralmente roda na CPU enquanto GPU treina
- Pipeline lento pode deixar GPU ociosa
- Técnicas rápidas permitem mais experimentos no mesmo prazo
- Antes do DDPM: medir baseline barato e reproduzível

Tempo economizado na etapa tradicional pode virar tempo para análise crítica de ganhos.

Protocolo proposto para segmentação - projeto



Reprodução dos artigos



Aumento de acurácia conforme combinação de várias formas de augmentations

Síntese do seminário

1. Invariâncias

Augmentation codifica hipóteses sobre o problema.

2. Rótulos consistentes

Imagem, máscara, bbox e distribuição de classe seguem regras diferentes.

3. Custo-benefício

Tradicionais geram baseline rápido; DDPM exige justificativa e auditoria.

Data augmentation deve ser tratado como hipótese experimental, não como etapa automática que sempre melhora o modelo.

Obrigado pela atenção!

Forms



<https://forms.gle/eRFgq59hobpF8vUC8>

Código, notebooks e artigos



<https://github.com/Mestrado-Matheus-Fonseca/matheus-983-tp558>

Referências principais

- [1] Yang et al. Image Data Augmentation for Deep Learning: A Survey. arXiv:2204.08610v2, 2023.
- [2] Buslaev et al. Albumentations: fast and flexible image augmentations. arXiv:1809.06839, 2018.
- [3] Krizhevsky. Learning Multiple Layers of Features from Tiny Images. 2009.
- [4] Lin et al. Microsoft COCO: Common Objects in Context. ECCV, 2014.
- [5] Ho et al. Denoising Diffusion Probabilistic Models. NeurIPS, 2020.

PDFs, código e notebooks no repositório da disciplina.

Dúvidas

Perguntas?