


Diffuse2Seg

Modelos de difusão como fonte de pseudo-máscaras




TP558 • quarto ciclo de seminários

Matheus Henrique Fonseca Afonso

Artigo de Hümmer et al. • arXiv:2609.06491v1

O que significa segmentar qualquer coisa?



Objeto inteiro → things

Região interna → parte

Sem nome de classe

Máscaras entre níveis podem se sobrepor

Things: objetos contáveis

Stuff: regiões como céu e solo

Partes e objetos podem coexistir

O gargalo são os rótulos

- 01** SAM: cerca de 11M imagens / 1B máscaras
- 02** Anotação densa custa tempo e trabalho
- 03** Hipótese: reutilizar estrutura aprendida na geração

Onde as abordagens anteriores param

DINO / UnSAM

Descoberta SSL de objetos; hierarquias e detector no UnSAM

DiffSeg / M2N2

Afinidades generativas; fusão ou prompts interativos

Diffuse2Seg


Grade automática + propagação + várias granularidades

DINO / UnSAM: forte viés para objetos

DiffSeg: fusão de atenção em grupos

M2N2: máscara interativa por prompt

A proposta em três etapas




1. SD2 congelado → afinidade

2. Grade + propagação →
pseudo-máscaras

3. Treinar e enriquecer o
estudante

Uma passagem, não uma geração completa




Uma passagem • embeddings de texto nulos • sem adicionar ruído forward ao latent

RGB 1120² → latent de
aproximadamente 140²

U-Net em t=150; texto nulo

Extrair autoatenção de alta
resolução

Da autoatenção ao grafo



$$A = \sum_l w_l \frac{1}{n_H} \sum_h A^{(l, h)}$$

$$w_1 = 0,85 \quad w_2 = 0,15$$

Temperatura de atenção: 0,55

Esquema conceitual; não é atenção SD2 medida

A_{ij} representa afinidade entre tokens

Média das cabeças; pesos 0,85 / 0,15

Uma matriz A guia todos os prompts

Por que propagar em vez de aplicar threshold?



Um ponto é um vetor one-hot

Afinidades fortes difundem
informação

Regularização busca mapas
coerentes

A energia equilibra coerência e ancoragem

$$E(f) = \frac{1}{p} \sum_i \left[\sum_j A_{ij} (f_j - f_i)^2 \right]^{p/2} + \frac{\lambda}{2} \|f - f^0\|_2^2$$

Coerência sobre o grafo

p controla a regularização

Gauss-Jacobi • parar quando a atualização quadrática é pequena

Ancoragem ao ponto

λ preserva o prompt


$p=2$: propagação linear

$p<2$: comportamento que preserva diferenças

λ mantém ligação com o prompt inicial


Vários pontos podem descobrir a mesma região

16 prompts automáticos




Normalizar cada mapa para soma 1

Afinidade proxy: 576 × 576




Comparar com KL simétrica

KL simétrica: 16 × 16



Clustering aglomerativo por ligação média

Cortes diferentes recuperam escalas diferentes




h pequeno → mais grupos

h grande → fusão em grupos grossos


Média → upsampling → argmax → componentes

Deduplicar sem apagar a hierarquia

Candidatos quase idênticos → rejeitar



Parte dentro do objeto → pode preservar




Filtrar componentes pequenos

Ordenar candidatos por área

Rejeitar $\text{IoU} > 0,9$; até 1.000 máscaras

O estudante é outro modelo




Arquitetura funcional do estudante • a extração SD2 fornece rótulos para treinamento

Mask2Former + ResNet-50

Queries → máscaras e objectness

Loss = 5 Dice + 5 máscara + 2 classe

Rodada 2: olhar novamente para as partes




Inferência global encontra pais

Crops ampliados podem revelar filhos

Validar contenção e enriquecer rótulos

O que foi treinado e onde foi avaliado



Parâmetros fixos entre domínios • zero-shot avalia transferência sem ajuste ao alvo

SA-1B: 100k / 200k / 400k
imagens

Holdout de 1.000 fixa os
parâmetros

Zero-shot: objetos, entidades e
partes

AR1000 mede cobertura de propostas

$\text{IoU} = \text{interseção} / \text{união}$

0,50 0,55 ... 0,90 0,95

Uma proposta cobre o objeto se a IoU supera o limiar

Calcular recall em cada limiar
→ média com até 1.000 propostas


AR alto não garante precisão, poucos falsos positivos ou a classe desejada

Até 1.000 máscaras por imagem

Recall médio em IoU 0,50...0,95

ARS / ARM / ARL mostram efeito da escala

Rótulos melhores, sobretudo em objetos grandes




AR: 20,7 vs. 16,4 do UnSAM

+4,3 pontos percentuais no agregado

Pequenos: 2,6 vs. 5,7; limitação real

Os ganhos transferem para cinco domínios




+4,3 a +7,1 p.p. frente ao UnSAM

Inclui stuff e partes

CutLER segue maior em ADE20K e UVO

No estudante, a fonte dos rótulos importa




Sem detector: +7,7 p.p. em stuff+things

Com CutLER / 400k: 43,8 vs. 41,7

Things / 400k: 41,1 vs. 41,3

O que as imagens do artigo mostram




Comparação qualitativa
selecionada pelos autores


Cobertura de fundo e limites de
entidades

Exemplos não substituem
avaliação sistemática


Ablações: preservar propostas melhora recall



3 → 6 níveis: +1,8 p.p.



NMS 0,5 → 0,9: +3,1 p.p.




Crops em SA-1B: +3,7 p.p.

Poucos rótulos humanos: qual é a comparação?

- 01** Referência supervisionada 100k: 51,1 mAR
- 02** 100 imagens de ajuste: 93,5% da referência
- 03** 10k: ganho reportado de 1,4 p.p.


Nossa reprodução: o que entrou no teste

Imagem sintética




Algoritmos de propagação e fusão

Mapa suave • prompt 9



Grafo RGB/posição, 24^2 pixels, 16 prompts


Partição fina • $p=1,6$



Sem SD2, CascadePSP ou treinamento


Protocolo pequeno, mas verificável

16 prompts automáticos




$p=2$ / 1,6 / 1,2; sementes 7 / 23 / 42

Afinidade proxy: 576 × 576



Mesmos grafo, λ , prompts e cortes por semente



KL simétrica: 16 × 16



Caso linear validado por solução fechada

O resultado local foi diferente do paper

3 sementes • dispersão, sem teste de significância




p=2: 56,1% ± 9,6 de recall toy

p=1,6: 25,0%; p=1,2: 45,0%

Não houve reprodução do ganho de $p < 2$

Por que os resultados não são comparáveis?


Entrada • semente 7



Autoatenção SD2 foi substituída por similaridade RGB

Partição fina observada • $p=1,6$ perde entidades neste proxy

$p = 2.0$ • mesmo grafo/ λ /cortes KL



Mesma cena toy; nenhum benchmark do paper

$p = 1.6$ • mesmo grafo/ λ /cortes KL



Pior fusão em $p=1,6$: entidades desaparecem

Fotografia real: apenas demonstração conceitual

Demonstração conceitual • grafo RGB 24^2 • sem avaliação COCO

Proxy $p=2$ • partição fina

Proxy $p=1,6$ • partição fina

COCO 39769 • fotografia original



Imagem COCO 39769 já usada
no ciclo 3


Partições vêm do mesmo proxy
RGB

Não há benchmark COCO ou
identificação de classe

Limitações e custo: onde o método pode falhar

- 01** Latent: objetos pequenos podem desaparecer
- 02** Texturas podem produzir sobresegmentação
- 03** Afinidade densa 140^2 : 1,43 GiB só em FP32

O que isso oferece para pistas SAR?



Proposta futura • SD2→SAR é hipótese separada • nenhuma transferência foi validada

Reutilizar crops e enriquecimento de pseudo-rótulos

Pistas estreitas desafiam a resolução latente

SD2 RGB → SAR exige validar mudança de domínio

Experimento futuro com controle

- 01** 1. Congelar split, checkpoint e baseline SAM
- 02** 2. Avaliar crops; depois qualidade dos pseudo-rótulos
- 03** 3. Teste final: IoU/Dice, falsos positivos e custo


Conclusões

- 01** Representações generativas podem supervisionar segmentação
- 02** Propagação + hierarquia conectam pontos a entidades
- 03** Nossa reprodução explica operações, não valida o benchmark


Referências e materiais

- 01** Hümmer et al. • arXiv:2609.06491v1
- 02** Código, protocolos e resultados em seminar_4
- 03** README: execução, vídeos e notas técnicas

Backup: timestep e compromisso p / precisão



(a) Influence of propagation exponent p .



(b) Behavior of the timestep t for extraction.

$p=1,2$ favorece recall; $p=1,6$ favorece mAP


Curvas de timestep são normalizadas por métrica

Não extraímos valores intermediários dessas curvas

Backup: configuração para treino integral

- 01** AdamW; LR $5e-5$; weight decay 0,05
- 02** 1024^2 ; batch16; 2.000 queries; 4 × A100
- 03** Round 1 ~8 épocas; Round 2 em 100k imagens

Backup: ablação local de fusão / NMS



3 / 6 níveis têm mesmo recall neste toy

NMS0,5: 16,7%; NMS0,9: 25,0%

Mais candidatos não garantem melhores máscaras

Backup: linearidade e detalhes numéricos

- 01** $p=2$: $[2L + \lambda I]f = \lambda f^0$ no grafo simétrico
- 02** Erro máximo do check: cerca de $1,9e-9$
- 03** Gradiente zero: epsilon explícito no proxy