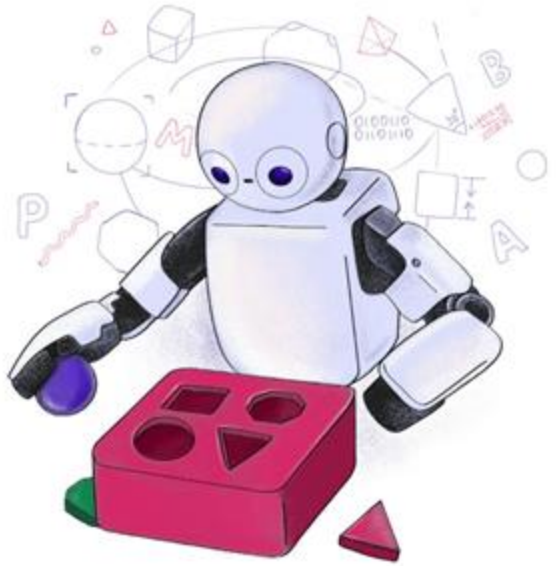
TP558 - Tópicos avançados em Machine Learning:

Diffuse2Seg: Diffusion Models Can Segment Anything Without Supervision



Inatel

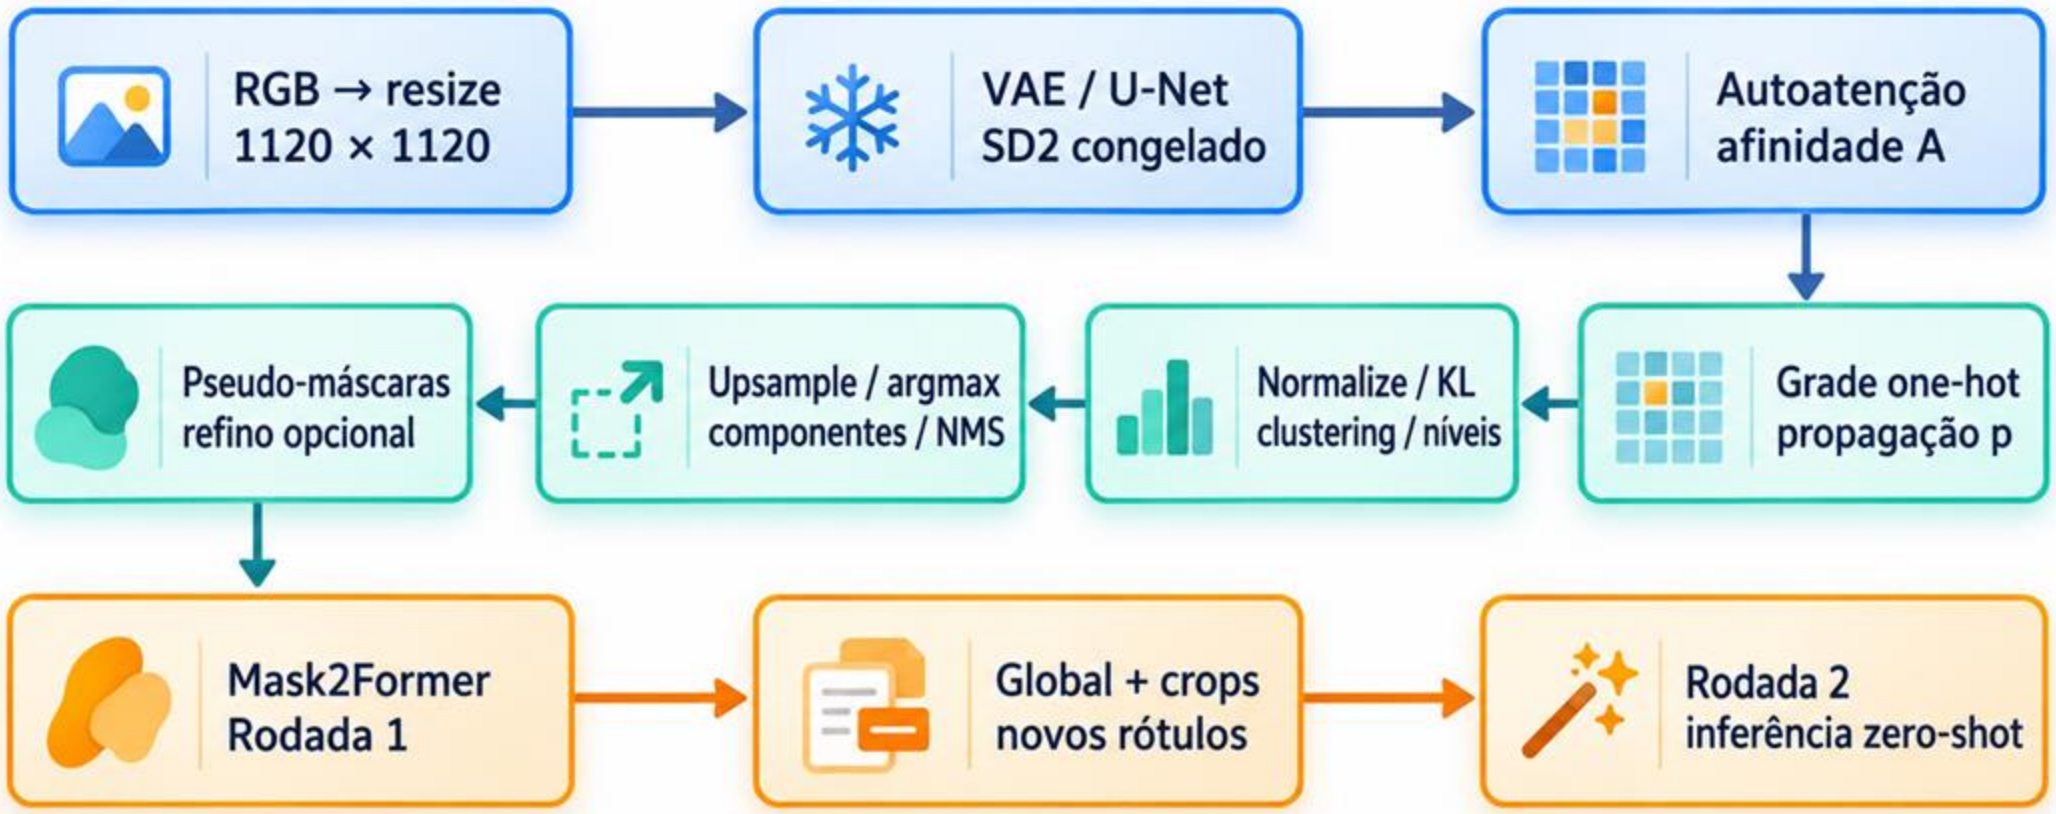
Matheus Henrique Fonseca Afonso
matheus.fonseca@mtel.inatel.br

Inatel

Agenda

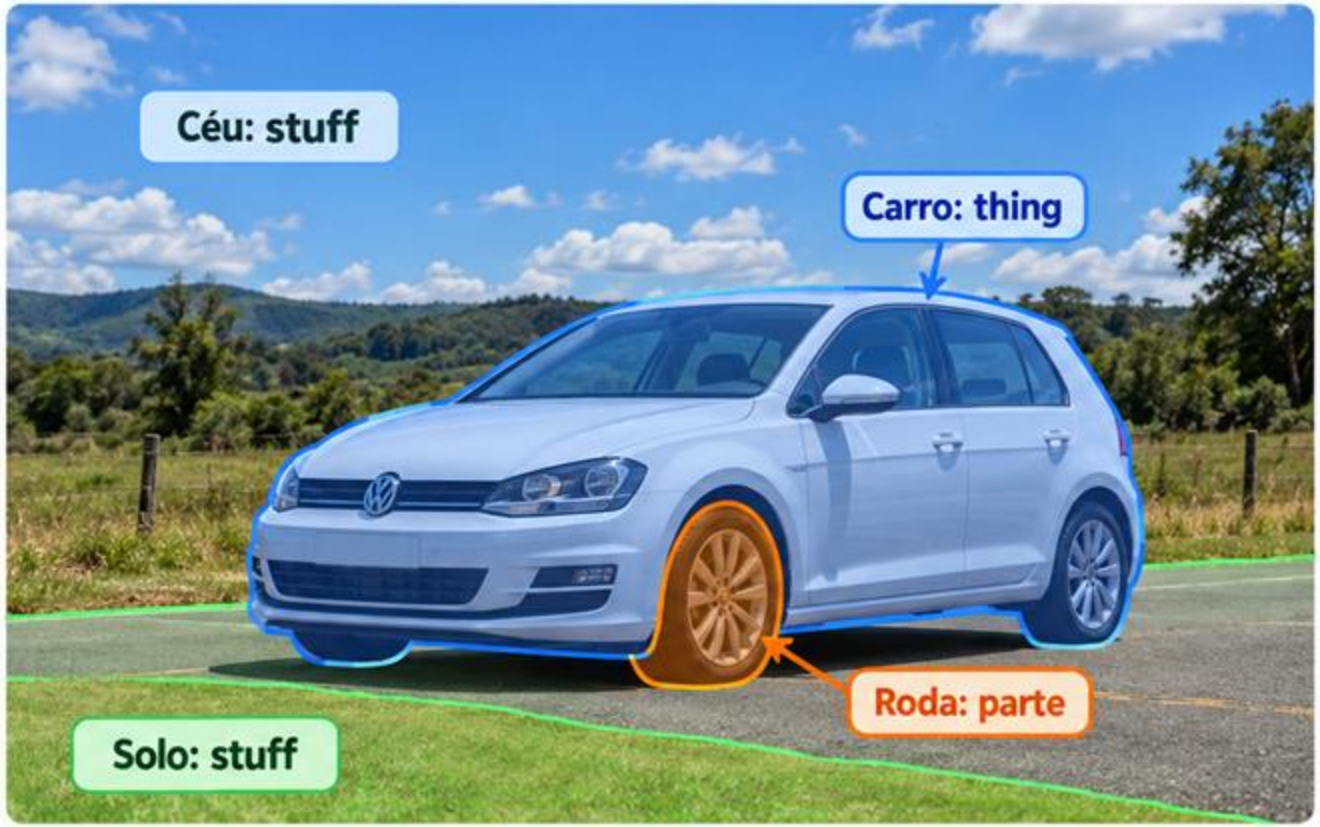
1	**Contexto e Motivação**	Segmentação de qualquer coisa e o gargalo dos rótulos
2	**Diffuse2Seg**	Ideia central, arquitetura e pipeline proposto
3	**Geração de pseudo-máscaras**	Autoatenção, propagação, clustering e hierarquia
4	**Treinamento e resultados**	Modelo estudante, avaliação, métricas e ablações
5	**Reprodução e análise crítica**	Experimento local, diferenças em relação ao artigo e limitações
6	**Aplicação e conclusões**	Relação com a pesquisa em SAR, próximos experimentos e síntese

Diffuse2Seg



Modelos de difusão como fonte de pseudo-máscaras

O que significa segmentar qualquer coisa?



Objeto inteiro → things

Segmenta o objeto como um todo, por exemplo, o carro.

Região interna → parte

Segmenta uma região interna do objeto, por exemplo, a roda (ou uma janela, farol etc).

Sem nome de classe

Máscaras entre níveis podem se sobrepor e não precisam ter rótulos de classe.

Things: objetos contáveis

Ex.: carro, pessoa, árvore, bicicleta.

Stuff: regiões como céu e solo

Ex.: céu, estrada, grama, água.

Partes e objetos podem coexistir

A mesma imagem pode conter things, partes e stuff.

O gargalo são os rótulos

01 SAM: cerca de 11M imagens / 1B máscaras

02 Anotação densa custa tempo e trabalho

03 Hipótese: reutilizar estrutura aprendida na geração

Onde as abordagens anteriores param

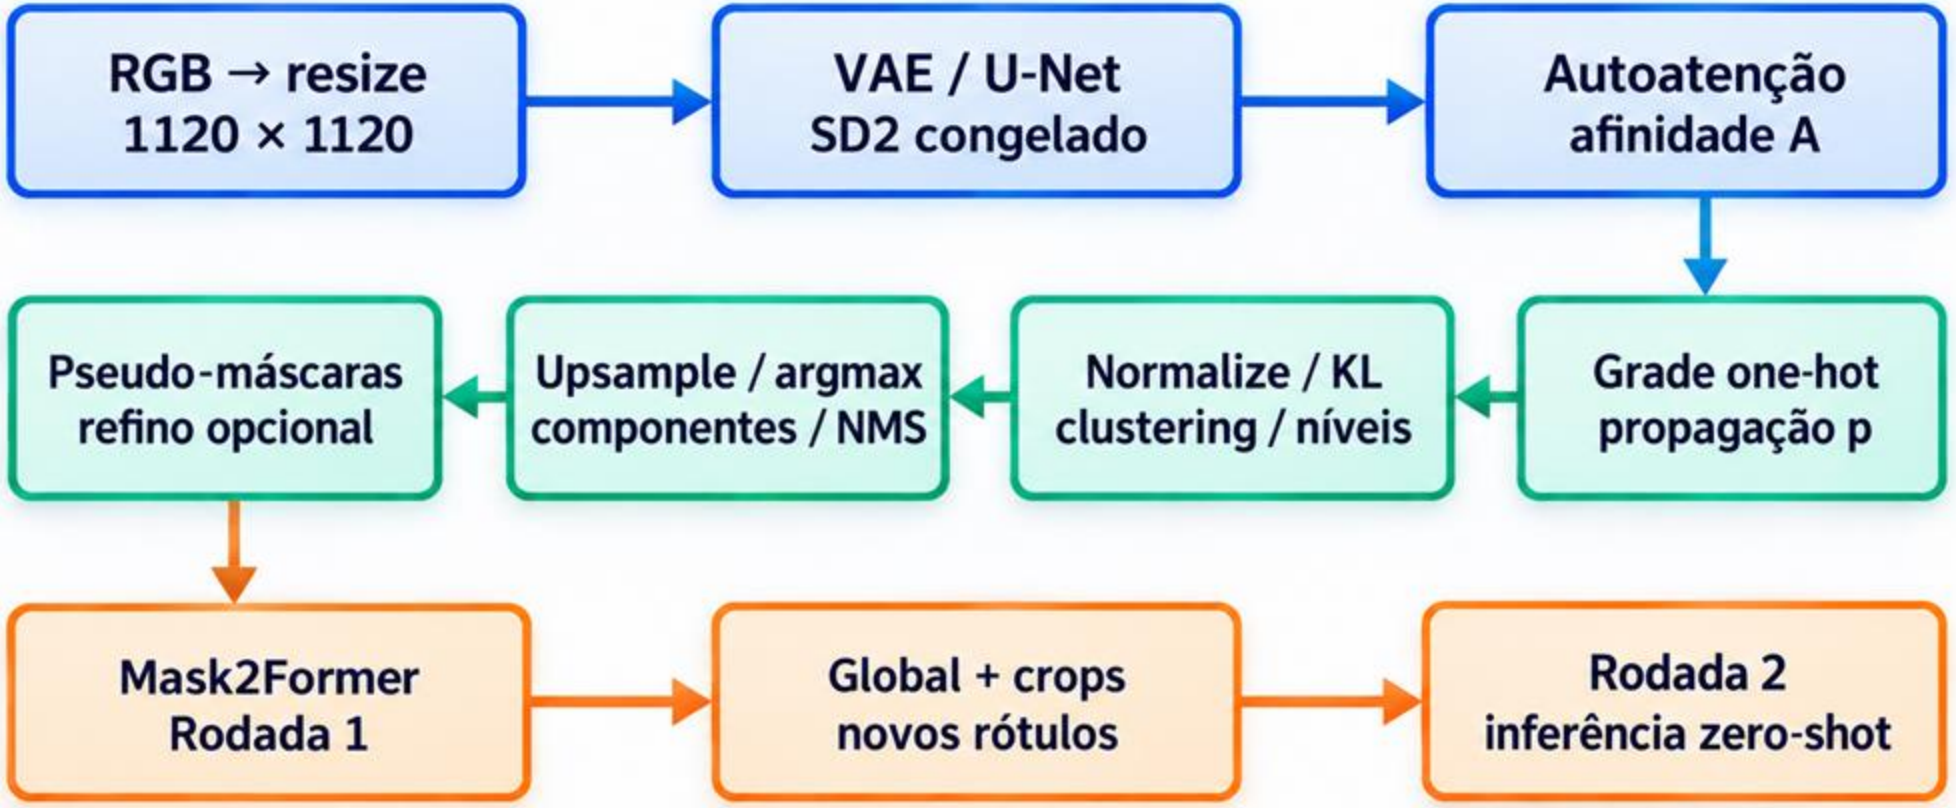
DINO / UnSAM	Descoberta SSL de objetos; hierarquias e detector no UnSAM
DiffSeg / M2N2	Afinidades generativas; fusão ou prompts interativos
Diffuse2Seg	Grade automática + propagação + várias granularidades

DINO / UnSAM: forte viés para objetos

DiffSeg: fusão de atenção em grupos

M2N2: máscara interativa por prompt

A proposta em três etapas



1. SD2 congelado → afinidade

2. Grade + propagação → pseudo-máscaras

3. Treinar e enriquecer o estudante

Uma passagem, não uma geração completa



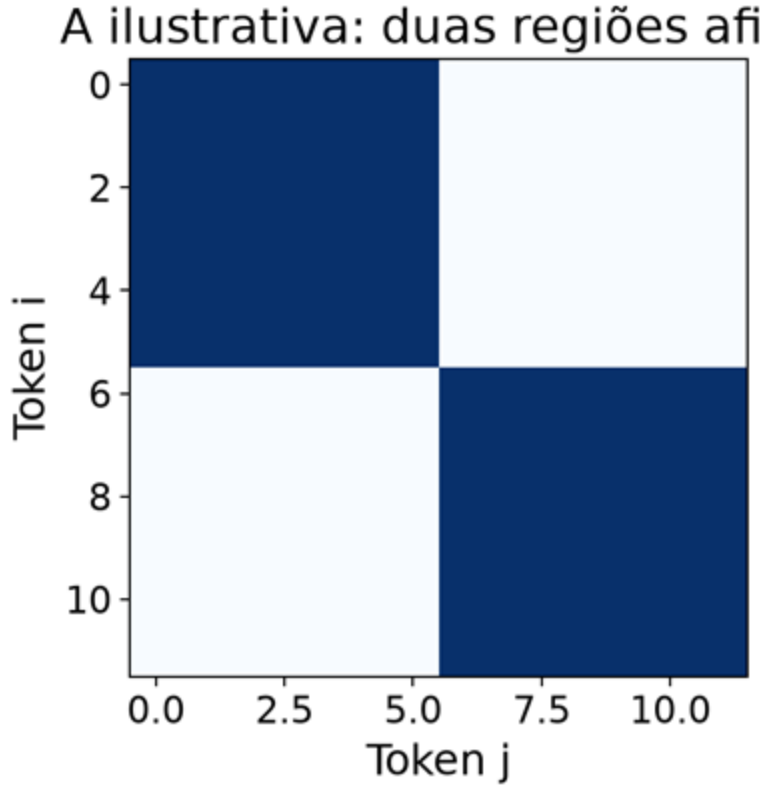
Uma passagem • embeddings de texto nulos • sem adicionar ruído forward ao latent

RGB 1120² → latent de aproximadamente 140²

U-Net em t=150; texto nulo

Extrair autoatenção de alta resolução

Da autoatenção ao grafo



$$A = \sum_{l} w_l \frac{1}{n_H} \sum_{h} A^{(l,h)}$$

$w_1 = 0{,}85 \quad w_2 = 0{,}15$

Temperatura de atenção: 0,55

Esquema conceitual; não é atenção SD2 medida

Aij representa afinidade entre tokens

Média das cabeças; pesos 0,85/ 0,15

Uma matriz A guia todos os prompts

Por que propagar em vez de aplicar threshold?



A energia equilibra coerência e ancoragem

$$E(f) = \frac{1}{p} \sum_i \left[\sum_j A_{ij} (f_j - f_i)^2 \right]^{p/2} + \frac{\lambda}{2} \| f - f^0 \|_2^2$$

Coerência sobre o grafo

p controla a regularização

Ancoragem ao ponto

λ preserva o prompt

Gauss-Jacobi • parar quando a atualização quadrática é pequena

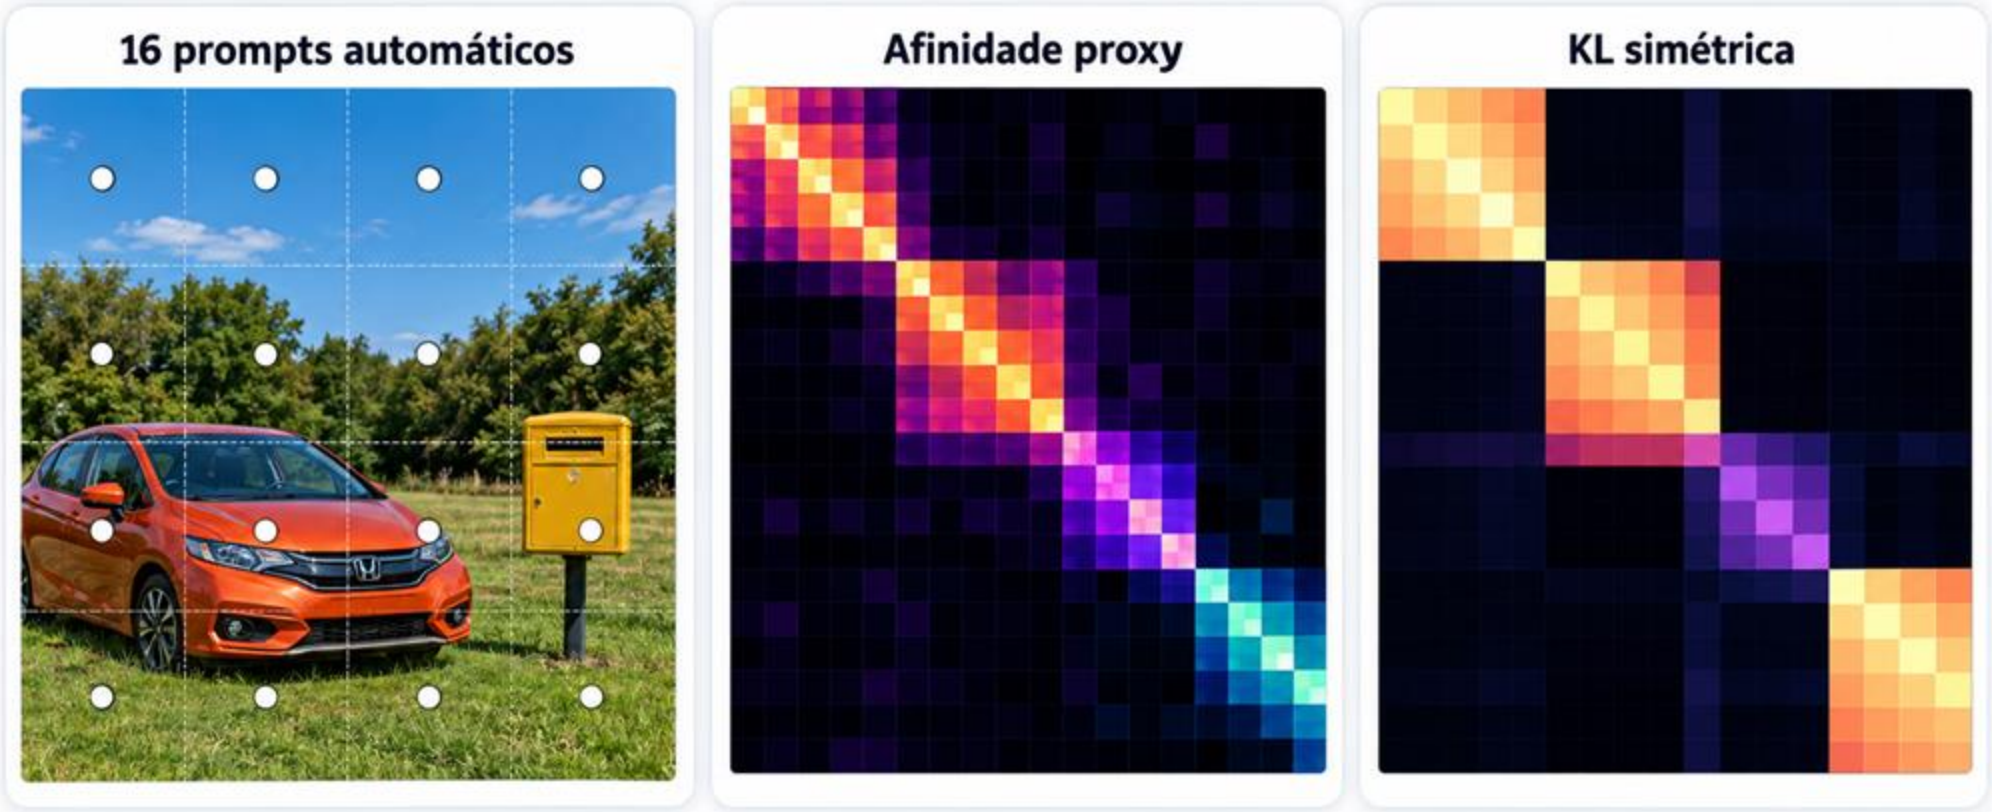
p=2: propagação linear

p<2: comportamento que preserva diferenças

λ mantém ligação com o prompt inicial

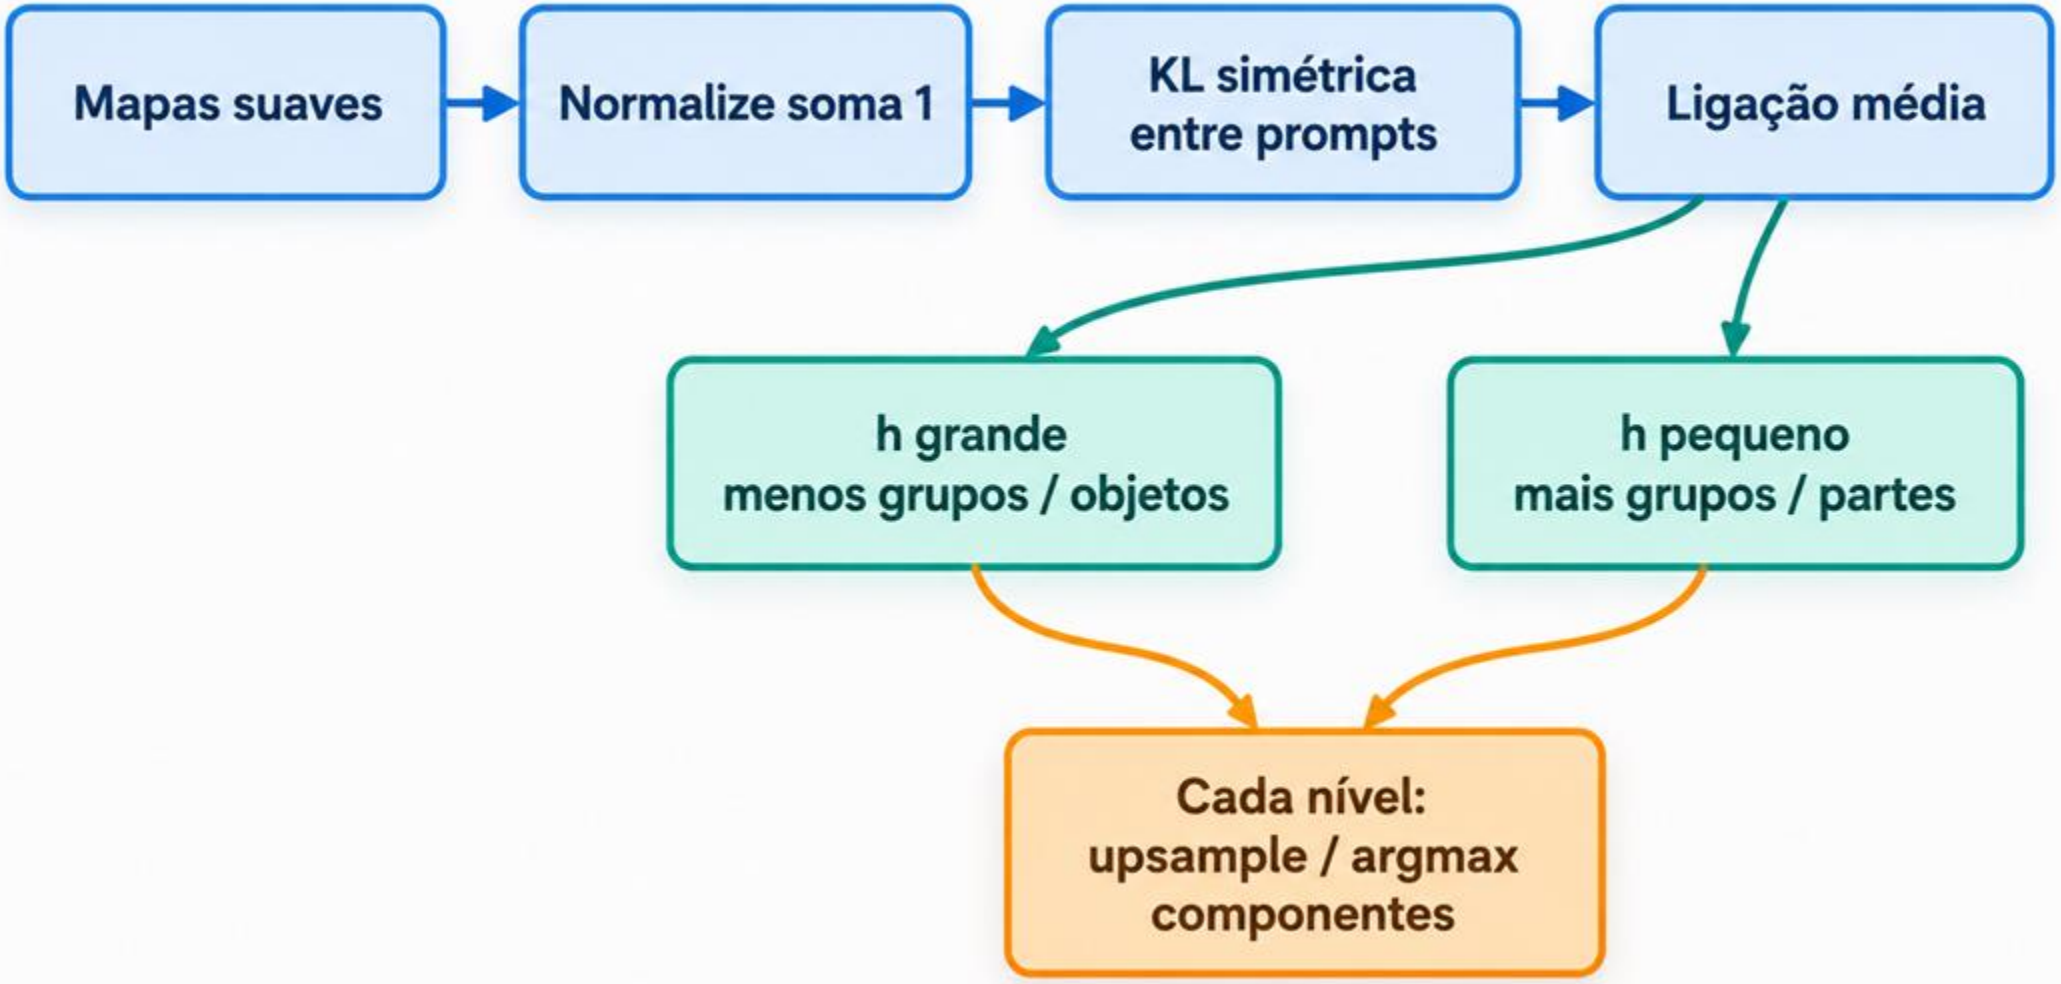
Vários pontos podem descobrir a mesma região

Prompts automáticos, afinidade proxy e agrupamento via KL em uma cena real



Os prompts sobre regiões semanticamente semelhantes geram maior afinidade;
o agrupamento por KL organiza os prompts em grupos coerentes.

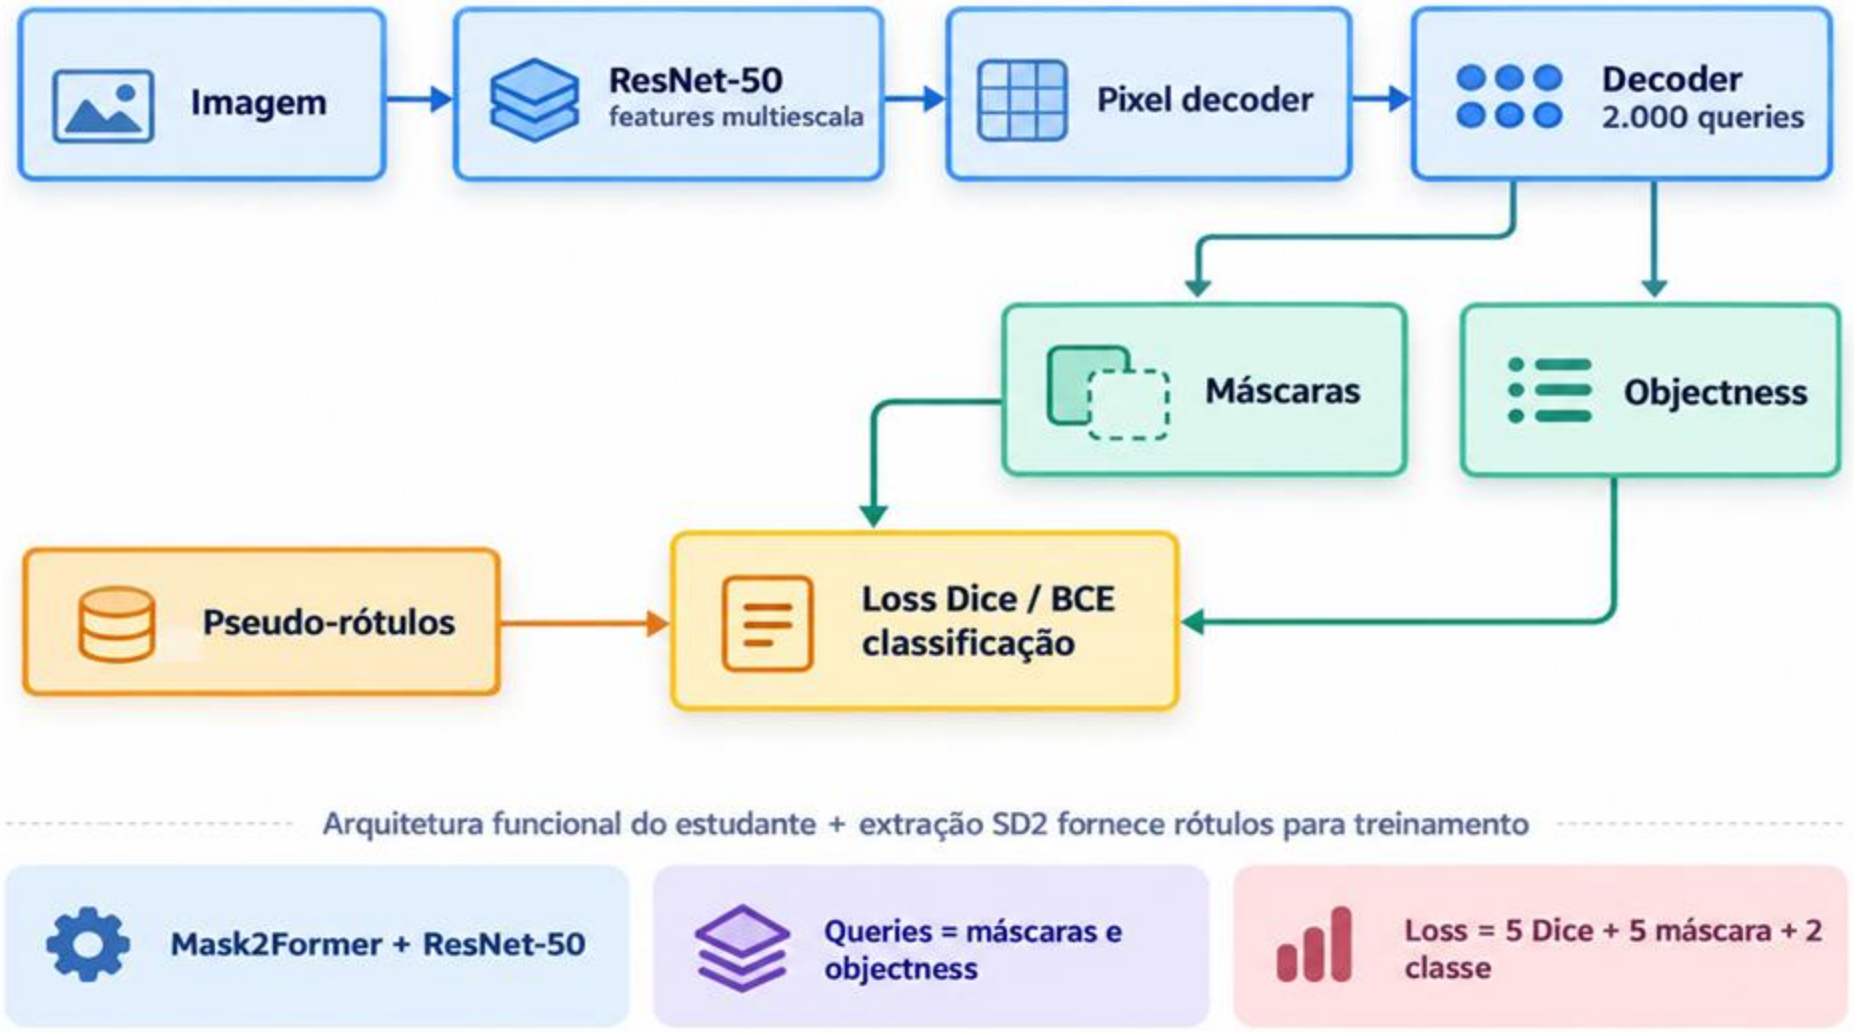
Cortes diferentes recuperam escalas diferentes



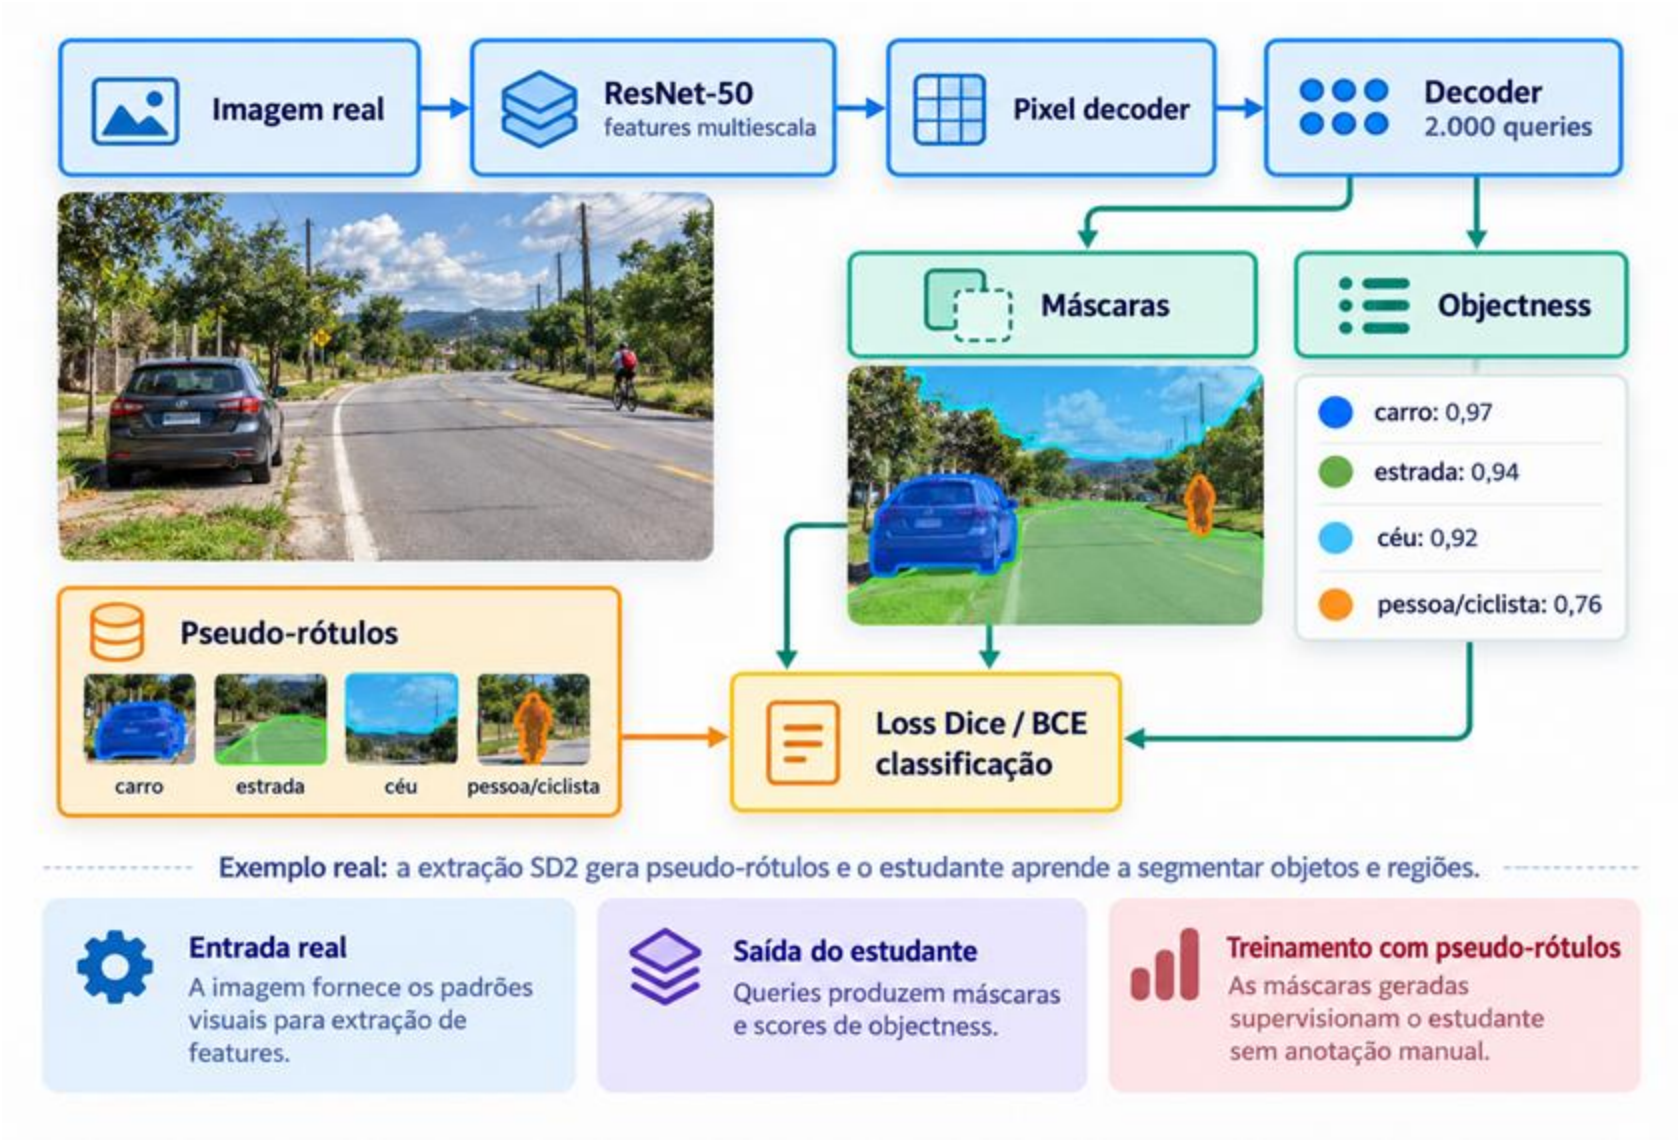
Deduplicar sem apagar a hierarquia



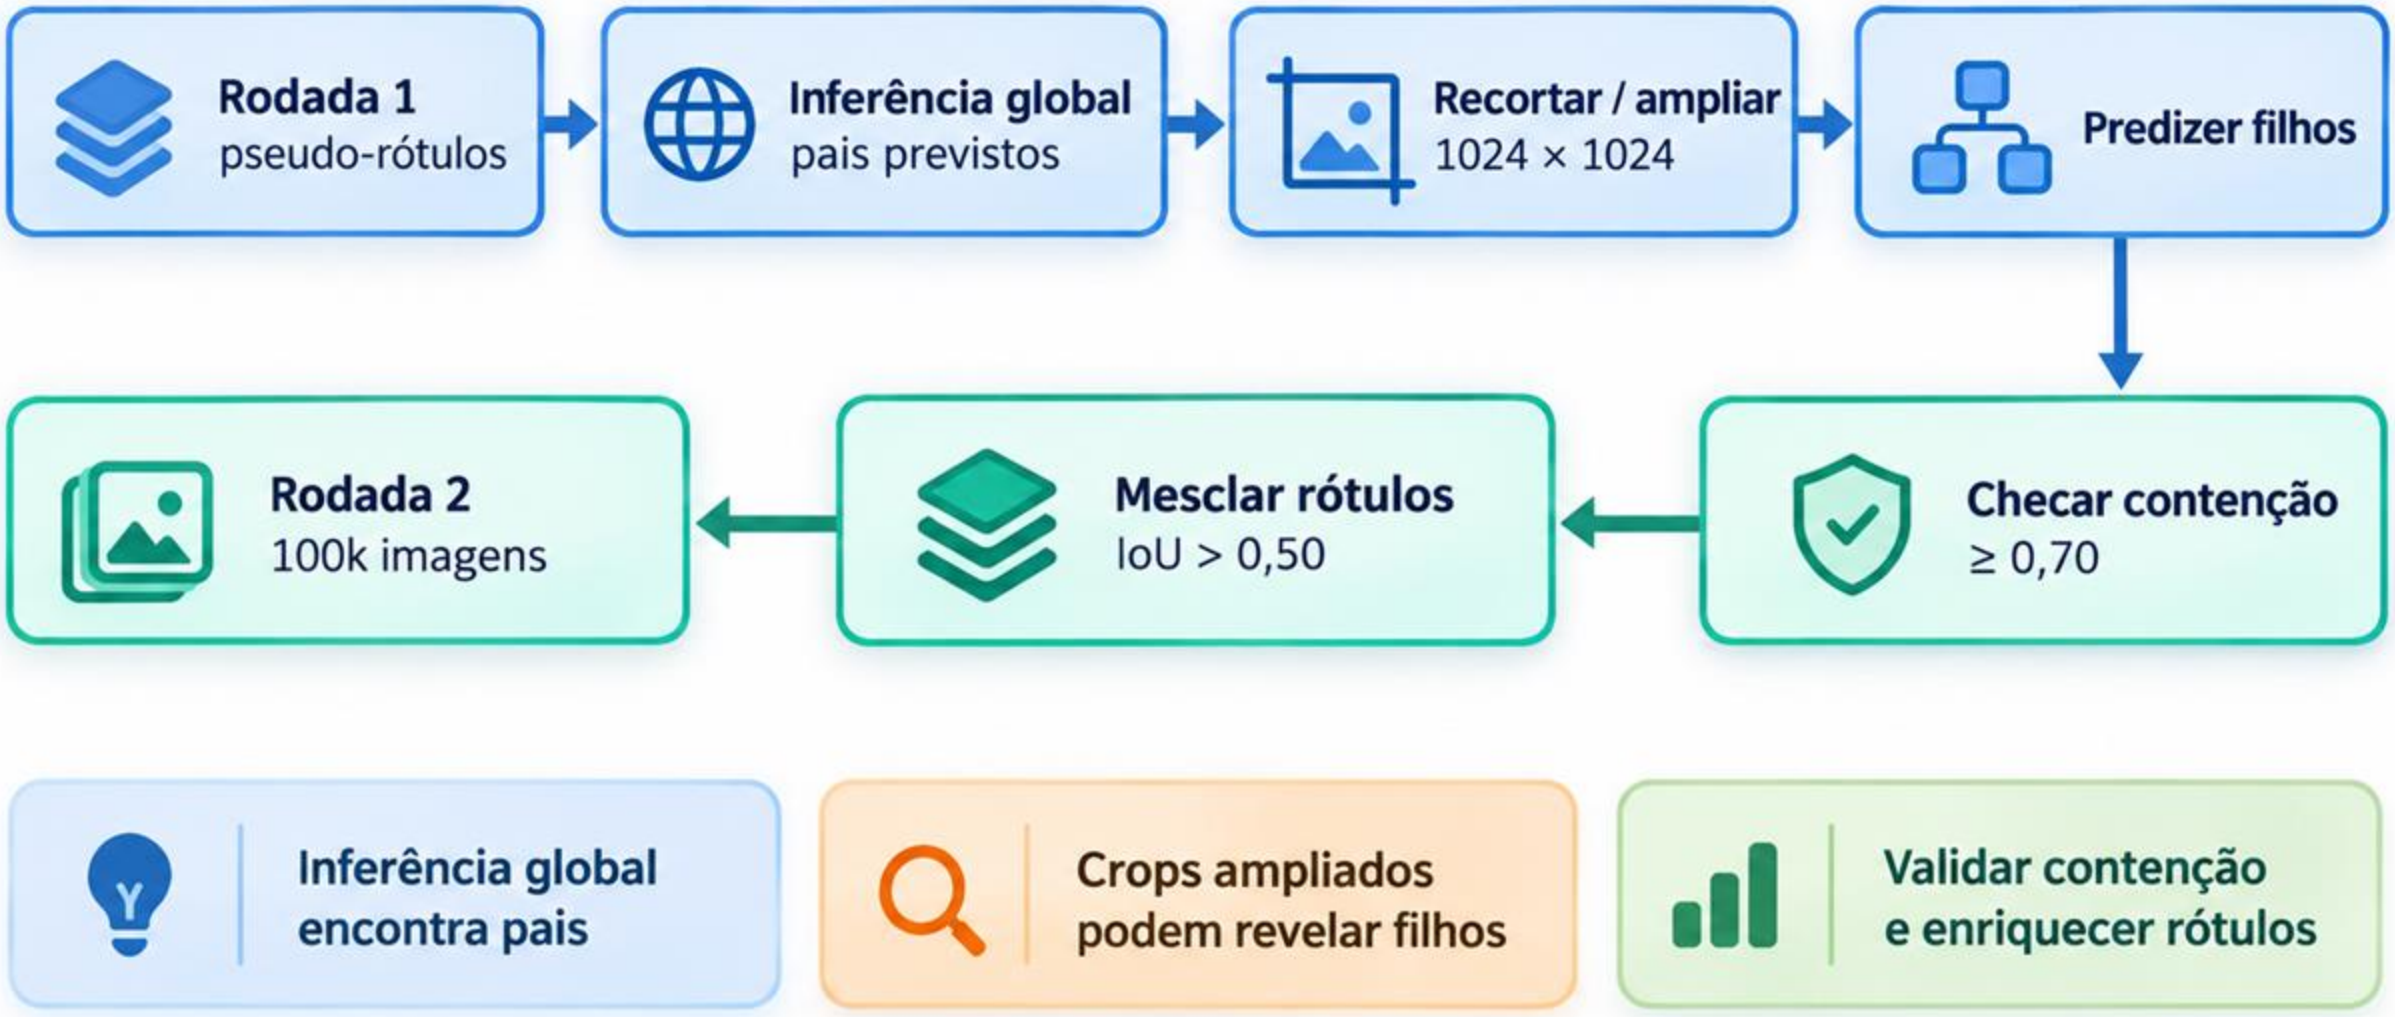
O estudante é outro modelo



O estudante é outro modelo



Rodada 2: olhar novamente para as partes



Rodada 2: olhar novamente para as partes

A partir de rótulos iniciais de objetos (pais), recortamos e ampliamos regiões para revelar partes (filhos), validamos a contenção e mesclamos os rótulos para obter anotações mais ricas e hierárquicas.



 Rótulos semânticos utilizados apenas para interpretação visual -> o método original é class-agnostic.

O que foi treinado e onde foi avaliado



Parâmetros fixos entre domínios • zero-shot avalia transferência sem ajuste ao alvo

SA-1B: 100k / 200k / 400k imagens

Holdout de 1.000 fixa os parâmetros

Zero-shot: objetos, entidades e partes

O que foi treinado e onde foi avaliado

Os pseudo-rótulos gerados em SA-1B treinam o estudante; os parâmetros são fixados em holdout e a avaliação zero-shot mede a transferência para novos domínios.

1. Pseudo-rótulos / treino SA-1B



100k / 200k / 400k

Pseudo-rótulos em SA-1B para treinar o modelo estudante.

2. Validar parâmetros — Holdout SA-1B



mIoU	0,452
AP (mask)	0,481
PQ	0,379

1.000 imagens

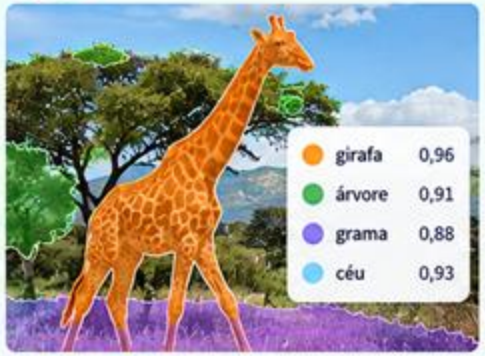
Holdout de SA-1B fixa os hiperparâmetros do estudante.

3. Avaliar gerador



Avalia o gerador de pseudo-rótulos em diferentes domínios e tipos de anotações.

4. Avaliar estudante



Zero-shot em novos domínios



COCO / LVIS / ADE Entity / SA-1B / PACO

Avalia o modelo estudante sem fine-tuning nos domínios de teste.

Parâmetros fixos entre domínios • zero-shot avalia transferência sem ajuste ao alvo

SA-1B: 100k / 200k / 400k imagens
Conjuntos crescentes de pseudo-rótulos para treinar o estudante.

Holdout de 1.000 fixa os parâmetros
Ajuste feito apenas no holdout, sem adaptar aos domínios-alvo.

Zero-shot: objetos, entidades e partes
A avaliação mede generalização sem fine-tuning no domínio de teste.

AR1000 mede cobertura de propostas

IoU = interseção / união

0,50 0,55 ··· 0,90 0,95



Uma proposta cobre o objeto se a **IoU supera o limiar**



Calcular **recall** em cada limiar → **média com até 1.000 propostas**

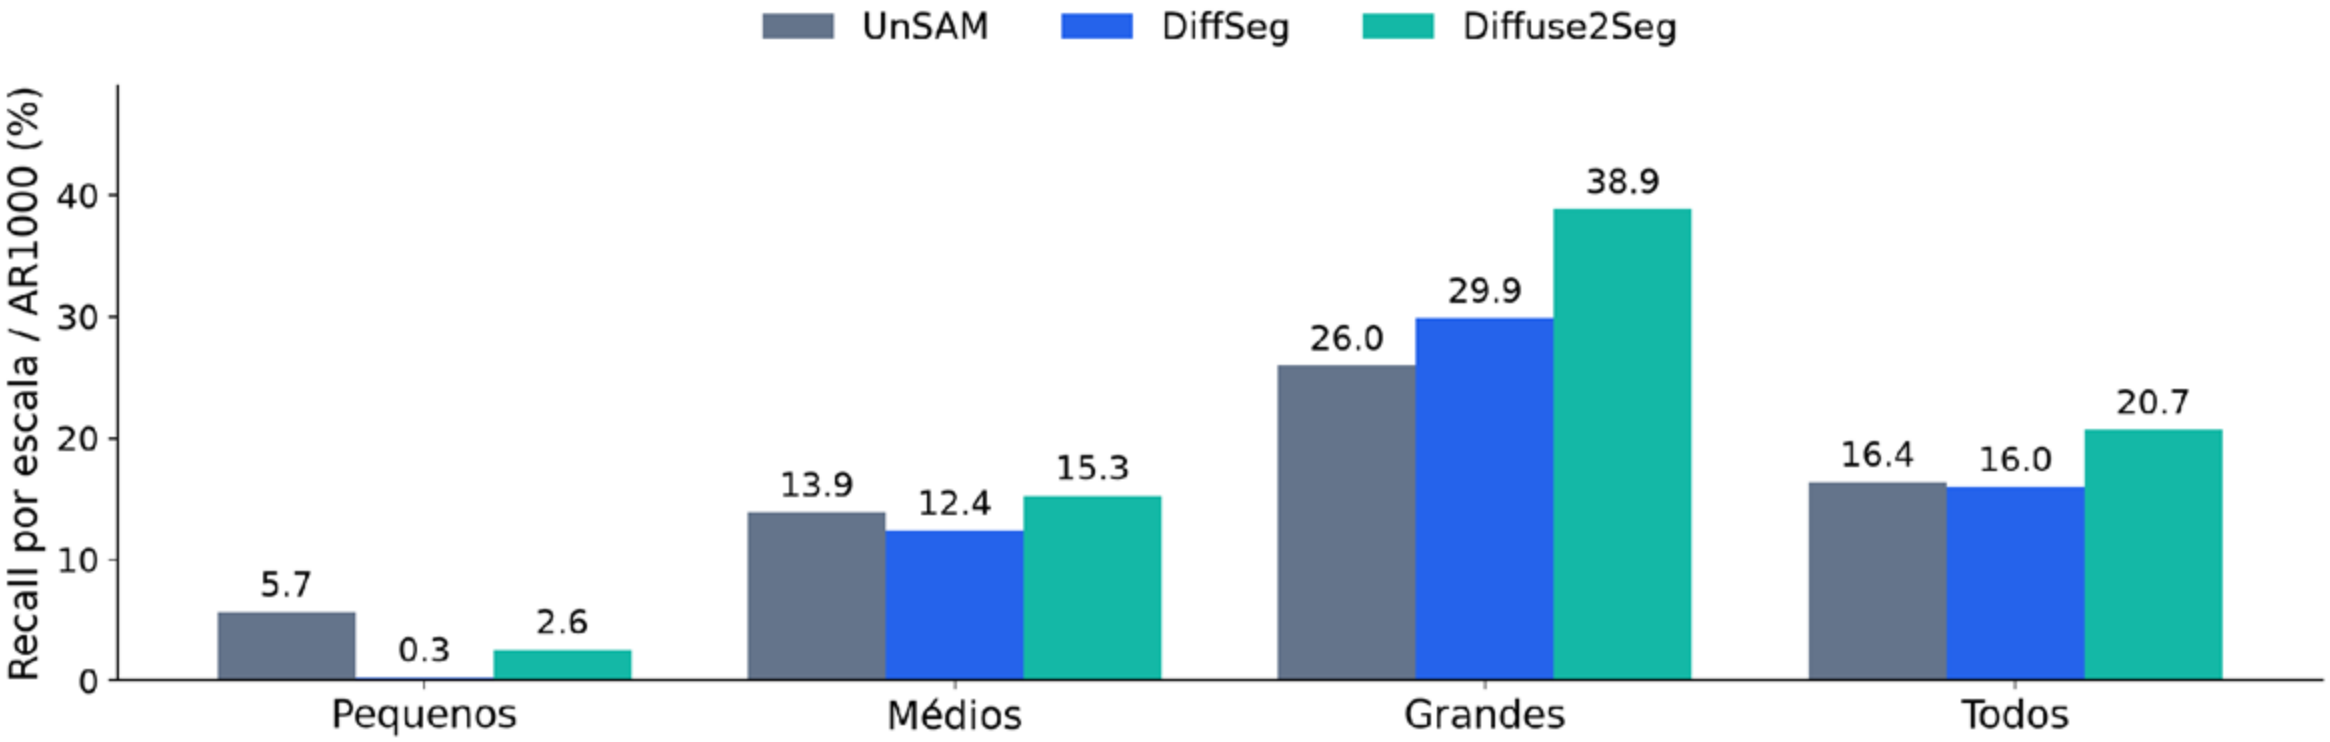
AR alto não garante precisão, poucos falsos positivos ou a classe desejada.

Até **1.000 máscaras** por imagem

Recall médio em **IoU 0,50...0,95**

ARS / ARM / ARL mostram efeito da escala

Rótulos melhores, sobretudo em objetos grandes



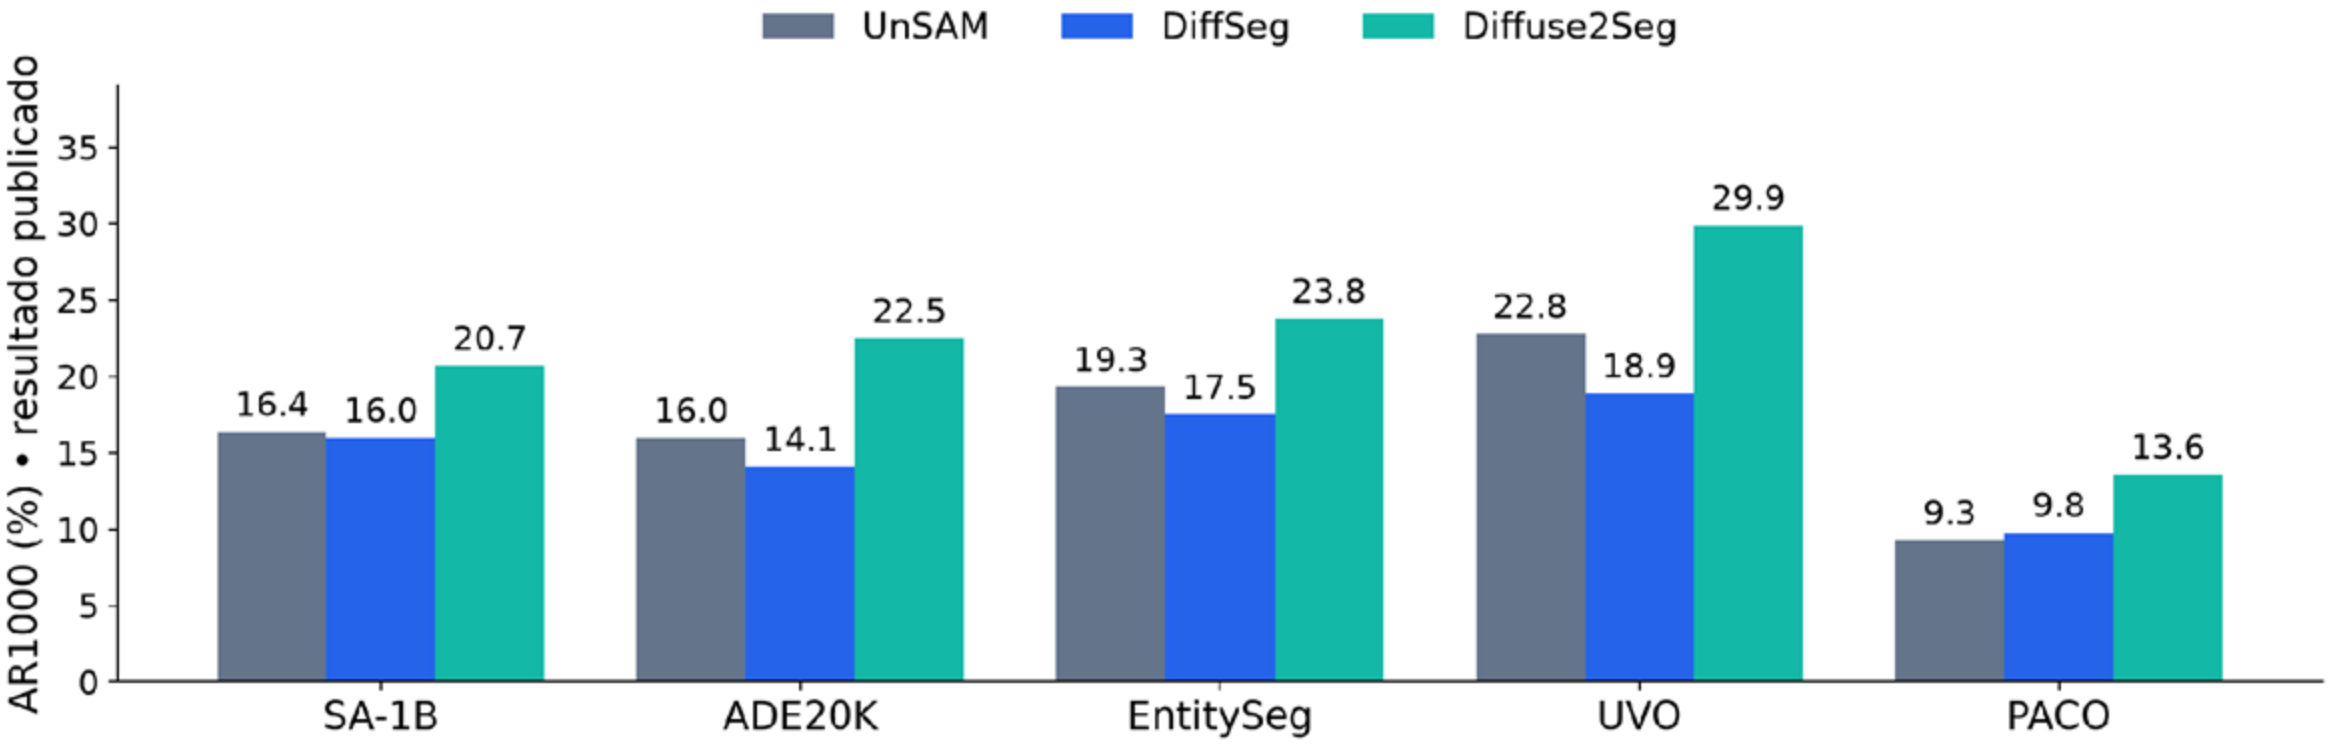
AR: 20,7 vs. 16,4 do UnSAM

+4,3 pontos percentuais no agregado

Pequenos: 2,6 vs. 5,7; limitação real

Resultado ORIGINAL • Tabela 1, p. 10

Os ganhos transferem para cinco domínios



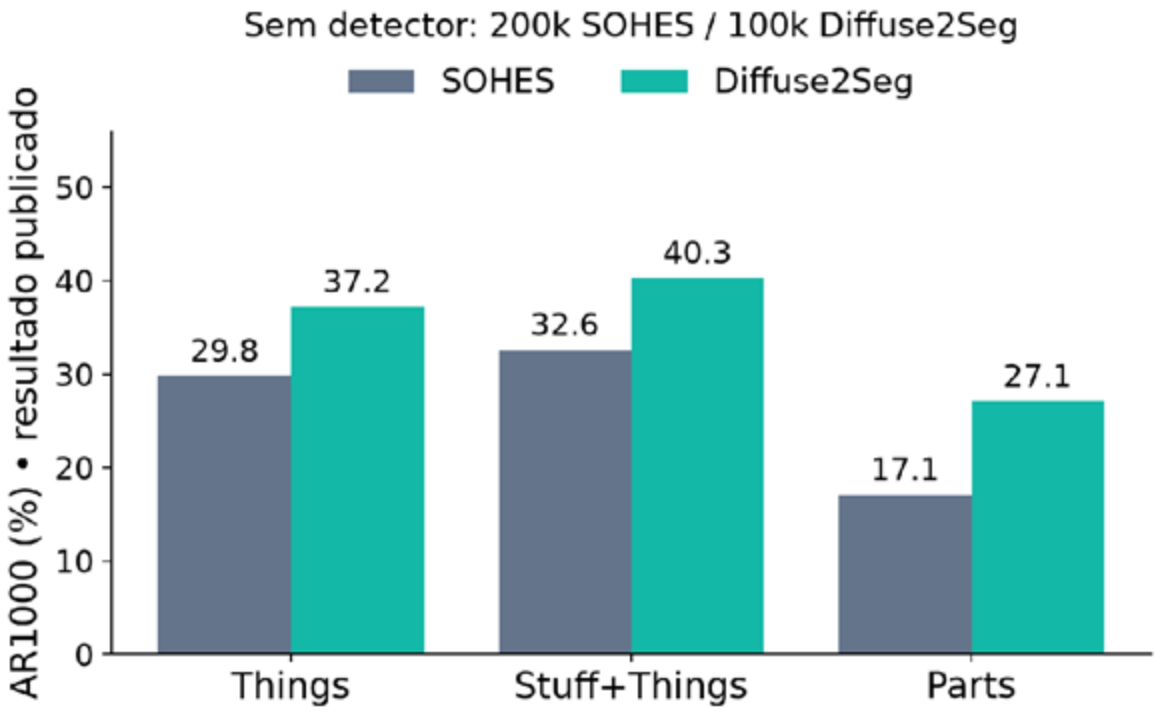
+4,3 a +7,1 p.p. frente ao UnSAM

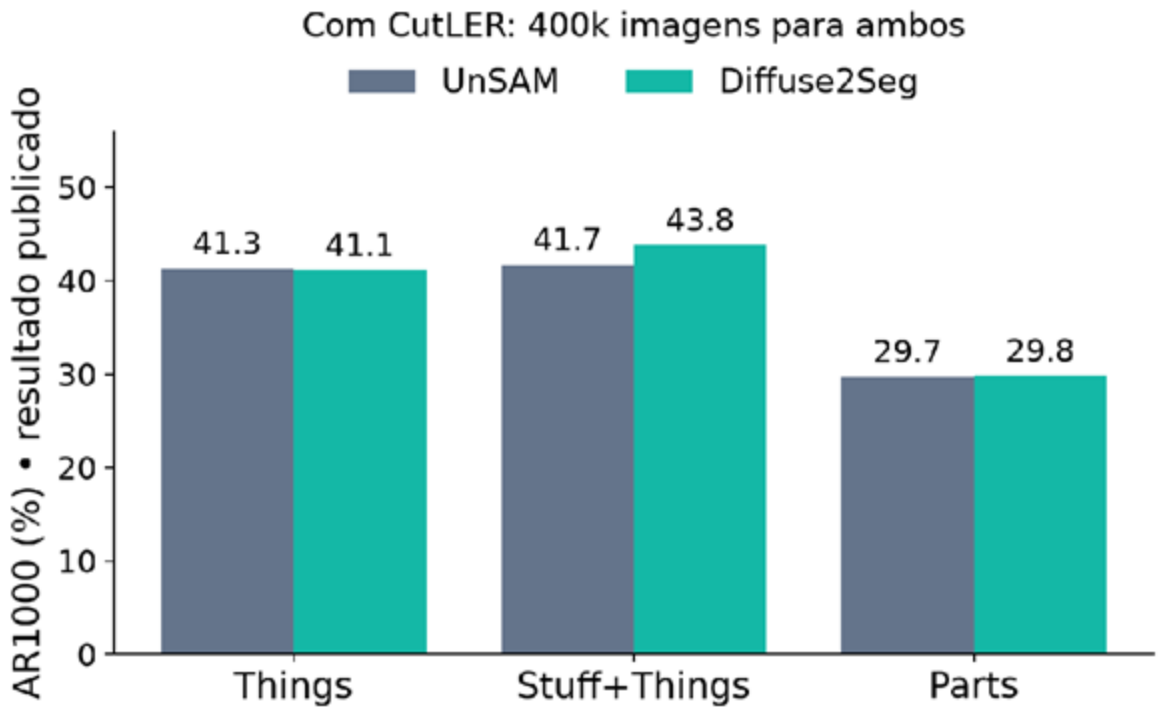
Inclui stuff e partes

CutLER segue maior em ADE20K e UVO

Resultado ORIGINAL • Tabela 2, p. 11

No estudante, a fonte dos rótulos importa





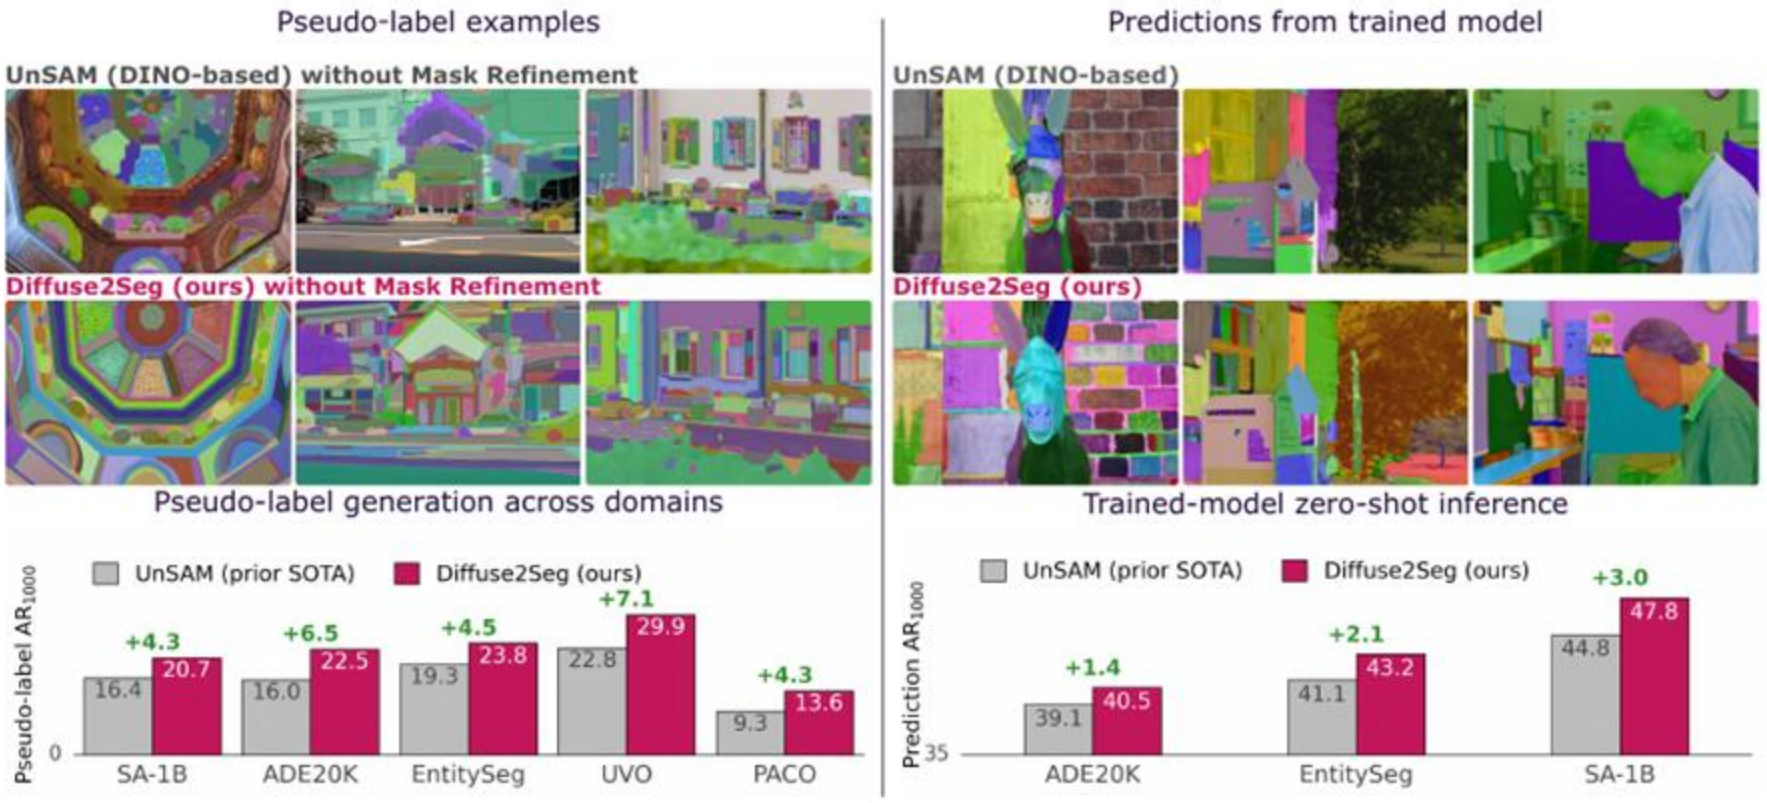
Sem detector: +7,7 p.p. em stuff+things

Com CutLER / 400k: 43,8 vs. 41,7

Things / 400k: 41,1 vs. 41,3

Resultado ORIGINAL • Tabela 3, p. 12

O que as imagens do artigo mostram

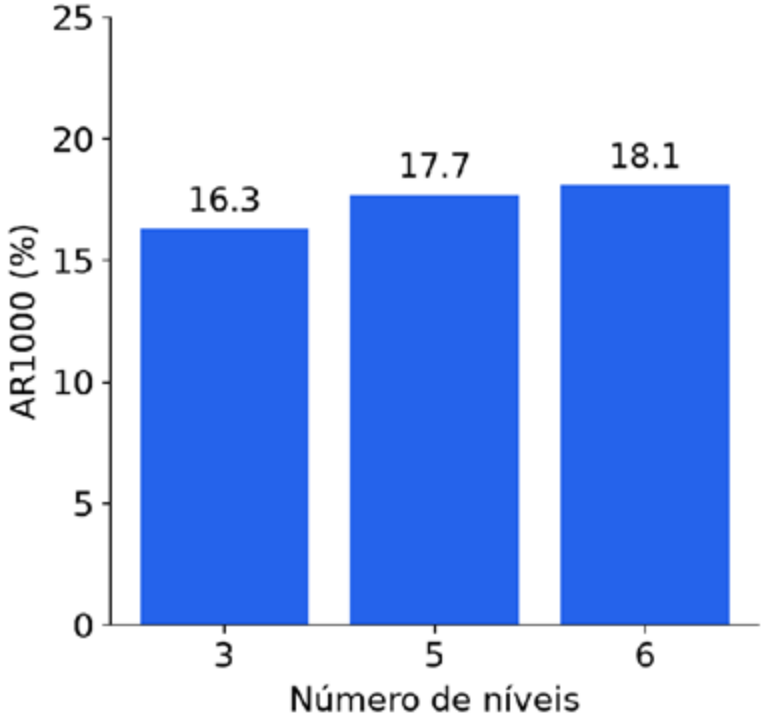


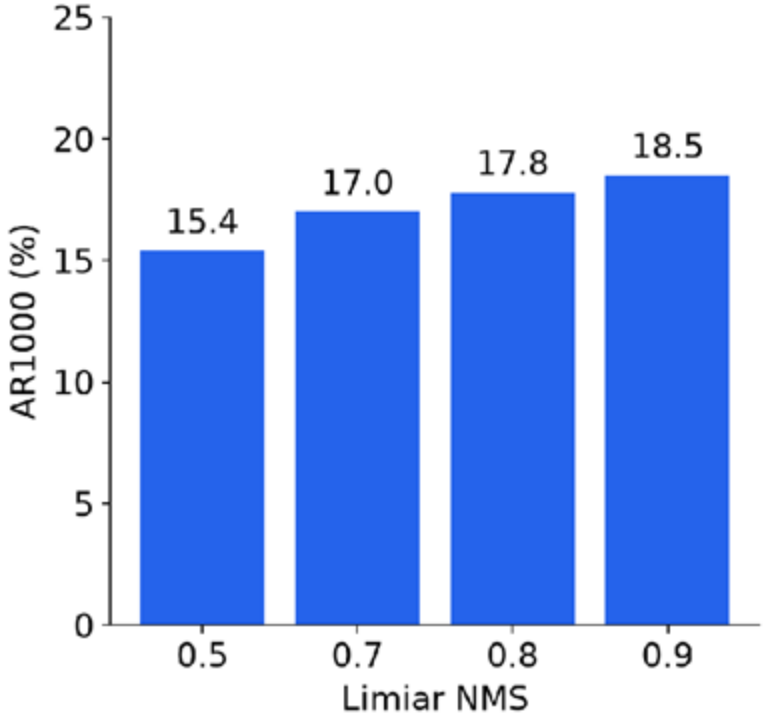
Comparação qualitativa selecionada pelos autores

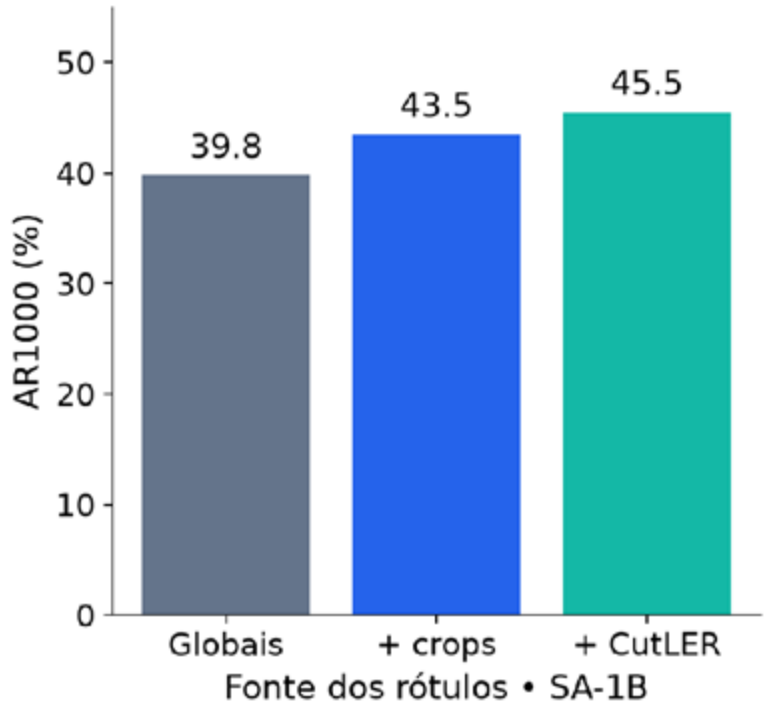
Cobertura de fundo e limites de entidades

Exemplos não substituem avaliação sistemática

Ablações: preservar propostas melhora recall







3 → 6 níveis: +1,8 p.p.

NMS 0,5 → 0,9: +3,1 p.p.

Crops em SA-1B: +3,7 p.p.

Poucos rótulos humanos: qual é a comparação?

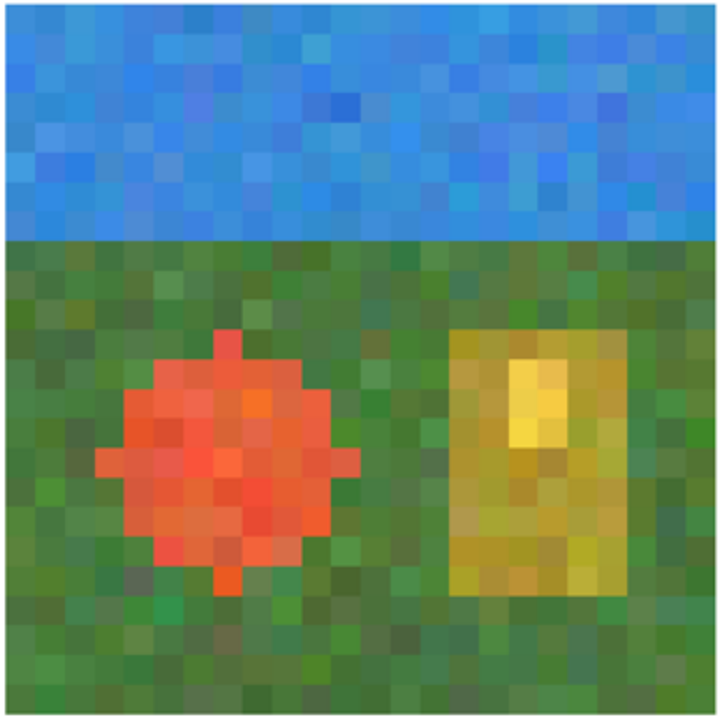
01 Referência supervisionada 100k: 51,1 mAR

02 100 imagens de ajuste: 93,5% da referência

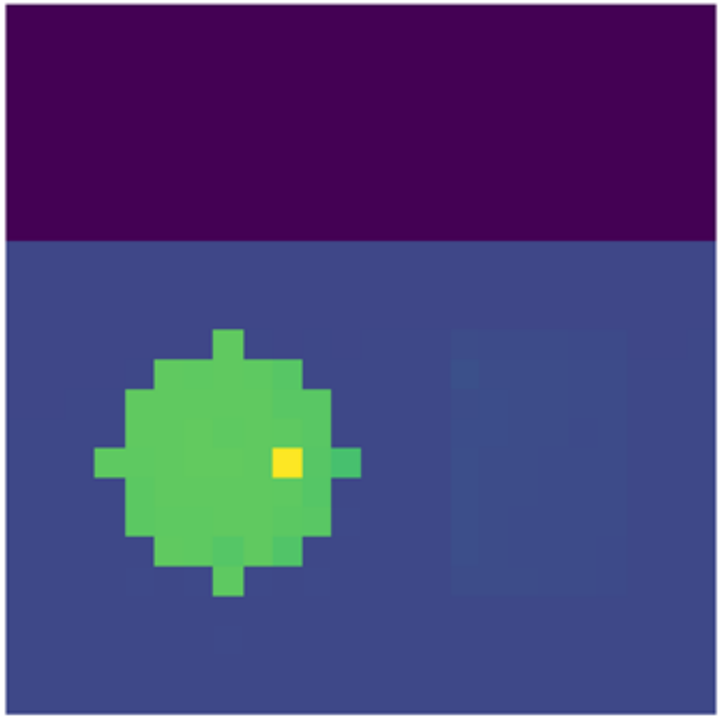
03 10k: ganho reportado de 1,4 p.p.

Nossa reprodução: o que entrou no teste

Imagem sintética



Mapa suave • prompt 9



Partição fina • p=1,6



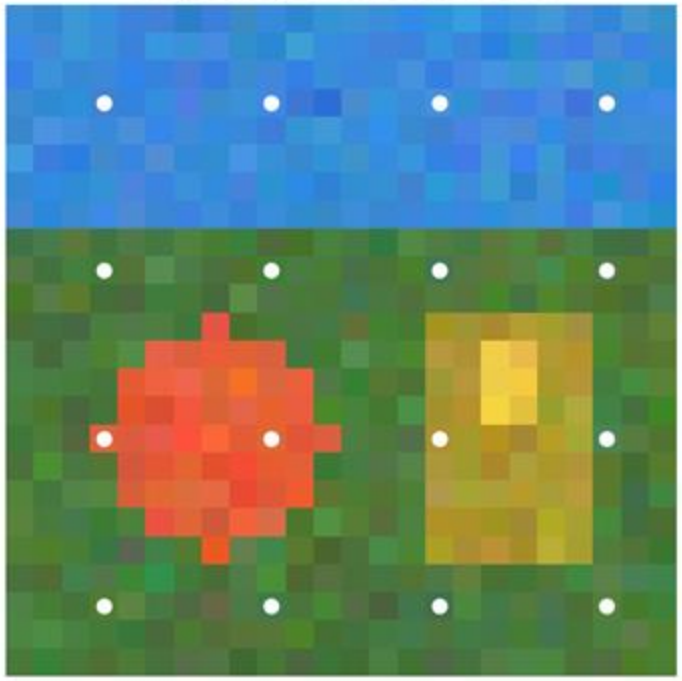
Algoritmos de propagação e fusão

Grafo RGB/posição, 24² pixels, 16 prompts

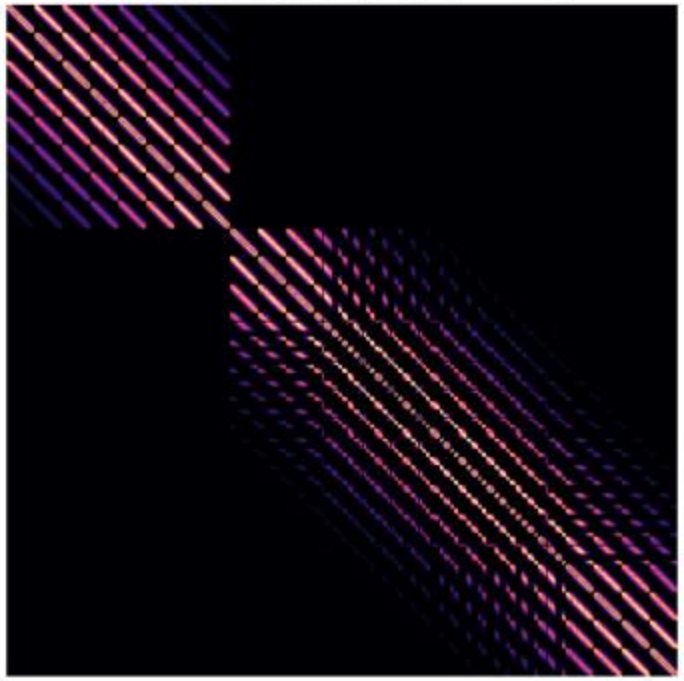
Sem SD2, CascadePSP ou treinamento

Protocolo pequeno, mas verificável

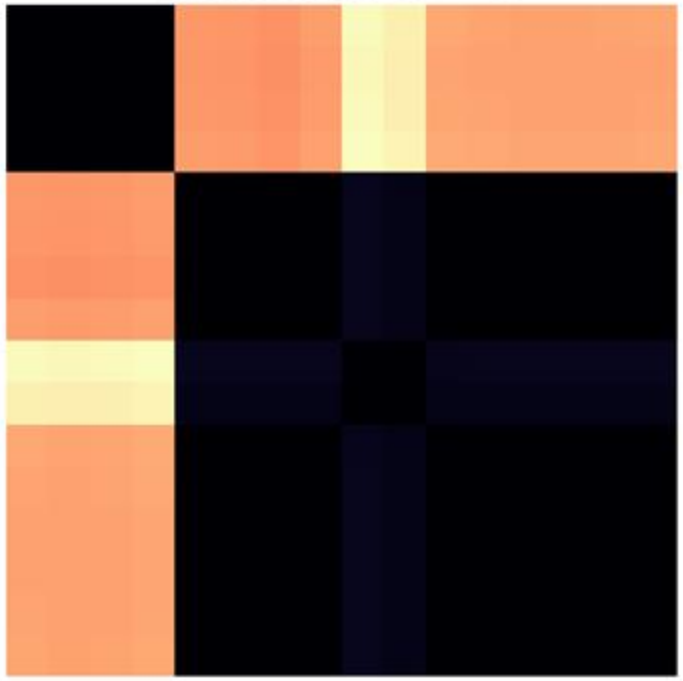
16 prompts automáticos



Afinidade proxy: 576 × 576



KL simétrica: 16 × 16

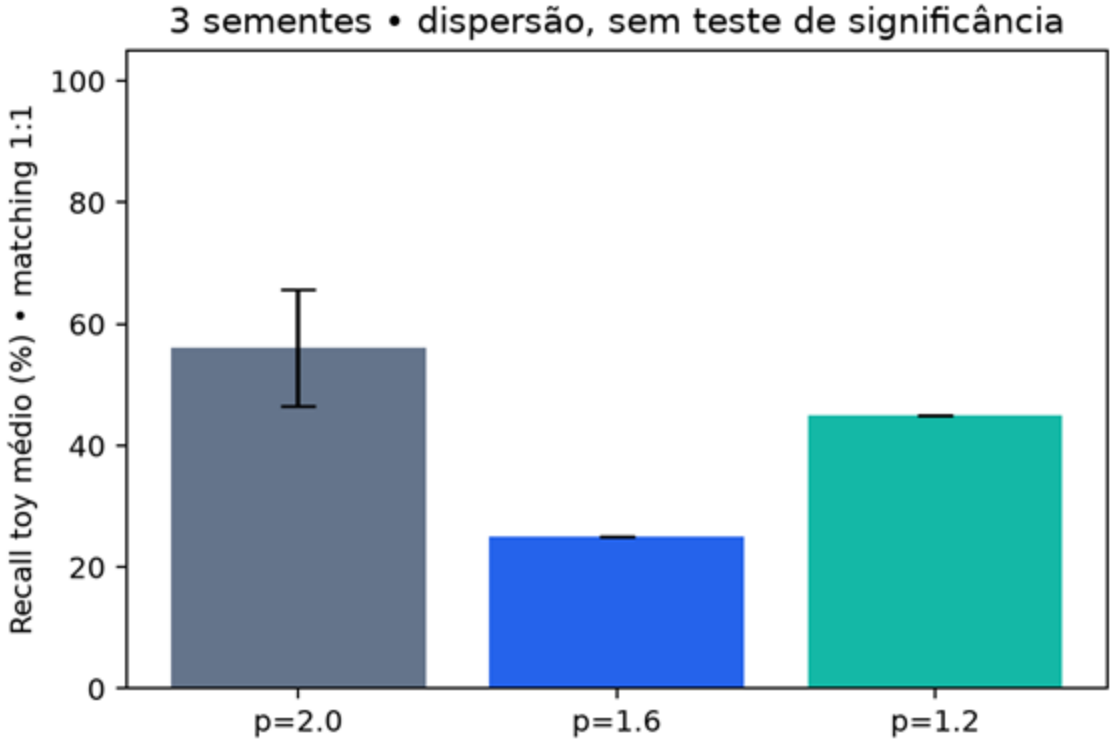


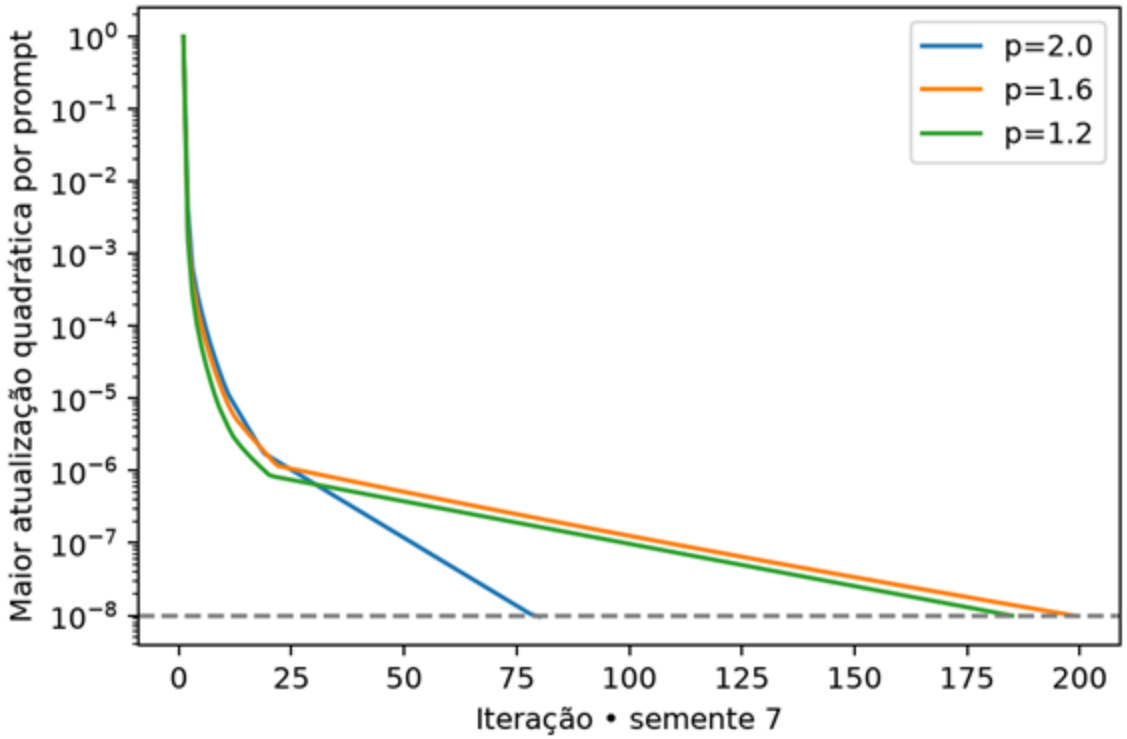
p=2 / 1,6 / 1,2; sementes 7 / 23/ 42

Mesmos grafo, λ, prompts e cortes por semente

Caso linear validado por solução fechada

O resultado local foi diferente do paper





p=2: 56,1% ± 9,6 de recall toy

p=1,6: 25,0%; p=1,2: 45,0%

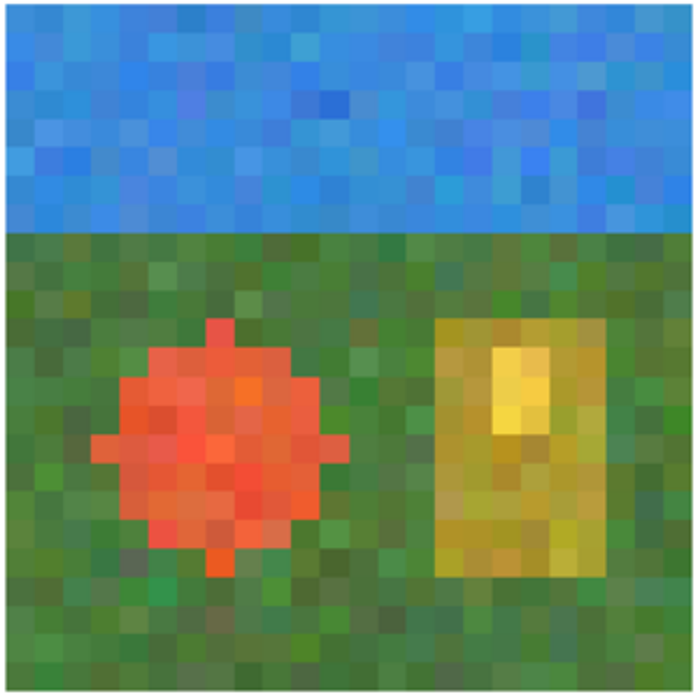
Não houve reprodução do ganho de p<2

RESULTADO LOCAL • 9 execuções • mean ± std amostral

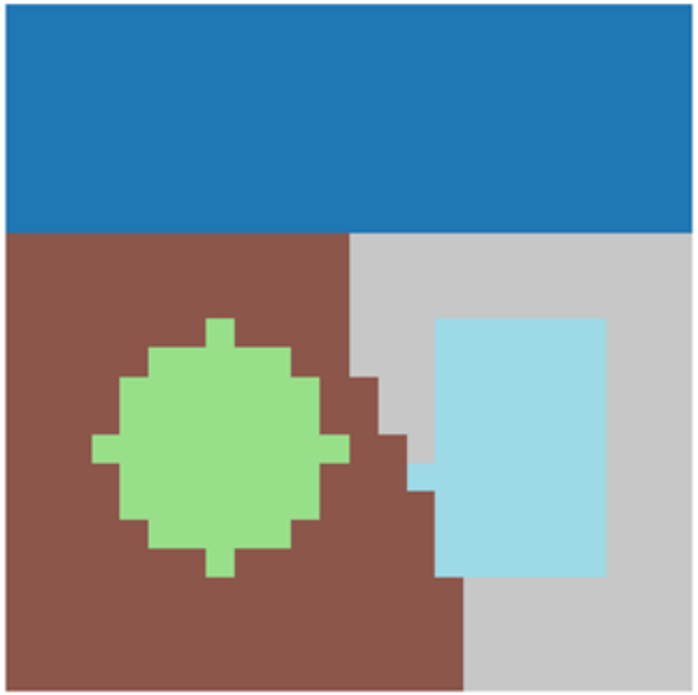
Por que os resultados não são comparáveis?

Partição fina observada • p=1,6 perde entidades neste proxy

Entrada • semente 7



p = 2.0 • mesmo grafo/λ/cortes KL



p = 1.6 • mesmo grafo/λ/cortes KL



Autoatenção SD2 foi substituída por similaridade RGB

Mesma cena toy; nenhum benchmark do paper

Pior fusão em p=1,6: entidades desaparecem

RESULTADO LOCAL • semente 7; análise própria

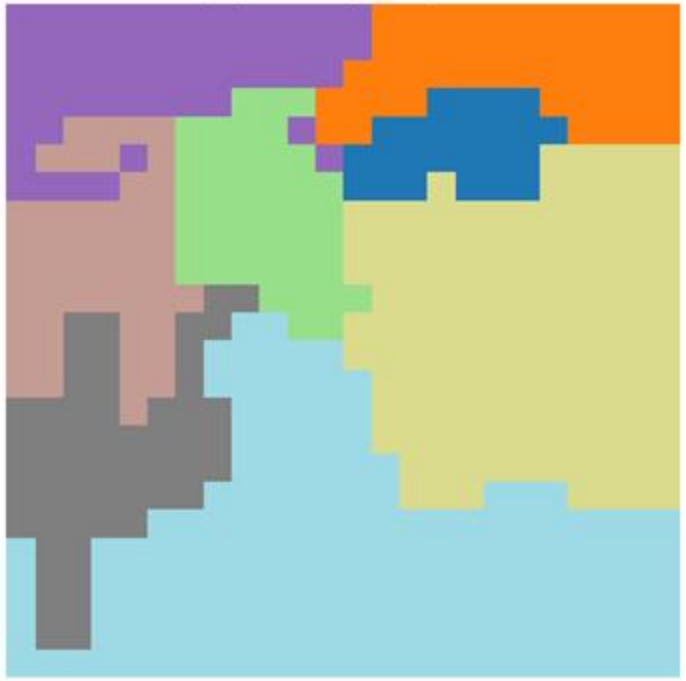
Fotografia real: apenas demonstração conceitual

Demonstração conceitual • grafo RGB 24² • sem avaliação COCO

COCO 39769 • fotografia original



Proxy p=2 • partição fina



Proxy p=1,6 • partição fina



Imagem COCO 39769 já usada no ciclo 3

Partições vêm do mesmo proxy RGB

Não há benchmark COCO ou identificação de classe

Limitações e custo: onde o método pode falhar

01 Latent: objetos pequenos podem desaparecer

02 Texturas podem produzir sobresegmentação

03 Afinidade densa 140^2: 1,43 GiB só em FP32

O que isso oferece para pistas SAR?



Experimento futuro com controle

01 Congelar split, checkpoint e baseline SAM

02 Avaliar crops, depois qualidade dos pseudo-rótulos

03 Teste final: IoU/Dice, falsos positivos e custo

Conclusões

01 Representações generativas podem supervisionar segmentação

02 Propagação + hierarquia conectam pontos a entidades

03 Nossa reprodução explica operações, não valida o benchmark

Obrigado pela atenção!

Inatel

Forms



https://forms.gle/yuWT9ZbZK7m9QyFm9

Código, notebooks e artigos



https://github.com/Mestrado-Matheus-Fonseca/matheus-983-tp558

Referências principais

[1] Hümmer et al. Diffuse2Seg: Diffusion Models Can Segment Anything Without Supervision. arXiv:2609.06491v1

PDFs, código e notebooks no repositório da disciplina.

Dúvidas

Inatel

Perguntas?